

混合专家模型：
通过门控网络给每个问题分配合适的专家，赋予不同的权重，再生成结果

蒸馏模型——“高仿版”
deepseek R1 distill qwen 32B
用阿里的qwen 32B参数比较小的模型去学习满血版deepseek R1 671B的输出结果。据此调整参数做出一个高仿版deepseek R1。
量化模型——原放大模型的压缩版
将模型中精度极高的参数转化为精度没有那么高的参数。从来降低模型的体积和性能要求。
OpenAI-安德烈 卡帕斯Andrej karpathy

AI大模型知识体系

