

在这个基础上，业务目标提升员工效率，统计技术文档查询，知识范围先从研发部试点，主要是专利论文等知识，用户范围给研发部专用，性能指标希望响应速度较快，支持用户数50人左右，主要大模型回答准确。接入大模型是deepSeekR170B，模型部署在本地服务器。在这基础上，添加如何上传文件，考虑异地如何上传。给我一个完整方案0912

针对您提出的非常具体和典型的企业级需求，我将为您量身定制一个**完整的、可执行的、安全的**搭建方案。

这个方案将严格遵循您的需求：**研发部门试点、专利论文知识、50用户、DeepSeek-R1 70B本地部署、快速响应、高准确性，并包含安全的异地文件上传方案。**

企业研发知识库完整搭建方案(试点版本)

一、核心目标与设计原则

- 核心业务目标**：显著减少研发人员查询专利、技术论文的时间，提升创新效率。
- 设计原则**：
 - 安全性第一**：所有数据（尤其是专利）存储和处理均在内部网络，外网访问需通过安全通道。
 - 用户体验优先**：界面简洁，问答准确，响应迅速（目标 < 3秒）。
 - 可维护性与扩展性**：**全部组件容器化**，为未来扩展至全公司打好基础。

二、技术架构选型(优化版)

针对50人研发团队和专利文档的特点，我们对技术栈进行微调，在保证性能的同时简化部署：

组件	推荐选型	理由
AI 模型	DeepSeek-R1 70B	您的指定模型，强大的代码和知识能力，非常适合研发场景。
模型服务框架	vLLM	关键选择! 专为大规模LLM的高效推理设计，支持 动态批处理 和 PagedAttention ，能显著提升70B大模型的 并发吞吐量和响应速度 ，完美匹配50人同时使用的需求。
向量数据库	Chroma	轻量、易用、API简单。对于试点项目，专利文档量在百万级以内，Chroma性能完全足够，极大降低运维复杂度。
元数据库	PostgreSQL	存储用户权限、聊天历史、文档元数据，稳定可靠。
文件存储	MinIO	创建独立桶（bucket）如 rd-patents 和 rd-papers 来存放原始文件。

组件	推荐选型	理由
可视化界面	Open WebUI	开源，功能完善，支持用户权限管理，研发人员易于上手。
部署方式	Docker Compose	一套命令即可拉起所有服务，非常适合试点和中小规模部署。
异地访问/上传	Tailscale + Open WebUI	关键选择！ 使用 零信任网络 方案Tailscale，为异地员工提供安全、便捷的内网接入，无需复杂VPN配置。文件通过Open WebUI界面上传。

三、详细部署与配置流程

前提： 确保本地服务器已安装 Docker, Docker Compose, NVIDIA Container Toolkit，并拥有足够显存（建议至少 2*80GB GPU）来运行70B模型。

1. 定义 Docker Compose 环境

创建 docker-compose.yml 文件，定义所有服务。以下是核心片段：

```
version: '3.8'

services:
  # 1. DeepSeek-R1 70B 服务（使用vLLM加速）
  deepseek-api:
    image: vllm/vllm-openai:latest
    container_name: deepseek-api
    deploy:
      resources:
        reservations:
          devices:
            - driver: nvidia
              count: all
              capabilities: [gpu]
    volumes:
      - /path/to/your/deepseek-r1-70b-model:/model # 将下载模型文件挂载进来
    command: [
      "python", "-m", "vllm.entrypoints.openai.api_server",
      "--model", "/model",
      "--tensor-parallel-size", "2", # 根据你的GPU数量调整
      "--served-model-name", "deepseek-r1",
      "--api-key", "your_secret_api_key_here" # 设置API密钥，增加安全性
    ]
    networks:
      - kb-network

  # 2. 向量数据库
  chroma:
    image: chromadb/chroma:latest
    container_name: chroma-db
    networks:
```

```
- kb-network
volumes:
- chroma_data:/chroma/chroma
```

3. 元数据库

```
postgres:
  image: postgres:15
  container_name: kb-postgres
  environment:
    POSTGRES_DB: knowledge_base
    POSTGRES_USER: admin
    POSTGRES_PASSWORD: strong_password_here
  volumes:
    - postgres_data:/var/lib/postgresql/data
  networks:
    - kb-network
```

4. 文件存储

```
minio:
  image: minio/minio
  container_name: minio
  command: server /data --console-address ":9001"
  environment:
    MINIO_ROOT_USER: minioadmin
    MINIO_ROOT_PASSWORD: minioadmin_password
  volumes:
    - minio_data:/data
  networks:
    - kb-network
```

5. 可视化界面

```
open-webui:
  image: ghcr.io/open-webui/open-webui:main
  container_name: open-webui
  depends_on:
    - deepseek-api
    - chroma
    - postgres
  ports:
    - "3000:8080" # 本地访问端口
  environment:
    # 指向我们的vLLM服务, vLLM兼容OpenAI API格式
    - OPENAI_API_KEY=your_secret_api_key_here
    - OPENAI_API_BASE_URL=http://deepseek-api:8000/v1
    - WEBUI_SECRET_KEY=your_secure_secret_for_session_encryption
    # 配置默认使用本地模型
    - DEFAULT_MODEL=deepseek-r1
    - DEFAULT_MODEL_OVERRIDE=deepseek-r1
    # 连接Chroma
    - CHROMA_URL=http://chroma:8000
  networks:
    - kb-network
  restart: unless-stopped
```

```
networks:
  kb-network:
    driver: bridge
```

```
volumes:
  chroma_data:
  postgres_data:
  minio_data:
```

2. **启动所有服务** 在包含 docker-compose.yml 的目录下运行：

```
docker compose up -d
```

所有服务将在后台启动。

四、核心功能实现：文件上传与知识库构建

1. 安全的异地访问与上传方案

- **在服务器上安装 Tailscale**：按照官方指南，在知识库服务器上安装并启用 Tailscale。
- **为每位异地研发人员安装 Tailscale**：让他们用企业邮箱注册并加入你的 Tailscale 网络。
- **访问知识库**：研发人员获得内网IP后，即可在浏览器中通过 `http://<服务器-tailscale-ip>:3000` 安全地访问 Open WebUI 界面，如同在公司内网一样。

2. 文件上传与处理流程

1. **上传**：研发人员登录 Open WebUI 后，使用其内置的“**文档上传**”功能，将专利 PDF、论文等文件直接拖入或选择上传。
2. **自动化处理**（后台魔法）：
 - Open WebUI 后台会自动将文件存入 MinIO。
 - 随后调用其内置的 **RAG 管道**：
 - **解析**：使用 unstructured 库解析 PDF，提取文本和元数据（如标题、作者）。
 - **分割**：将文本分割成语义恰当的片段。
 - **向量化**：使用内置的嵌入模型（如 all-MiniLM-L6-v2）为每个片段生成向量。
 - **入库**：将向量、文本片段、元数据存储到 Chroma 数据库中。

至此，知识库已构建完毕。

五、使用、统计与优化

1. **使用**：研发人员在 Open WebUI 的聊天界面直接提问，例如：
 - “关于碳纳米管电池的相关专利有哪些？”
 - “总结一下这篇论文的核心创新点。”（同时上传论文）
 - “我们的技术和USPTO专利#XXXXXX相比有什么优势？”
2. **统计技术文档查询**：
 - **初级方案**：直接查询 PostgreSQL 数据库中的 messages 表，可以统计每个用户的提问次数、热门问题等。
 - **高级方案**：集成 Grafana，编写 SQL 查询，制作可视化的数据看板，实时展示知识库使用情况。
3. **确保回答准确**：
 - **优化检索**：在 Open WebUI 设置中调整检索参数，如增加 top_k 值，让模型获得更多上下文。

- **Prompt 工程**：在 Open WebUI 中自定义系统提示词，例如：“你是一个严谨的研发助手，严格根据提供的专利和论文上下文回答问题。如果信息不明确，请回答‘根据现有资料无法确定’。”
- **反馈循环**：鼓励用户使用消息的“点赞/点踩”功能，收集 bad cases，持续优化文档质量和提示词。

总结

该方案为您提供了一个**全栈式、开箱即用、安全可靠**的试点项目框架。

- **核心技术**：vLLM + DeepSeek-R1 70B 确保了大模型服务的高性能和低延迟。
- **安全访问**：Tailscale 提供了媲美VPN的安全性，但用户体验远超传统VPN。
- **便捷操作**：Open WebUI 提供了从文件上传、知识库管理到问答交互的完整可视化界面，极大降低了使用和维护门槛。
- **清晰路径**：所有组件容器化，未来若试点成功，可平滑迁移至 Kubernetes 集群以支持全公司规模。

接下来，您只需要准备硬件资源，按步骤部署，即可开始向研发团队交付价值。