

Deepseek技术浅析（三）：训练方法

原创 爱研究的小牛 最新推荐文章于 2025-02-07 00:33:01 发布 阅读量2.5k 收藏8 点赞数10

CC 4.0 BY-SA版权

分类专栏：大模型 文章标签：人工智能 AIGC 深度学习

Deepseek 是一个先进的深度学习平台，其训练方法涵盖了多种前沿技术，包括 分布式训练、混合精度训练、强化学习与多词元预测、持续学习与微调 以及 人类反馈的强化学习（RLHF）。

1. 分布式训练

分布式训练通过将计算任务分配到多个设备（如 GPU、TPU）或多个节点上，加速模型训练。

1.1 数据并行（Data Parallelism）

数据并行是最常见的分布式训练方法，将数据分片分配到多个设备上，每个设备计算梯度并同步更新模型参数。

公式：

数据并行的梯度更新公式为：

$$\theta \leftarrow \theta - \eta \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} \mathcal{L}(x_i, y_i; \theta)$$

CSDN @爱研究的小牛

其中：

- θ 是模型参数。
- η 是学习率。

具体实现：

- 数据分片**：将训练数据分片分配到多个设备上。
- 梯度计算**：每个设备计算本地梯度。

- 3. **梯度同步**：通过 All-Reduce 操作同步梯度。
- 4. **参数更新**：更新全局模型参数。

1.2 模型并行 (Model Parallelism)

模型并行将模型的不同部分分配到多个设备上，适用于超大模型训练。

公式：

模型并行的前向传播公式为：

$$h_{i+1} = f_i(h_i; \theta_i)$$

CSDN @爱研究的小牛

其中：

- h_i 是第 i 层的输入。
- f_i 是第 i 层的计算函数。
- θ_i 是第 i 层的参数。

具体实现：

- 1. **模型分片**：将模型的不同层分配到多个设备上。
- 2. **前向传播**：每个设备计算本地层的输出。
- 3. **反向传播**：每个设备计算本地层的梯度。
- 4. **梯度同步**：通过设备间通信同步梯度。

2. 混合精度训练

混合精度训练通过使用半精度（FP16）和单精度（FP32）浮点数，加速训练并减少内存占用。

2.1 基本原理

混合精度训练的核心思想是在前向传播和反向传播中使用 FP16，在参数更新中使用 FP32。

公式：

混合精度训练的梯度更新公式为：

$$\theta_{\text{FP32}} \leftarrow \theta_{\text{FP32}} - \eta \nabla_{\theta_{\text{FP16}}} \mathcal{L}(x, y; \theta_{\text{FP16}})$$

具体实现：

- 1. **前向传播**：使用 FP16 计算损失函数。
- 2. **反向传播**：使用 FP16 计算梯度。
- 3. **参数更新**：将梯度转换为 FP32 并更新参数。

3. 强化学习与多词元预测

强化学习与多词元预测结合了强化学习和语言模型的优势，用于生成更高质量的文本。

3.1 基本原理

强化学习通过奖励信号优化语言模型的生成策略，多词元预测通过同时预测多个词元提升生成效率。

公式：

强化学习的目标是最大化累计奖励：

$$\mathcal{L}_{\text{RL}} = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^T r_t \right]$$

其中：

- π_{θ} 是语言模型的策略。
- r_t 是第 t 步的奖励。

具体实现：

1. **策略优化**：使用 Policy Gradient 或 PPO 优化语言模型的策略。
2. **多词元预测**：同时预测多个词元，提升生成效率。

4. 持续学习与微调

持续学习与微调通过在已有模型的基础上进行增量训练，适应新任务或新数据。

4.1 基本原理

持续学习通过正则化或知识蒸馏防止模型遗忘旧知识，微调通过少量数据调整模型参数。

公式：

持续学习的损失函数为：

$$\mathcal{L}_{\text{CL}} = \mathcal{L}_{\text{new}} + \lambda \mathcal{L}_{\text{old}}$$

CSDN @爱研究的小牛

其中：

- L_{new} 是新任务的损失。
- L_{old} 是旧任务的损失。
- λ 是正则化系数。

具体实现：

- 1. **正则化**：使用 L2 正则化或 Elastic Weight Consolidation (EWC) 防止遗忘。
- 2. **知识蒸馏**：使用旧模型的输出作为软标签，指导新模型的训练。

5. 人类反馈的强化学习 (RLHF)

人类反馈的强化学习通过结合人类反馈和强化学习，优化模型的生成策略。

5.1 基本原理

RLHF 的核心思想是通过人类反馈构建奖励函数，指导强化学习优化模型。

公式：

RLHF 的目标是最大化人类反馈的奖励：

$$\mathcal{L}_{\text{RLHF}} = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^T r_{\text{human}}(x_t, y_t) \right]$$

CSDN @爱研究的小牛

其中：

- $r_{\text{human}}(x_t, y_t)$ 是人类反馈的奖励。

具体实现：

- 1. **奖励模型训练**：使用人类反馈数据训练奖励模型。
- 2. **策略优化**：使用强化学习方法（如 PPO）优化语言模型的策略。

6. 关键技术公式总结

1. 数据并行梯度更新：

$$\theta \leftarrow \theta - \eta \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} \mathcal{L}(x_i, y_i; \theta)$$

2. 混合精度梯度更新：

$$\theta_{\text{FP32}} \leftarrow \theta_{\text{FP32}} - \eta \nabla_{\theta_{\text{FP16}}} \mathcal{L}(x, y; \theta_{\text{FP16}})$$

3. 强化学习目标：

$$\mathcal{L}_{\text{RL}} = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^T r_t \right]$$

4. 持续学习损失函数：

$$\mathcal{L}_{\text{CL}} = \mathcal{L}_{\text{new}} + \lambda \mathcal{L}_{\text{old}}$$

5. RLHF 目标：

$$\mathcal{L}_{\text{RLHF}} = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^T r_{\text{human}}(x_t, y_t) \right]$$

CSDN @爱研究的小牛