

# Deepseek技术浅析（五）：强化学习与多词元预测

原创 爱研究的小牛 于 2025-02-12 11:48:45 发布 阅读量1.4k 收藏 25 点赞数 21

CC 4.0 BY-SA版权

分类专栏： 大模型 文章标签： 人工智能 AIGC 深度学习 机器学习

DeepSeek 作为一种先进的深度学习模型架构，不仅集成了专家混合模型（Mixture of Experts, MoE）和动态路由机制，还引入了强化学习（Reinforcement Learning, RL）和多词元预测（Multi-token Prediction）等技术，以进一步提升模型在复杂任务中的表现。

## 一、强化学习在 DeepSeek 中的应用

### 1. 基本原理

强化学习是一种通过与环境的交互进行学习的机器学习范式，其核心思想是智能体（Agent）通过试错（Trial and Error）来学习策略（Policy），以最大化累积奖励（Cumulative Reward）。在 DeepSeek 中，强化学习主要用于优化模型的生成策略，使其生成的结果更符合人类的期望。

### 2. 主要应用场景

- **文本生成**：例如生成更符合用户需求的文本内容。
- **对话系统**：优化对话策略，提高对话的连贯性和准确性。
- **代码生成**：生成更高效、更符合规范的代码。

### 3. 关键技术

#### (1) 强化学习框架

DeepSeek 采用的强化学习框架通常基于 **策略梯度法（Policy Gradient Methods）**，其核心思想是通过梯度上升法优化策略参数，以最大化期望累积奖励。

- **策略函数（Policy Function）**：
  - 定义：策略函数  $\pi_{\theta}(a|s)$  表示在状态  $s$  下采取动作  $a$  的概率，其中  $\theta$  是策略参数。
  - 在 DeepSeek 中，策略函数可以表示为生成下一个词元的概率分布：

$$\pi_{\theta}(a|s) = P(a|s; \theta)$$

CSDN @爱研究的小牛

- **解释：** $a$  是下一个词元， $s$  是当前的上下文信息（例如已生成的文本序列）。
- **奖励函数 (Reward Function)：**
  - 定义：奖励函数  $R(s, a, s')$  表示在状态  $s$  下采取动作  $a$  并转移到状态  $s'$  获得的奖励。
  - 在文本生成任务中，奖励函数可以基于多种指标进行设计，例如：
    - **语言模型得分：**例如困惑度 (Perplexity)。
    - **人类评估得分：**例如语法正确性、语义连贯性等。
    - **任务特定指标：**例如代码生成的正确性、效率等。
- **策略梯度公式：**

$$\nabla J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) R(s, a, s')]$$

CSDN @爱研究的小牛

- **解释：** $J(\theta)$  是目标函数，表示期望累积奖励，目标是最大化  $J(\theta)$ 。

(2) 优势函数 (Advantage Function)

为了减少方差，提高训练稳定性，DeepSeek 通常使用优势函数来代替奖励函数：

- **优势函数定义：**

$$A(s, a) = Q(s, a) - V(s)$$

CSDN @爱研究的小牛

- **解释：** $Q(s, a)$  是状态-动作值函数，表示在状态  $s$  下采取动作  $a$  的预期累积奖励， $V(s)$  是状态值函数，表示在状态  $s$  下的预期累积奖励。
- **策略梯度公式（使用优势函数）：**

$$\nabla J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) A(s, a)]$$

CSDN @爱研究的小牛

(3) 策略优化算法

DeepSeek 可以采用多种策略优化算法，例如：

• REINFORCE 算法：

- **特点：**基于蒙特卡洛采样，计算简单，但方差较大。
- **公式：**

$$\nabla J(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} \log \pi_{\theta}(a_i | s_i) R_i$$

CSDN @爱研究的小牛

- **解释：** $N$  是样本数量， $R_i$  是第  $i$  个样本的累积奖励。

• Actor-Critic 算法：

- **特点：**结合了策略梯度和价值函数估计，能够有效降低方差。
- **公式：**

$$\nabla J(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} \log \pi_{\theta}(a_i | s_i) A_i$$

CSDN @爱研究的小牛

- **解释：** $A_i$  是第  $i$  个样本的优势函数估计值。

• PPO (Proximal Policy Optimization) 算法：

- **特点：**通过限制策略更新的幅度，避免策略崩溃，提高训练稳定性。
- **公式：**

$$\nabla J(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} \log \pi_{\theta}(a_i | s_i) \min \left( \frac{\pi_{\theta}(a_i | s_i)}{\pi_{\theta_{\text{old}}}(a_i | s_i)} A_i, \text{clip} \left( \frac{\pi_{\theta}(a_i | s_i)}{\pi_{\theta_{\text{old}}}(a_i | s_i)}, 1 - \epsilon, 1 + \epsilon \right) A_i \right)$$

CSDN @爱研究的小牛

- **解释：** $\epsilon$  是剪辑参数，用于限制策略更新的幅度。

(4) 奖励塑形 (Reward Shaping)

为了引导模型学习更符合人类期望的行为，DeepSeek 可以使用奖励塑形技术，例如：

- **预训练语言模型得分：**例如使用 GPT 等预训练语言模型对生成结果进行评分，作为奖励信号的一部分。
- **任务特定奖励：**例如在代码生成任务中，使用代码编译器的错误信息作为奖励信号。

二、多词元预测 (Multi-token Prediction)

1. 基本原理

多词元预测是指模型一次性生成多个连续的词元，而不是逐个生成词元。这种方法可以提高生成效率，并减少生成过程中的误差累积。

2. 主要应用场景

- **文本生成：**例如生成完整的句子或段落。
- **代码生成：**生成完整的代码片段或函数。

3. 关键技术

(1) 序列到序列模型 (Seq2Seq Model)

DeepSeek 采用的 Seq2Seq 模型通常基于 Transformer 架构，其核心思想是将输入序列编码为上下文向量，再解码生成目标序列。

- **编码器 (Encoder)：**
  - **功能：**将输入序列  $x = (x_1, x_2, \dots, x_n)$  编码为上下文向量  $h = (h_1, h_2, \dots, h_n)$ 。
  - **结构：**通常由多层 Transformer 编码器层组成。

- **解码器 (Decoder) :**
  - **功能:** 根据上下文向量  $h_h$  和已生成的词元序列  $y_{1:t-1} = (y_1, y_2, \dots, y_{t-1})$  生成下一个词元  $y_t$ 。
  - **结构:** 通常由多层 Transformer 解码器层组成。

(2) 掩码机制 (Masking Mechanism)

为了实现多词元预测，DeepSeek 在解码过程中使用掩码机制来屏蔽未来的词元信息：

- **掩码矩阵 (Mask Matrix) :**
  - **定义:** 定义一个掩码矩阵  $M$  , 其中  $M_{ij} = 1$  表示词元  $y_i$  可以看到词元  $y_j$  , 否则  $M_{ij} = 0$  。
  - **示例:** 对于生成前 3 个词元的任务，掩码矩阵可以表示为：

$$M = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 0 \end{bmatrix}$$

CSDN @爱研究的小牛

- **解释:** 第  $i$  行表示生成第  $i$  个词元时可以看到哪些词元。
- **注意力机制中的掩码:**
  - 在计算注意力权重时，将掩码矩阵应用于注意力得分矩阵，以屏蔽未来的词元信息。

(3) 束搜索 (Beam Search)

为了生成更优的词元序列，DeepSeek 通常使用束搜索算法：

- **定义:** 在每个时间步，保留  $k$  个最优的候选序列（称为束），其中  $k$  是束宽度。
- **步骤:**
  - 1.初始化束为包含起始符的序列。
  - 2.在每个时间步，对每个候选序列生成所有可能的下一个词元，并计算其得分。
  - 3.选择得分最高的  $k$  个候选序列作为新的束。

4.重复步骤 2 和 3，直到生成终止符或达到最大长度。

(4) 训练目标

DeepSeek 的多词元预测训练目标通常基于最大似然估计（Maximum Likelihood Estimation, MLE）：

- 目标函数：

$$L(\theta) = -\frac{1}{N} \sum_{i=1}^N \log P(y_i|x_i; \theta)$$

- 解释：  $N$  是样本数量，  $y_i$  是目标序列，  $x_i$  是输入序列，  $\theta$  是模型参数。

三、过程模型公式

以下是 DeepSeek 中强化学习与多词元预测的简化过程模型公式：

1. 强化学习

- (1) 策略函数：

$$\pi_{\theta}(a|s) = P(a|s; \theta)$$

- (2) 优势函数：

$$A(s, a) = Q(s, a) - V(s)$$

- (3) 策略梯度：

$$\nabla J(\theta) = \mathbb{E}_{\pi_{\theta}}[\nabla_{\theta} \log \pi_{\theta}(a|s) A(s, a)]$$

(4) PPO 算法：

$$\nabla J(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla_{\theta} \log \pi_{\theta}(a_i|s_i) \min \left( \frac{\pi_{\theta}(a_i|s_i)}{\pi_{\theta_{\text{old}}}(a_i|s_i)} A_i, \text{clip} \left( \frac{\pi_{\theta}(a_i|s_i)}{\pi_{\theta_{\text{old}}}(a_i|s_i)}, 1 - \epsilon, 1 + \epsilon \right) A_i \right)$$

2. 多词元预测

(1) 编码器输出：

$$h = \text{Encoder}(x)$$

(2) 解码器输出：

$$P(y_t|y_{1:t-1}, x) = \text{Decoder}(h, y_{1:t-1})$$

(3) 束搜索：

- 步骤：
  - 1.初始化束为包含起始符的序列。
  - 2.在每个时间步，对每个候选序列生成所有可能的下一个词元，并计算其得分。
  - 3.选择得分最高的  $k$  个候选序列作为新的束。
  - 4.重复步骤 2 和 3，直到生成终止符或达到最大长度。

(4) 训练目标：

$$L(\theta) = -\frac{1}{N} \sum_{i=1}^N \log P(y_i|x_i; \theta)$$

