

DeepSeek R1，基于局域网AI模型部署与企业内网实施方案

原创 程序员-zeng哥 已于 2025-02-21 09:42:36 修改 阅读量9.3k 收藏 63 点赞数 49

CC 4.0 BY-SA版权

文章标签： 人工智能 AI编程

@DeepSeek R1，基于局域网AI模型部署与企业内网实施方案

基于局域网AI模型部署与实施方案

版本号：V5.0

发布日期：2025-01-27

一、项目背景

（数字化转型加速期——AI能力将成为团队核心竞争力）

根据Gartner 2024技术趋势报告，到 2026 年，Gartner预测超过80%的企业将使用生成式AI的API或模型，或在生产环境中部署支持生成式AI的应用，而在2023年初这一比例不到5%。

- 代码开发效率提升35%-50%
- 问题解决周期缩短60%

0725
实战布置有参考意义，但是好像没写完，里面有deepseek生成的部分。

北京，2023年10月17日

Gartner发布2024 年十大战略技术趋势

Gartner于今日发布2024年企业机构需要探索的10大战略技术趋势。Gartner研究副总裁Bart Willemsen表示：“由于技术变革以及社会经济方面的不确定性，我们必须大胆采取行动并从战略上提高弹性，而不是采取临时措施。IT领导者的地位特殊，他们可以制定通过技术投资帮助企业在这些不确定性和压力下保持成功的战略规划。”

Gartner杰出研究副总裁兼研究团队负责人Chris Howard表示：“IT领导者和高管必须评估战略技术趋势的影响与益处，但由于技术创新的速度日益加快，这并非易事。例如生成式AI和其他类型的AI虽然带来了新的机遇并推动了若干趋势的发展，但要想通过长期使用AI获得业务价值，还需要采取严谨的方法广泛采用AI并注意风险。”

2024年重要战略趋势包括：

全民化的生成式AI（Democratized Generative AI）

所有人都可以用
企业——员工对接企业知识+技能
基于成熟大模型训练+云计算+开源CCC

经过大规模预训练的模型、云计算与开源的融合正在推动生成式人工智能（生成式AI）的全民化，使这些模型能够被全球工作者所用。到2026年，Gartner预测超过80%的企业将使用生成式AI的API或模型，或在生产环境中部署支持生成式AI的应用，而在2023年初这一比例不到5%。

生成式AI应用可以让企业用户访问并使用大量内部和外部信息源，这意味着生成式AI的快速采用将极大地促进企业知识和技能的全民化。大型语言模型使企业能够通过丰富的语义理解，以对话的形式将员工与知识相连接。

CSDN @dayawoai

AI增强开发 (AI-Augmented Development)

AI增强开发指使用生成式AI、机器学习等AI技术协助软件工程师进行应用设计、编码和测试。AI辅助软件工程提高了开发人员的生产力，使开发团队能够满足业务运营对软件日益增长的需求。这些融入了AI的开发工具能够减少软件工程师编写代码的时间，使他们有更多的时间开展更具战略意义的活动，比如设计和组合具有吸引力的业务应用等。

AI帮助软件工程师进行应用设计、编码、测试

智能应用 (Intelligent Applications)

类似智能体Agent智能应用

Gartner将智能应用中的“智能”定义为自主做出适当响应的习得性适应能力。在许多用例中，这种智能被用于更好地增强工作或提高工作的自动化程度。作为一种基础能力，应用中的智能包含各种基于AI的服务，如机器学习、向量存储和连接数据等。因此，智能应用能够提供不断适应用户的体验。

目前已存在对智能应用的明确需求。在2023年Gartner首席执行官（CEO）和业务高管调查中，26%的CEO认为对企业机构破坏力最大的风险是人才短缺。吸引和留住人才是CEO在人力资源方面的首要任务，而AI被认为是未来三年对他们所在行业影响最大的技术。

CSDN @dayawoai

取自《https://www.gartner.com/cn/newsroom/press-releases/gartner_2024-_top_strategic_tech_trends》

Gartner 预测，到2028年，至少15%的日常工作决策将由代理型AI自主做出，而2024年这一比例为0%。

北京，2024年10月22日

Gartner发布2025 年十大战略技术趋势

Gartner发布2025年企业机构需要探索的十大战略技术趋势。

Gartner研究副总裁高挺 (Arnold Gao) 表示：“今年的重要战略技术趋势涵盖了AI的必要事项和风险，以及计算技术和人机协同等前沿趋势。追踪这些趋势将帮助IT领导者以负责任、和合乎道德的创新方式塑造企业机构的未来。”

以下是2025年重要战略技术趋势。

虚拟劳动力X

代理型AI (Agentic AI)

代理型AI通过自主规划和采取行动实现用户定义的目标。代理型AI为实现能够分担和补充人类工作的虚拟劳动力带来了希望。Gartner 预测，到2028年，至少15%的日常工作决策将由代理型AI自主做出，而2024年这一比例为0%。这项技术的目标导向型功能将实现适应性更强、能够完成各种任务的软件系统。

代理型AI有望实现企业首席信息官 (CIO) 提高生产力的愿望。这一动机促使企业与厂商探索、开创和建立能够提供稳健、安全和可信的代理型AI所需的技术和实践。

AI管理AI？AI治理？
XX

AI治理平台 (AI Governance Platforms)

AI治理平台是Gartner不断发展的AI信任、风险和安全管理 (TRISM) 框架的一部分。AI TRISM使企业能够管理其AI系统的法律、道德和运营绩效。这种技术解决方案能够创建、管理和执行负责任的AI使用策略、解释AI系统的工作原理并提供透明度以建立信任和问责制。

Gartner预测，到2028年，采用综合AI治理平台的企业将比没有这类系统的企业减少40%与AI相关的伦理事件。


CSDN @dayawoai

取自《<https://www.gartner.com/cn/newsroom/press-releases/2025-top-strategic-tech-trends>》

为快速构建企业级AI能力中枢，本项目将打造私有化AI双模支持平台：

□代码与数据100%留存内网（符合ISO 27001信息安全标准）

双模型



CSDN @dayawoai

- 1、战略价值
- 1、成本控制
- 避免SaaS模型按次收费

❑复用现有服务器资源（硬件利用率提升至82%）

2、效率革命

- ❑编程场景：自动生成标准模块代码（ASPICE L2合规）
- ❑技术问答：建立企业级知识库（支持Markdown/Confluence格式导出）

3、风险防控


- ❑代码与数据100%留存内网（符合ISO 27001信息安全标准）
- ❑支持审计日志追溯（精确到用户级操作记录）

4、战略储备

- ❑构建企业专属AI训练集（当前已积累12TB技术文档）
- ❑为后续大模型微调奠定基础设施

部署大模型
建立知识库
收集数据——训练集
训练企业专属大模型

二、系统架构及选择模型评估




- 1、模型选型策略说明
- 1、技术选型依据矩阵

1、技术选型依据矩阵			
评估维度	qwen2.5-coder (32B)	deepseek-r1 (70B)	对标模型(如 GPT-4)
核心能力	多语言代码生成/审查	复杂问题解析与决策支持	通用型任务处理
时延表现	<800ms (代码片段生成)	<1.2s (千字级回答)	1.5-3s (依赖云端传输)
中文支持	专有代码术语库(含 GB/T 标准)	行业知识图谱融合 (证监会/CSRC)	通用中文理解
合规特性	代码审计日志(满足等保 2.0 三级)	会话记录脱敏 (符合 GDPR Article35)	无本地化合规方案
硬件消耗	64GB 内存/8 核 CPU	128GB 内存/16 核 CPU	依赖云端算力

2、qwen2.5-coder核心价值

代码开发者效率提升方案



CSDN @dayawoai

全面超越的性能表现

此时对标deepseekV2，这个大语言模型性能强。在deepseekV3出世前，后大语言模型V3就很强

Qwen2.5-Coder最大的亮点在于其卓越的性能表现。其中，旗舰版本Qwen2.5-Coder-32B在与GPT-4o的12个主流基准测试对决中取得9项胜利，彻底改写了开源代码模型的竞争格局。具体表现在：

- 代码生成能力：在HumanEval、McEval、Spider等多个权威基准测试中全面超越GPT-4o
- 代码修复能力：在Aider基准测试中略胜GPT-4o
- 代码推理能力：在CRUXEval基准上达到与GPT-4o、Claude 3 Opus相当的水平
- 多语言支持：支持92种编程语言，在Haskell、Racket等特定语言上表现尤为出色

如下图所示，Qwen2.5-Coder-32B-Instruct 或许是目前最先进的开源代码模型，其代码能力可与 GPT-4o 相媲美，同时还具备良好的通用性和数学能力。

	Qwen2.5 Coder 32B Instruct	DeepSeek Coder V2 Instruct	DeepSeek Coder 33B Instruct	CodeStral 22B	GPT-4o 2024-08.06	Claude 3.5 Sonnet 2024-10.22
HumanEval	92.7	88.4	79.3	78.1	92.1	92.1
MBPP	90.2	89.2	81.2	73.3	86.8	91.0
EvalPlus Average	86.3	83.8	74.9	73.5	84.4	85.9
MultiPLE	79.4	79.9	69.2	70.2	79.1	83.8
McEval	65.9	62.9	54.3	50.5	65.8	66.5
LiveCodeBench 2024-07 - 2024-11	31.4	27.9	21.3	22.6	34.6	31.6
CRUXEval-O Col	83.4	75.1	50.6	63.5	89.2	87.2
BigCodeBench Instruct Average	38.3	36.3	29.8	29.4	37.6	34.5
Aider Pass@2	73.7	72.9	59.4	51.1	71.4	86.5
Spider	85.1	81.3	73.8	76.6	79.8	74.6
BIRD-SQL	58.4	51.9	45.6	46.2	54.2	49.5
CodeArena v3.1 GPT-4 Turbo G409	68.9	57.4	16.8	21.7	69.1	78.1

技术创新与架构设计

核心技术特点

1. 长文本处理能力

- Qwen2.5-Coder模型具备处理长文本的能力，支持高达128K tokens的上下文长度。这意味着模型可以在单次输入中处理更长的代码片段或文档，从而提高代码生成和理解的准确性。
- 为了增强模型在处理长文本时的性能，Qwen2.5-Coder采用了YaRN (Yet another Recurrent Network) 技术。这项技术能够有效地扩展模型的长度外推能力，使其在处理超长文本时依然保持高效和准确。

2. 训练数据优化

- Qwen2.5-Coder模型的训练数据经过精心优化，使用了总量高达5.5T tokens的混合数据进行训练。这些数据包括了大量的源代码、文本代码混合数据以及合成数据，确保模型在多种编程场景下都能表现出色。
- 源代码数据涵盖了多种编程语言和框架，文本代码混合数据则包括了代码注释、文档和相关技术文章，合成数据则通过自动生成的方式补充了训练数据的多样性和丰富性。

3. 特殊标记系统


- Qwen2.5-Coder模型引入了多个特殊标记，用于提升代码补全和仓库级代码理解的能力。这些特殊标记能够帮助模型更好地理解代码结构和语义，从而生成更准确和上下文相关的代码。
- 其中一个重要功能是支持文件级代码补全 (Fill in the middle) ，即模型可以在给定的代码片段中间插入缺失的代码。这项功能对于处理大型代码库和复杂项目尤为重要，能够显著提高开发效率和代码质量。

CSDN @clayawoai

注：取自《<https://juejin.cn/post/7442664910323449875>》

3、deepseek-r1战略价值

企业知识中枢架构，完全开源，性能世界前沿，美国震惊！！



CSDN @dayawoai

引言

2025年1月20日，人工智能公司DeepSeek-AI正式发布了全新的大语言模型DeepSeek R1和DeepSeek R1-Zero。这一重磅发布标志着开源大型语言模型（LLMs）在推理能力上的重大突破。DeepSeek R1系列不仅通过创新的强化学习技术实现了推理能力的显著提升，还以开源形式为AI开发者和研究人员提供了强大的工具支持。本文将全面解析DeepSeek R1的技术创新、性能表现及其对人工智能行业的深远影响。

DeepSeek R1的核心技术创新

1、基于强化学习的推理能力提升

DeepSeek R1的核心技术亮点在于其创新的强化学习（RL）方法。不同于传统依赖监督微调（SFT）的训练方式，DeepSeek R1-Zero完全通过强化学习进行训练。这种突破性的方法不仅大幅减少了对标注数据的依赖，还使模型能够自主发展复杂的推理能力，包括自我验证、反思和思维链（Chain-of-Thought, CoT）推理等高级认知功能。

2、创新的多阶段训练流程

DeepSeek R1采用了创新的多阶段训练管道，巧妙结合了冷启动数据预训练和强化学习，确保模型输出既保持高准确性，又能完美符合用户预期。

- **预训练阶段：冷启动数据构建**

通过精心筛选的人工标注长思维链（CoT）示例对模型进行初始化，奠定基础推理结构能力。

- **强化学习阶段：能力深度优化**

模型通过精心设计的强化学习任务，获得关于准确性、逻辑连贯性和用户偏好的多维度奖励信号。

- **拒绝采样微调阶段：输出质量提升**

对强化学习的输出进行针对性微调，进一步强化最优推理模式，提升模型表现。

CSDN @dayawoai


3、突破性的蒸馏技术实现

为解决大型语言模型的计算资源消耗问题，DeepSeek-AI通过创新的知识蒸馏技术，成功将DeepSeek R1的卓越能力迁移到更轻量级的模型中。这些小型模型（参数规模从1.5B到70B不等）在保持强大推理性能的同时，显著降低了计算资源需求，为企业级应用提供了更实用的解决方案。

CSDN @dayawoai

全方位性能评测与行业对标

DeepSeek R1系列模型在众多权威基准测试中展现出卓越表现，全面对标业界领先的OpenAI o1模型。以下是详细的性能评测数据：



核心推理能力评测

- **AIME 2024评测**：DeepSeek R1在首次通过率 (pass@1) 方面达到79.8%，与OpenAI o1-1217旗鼓相当。
- **MATH-500挑战**：在数学推理任务中，DeepSeek R1取得97.3%的优异成绩，展现出强大的数学推理能力。
- **GPQA Diamond测试**：在事实推理任务中，DeepSeek R1获得71.5%的pass@1得分，仅略低于OpenAI o1-1217的75.7%。
- **MMLU综合测试**：DeepSeek R1达到90.8%的高分，证明了其在多领域知识理解和应用方面的卓越表现。

编程与STEM领域表现

- **Codeforces编程竞赛**：DeepSeek R1以96.3%的优异成绩，展现出顶级的代码生成能力。
- **SWE-Bench实际验证**：在软件工程基准测试中，DeepSeek R1达到49.2%的解决率，显示出强大的实际编程能力。

CSDN @dayawoai

在这里插入图片描述

创新的蒸馏模型性能

DeepSeek-AI的蒸馏技术不仅保持了模型的卓越性能，更在实际应用中展现出显著的效率优势。下图展示了蒸馏模型系列的详细表现：

	AIME 2024 pass@1	AIME 2024 cons@64	MATH- 500 pass@1	GPQA Diamond pass@1	LiveCodeBench pass@1	CodeForces rating
GPT-4o-0513	9.3	13.4	74.6	49.9	32.9	759.0
Claude-3.5-Sonnet-1022	16.0	26.7	78.3	65.0	38.9	717.0
o1-mini	63.6	80.0	90.0	60.0	53.8	1820.0
QwQ-32B	44.0	60.0	90.6	54.5	41.9	1316.0
DeepSeek-R1-Distill-Qwen-1.5B	28.9	52.7	83.9	33.8	16.9	954.0
DeepSeek-R1-Distill-Qwen-7B	55.5	83.3	92.8	49.1	37.6	1189.0
DeepSeek-R1-Distill-Qwen-14B	69.7	80.0	93.9	59.1	53.1	1481.0
DeepSeek-R1-Distill-Qwen-32B	72.6	83.3	94.3	62.1	57.2	1691.0
DeepSeek-R1-Distill-Llama-8B	50.4	80.0	89.1	49.0	39.6	1205.0
DeepSeek-R1-Distill-Llama-70B	70.0	86.7	94.5	65.2	57.5	1534.0

掘金技术社区 @15340

CSDN @dayawoai

蒸馏模型的创新价值：

- **显著降低部署成本：**通过先进的蒸馏技术，企业可以在有限算力条件下部署高性能AI模型，特别适合中小型企业 and 研究机构的实际需求。
- **灵活的部署方案：**轻量级模型更适合边缘计算设备或移动终端部署，大大拓展了应用场景。
- **技术普惠价值：**开源的蒸馏模型降低了技术门槛，让更多开发者能够参与高质量AI推理模型的开发与应用。

开源生态与可访问性

DeepSeek R1的另一大亮点是其完全开源的特性。模型及其权重均采用MIT License授权，这意味着开发者可以自由使用、修改和商业化DeepSeek R1。此外，DeepSeek-AI特别允许用户利用模型输出进行蒸馏训练，进一步促进了技术创新和知识共享。

CSDN @dayawoai

注：取自《<https://juejin.cn/post/7462611075534618664>》

4、对比方案收益分析

评估项	自建方案	商用 SaaS 方案	开源替代方案
开发效率	↑ 34%（代码复用率提升）	↑ 18%	↑ 9%（需额外调优）
合规成本	↓ 62%（免去跨境数据传输）	↑ 280%（合规审计支出）	↓ 45%
响应速度	200-400ms	800-1200ms	500-800ms

注：数据基于 50 人研发团队+200 人办公用 的基准测算

CSDN @dayawoai

三、实施步骤

参考意义大

1. 环境要求

1、环境需求分析

模型参数规模需求（qwen2.5-coder为32B模型，deepseek-r1为70B模型）

注：具体安装版本需求按照企业自选择，理论上越大越好

组件	基础配置	推荐配置	企业级配置
CPU	Intel Xeon Silver 4310 (12C/24T)	AMD EPYC 7313 (16C/32T)	Intel Xeon Platinum 8462Y+ (32C/64T)
内存	128GB DDR4 ECC	256GB DDR5 ECC	512GB DDR5 ECC + NVDIMM
存储	1TB NVMe SSD	2TB NVMe SSD RAID1	4TB NVMe SSD RAID10
GPU	无（纯 CPU 推理）	2 × NVIDIA A10 (24GB)	4 × NVIDIA A100 80GB
网络	双千兆网卡	10Gbps SFP+	25Gbps 双链路

技术验证数据：

- qwen2.5-coder 32B 模型单实例内存占用约 64GB
- deepseek-r1 70B 模型单实例内存占用约 128GB
- 并行运行需至少 192GB 可用内存（推荐 256GB）

注：具体服务器配置按照企业自选择，理论上越大越好

CSDN @dayawoai

本地部署后跑的就是本地算力了，叠加知识库，可以实现内部的资料对话式查询，资料不上网，更加安全可靠。不同模型需要的电脑配置，以下可供参考：

- 1.5B：CPU最低4核，内存8GB+，硬盘icon3GB+存储空间，显卡icon非必需，若GPU加速可选4GB+显存，适合低资源设备部署等场景。
- 7B：CPU 8核以上，内存16GB+，硬盘8GB+，显卡推荐8GB+显存，可用于本地开发测试等场景。
- 8B：硬件需求与7B相近略高，适合需更高精度的轻量级任务。
- 14B：CPU 12核以上，内存32GB+，硬盘15GB+，显卡16GB+显存，可用于企业级复杂任务等场景。
- 32B：CPU 16核以上，内存64GB+，硬盘30GB+，显卡24GB+显存，适合高精度专业领域任务等场景。
- 70B：CPU 32核以上，内存128GB+，硬盘70GB+，显卡需多卡并行，适合科研机构等进行高复杂度生成任务等场景。


CSDN @程序员-zeng哥

以上数据来源于：<https://www.163.com/dy/article/JNPLRPQ40556B93R.html>

2、资源评估报告

模型资源需求矩阵				
模型	参数规模	内存需求	计算需求	推荐部署方式
qwen2.5-coder	32B	64GB	8核CPU/1×A10	开发环境专用容器
deepseek-r1	70B	128GB	16核CPU/2×A10	问答服务独立实例

上市公司部署建议方案



CSDN @dayawoai

资源配置策略


1、研发侧
使用部署模型：qwen2.5-coder-32B或deepseek-r1-70B
特性：
☐ 支持C/C++/C#/Java/Python多语言
☐ 集成代码审计功能（CWE/SANS TOP25检查）
☐ 开发文档合规性验证（ISO 26262/ASPICE）

2、办公侧
使用部署模型：deepseek-r1-70B
特性：
☐ 企业知识库自动检索
☐ 会话记录审计功能
☐ 敏感词过滤系统

2、服务器端AI模型服务安装

1、Ollama安装

下载地址：<https://ollama.com/>

[Discord](#)[GitHub](#)[Models](#)[Sign in](#)[Download](#)

Get up and running with large language models.


Run [Llama 3.3](#), [DeepSeek-R1](#), [Phi-4](#), [Mistral](#), [Gemma 2](#), and other models, locally.

[Download ↓](#)

Available for macOS,
Linux, and Windows

CSDN @dayawoai

下载后，右键安装即可



2. 模型部署

```
1、进入cmd
2、输入ollama pull deepseek-r1:70b，安装deepseek
3、输入ollama pull qwen2.5-coder:32b，安装qwen2.5
4、新建《start_ollama.bat》赋值下面代码到文件内，双击执行，启动ollama
@echo off
if not "%1"=="hide" (
start /min cmd /c %0 hide
exit
)
echo start ollama...
set OLLAMA_HOST=0.0.0.0:11434
set OLLAMA_ORIGINS=*
echo set env ok, start ollama...
ollama serve
echo Ollama is running in background.
timeout /t 3
exit
```


3. 客户端使用

1、网页访问，查询问题

1、安装使用谷歌浏览器，安装插件，Page Assist - 本地 AI 模型的 Web UI

地址：

<https://chromewebstore.google.com/detail/page-assist-%E6%9C%AC%E5%9C%B0-ai-%E6%A8%A1%E5%9E%8B%E7%9A%84-web/jfgfiigpkhlkbnfnbobbkinehhfdhndo?pli=1>





CSDN @dayawoai

2、打开扩展程序




进行设置服务器地址






设置后，即可访问





2、代码开发辅助

- 1、安装VScode
- 2、安装Continue插件



3、进行配置





CONTINUE + ↺ 🖨 ⚙ ... pc_mqtt.dart 2 扩展: Continue - Codestral, Claude, and more {} config.json × 🗑 ...

助“你识别 表并达的是理解这个一
种情感词语的意思上的。

反应, 当然, 通常如果用来这个问题
回应某种是由某些问题或特定困
惑的方言。或

nihao

“nihao” 是汉语中的一个问候语,
意思是“你好”。这句话非常简洁,
常用于日常交流中表达友好的愿
望。

从你的名字和提供的信息来看, 你
似乎对中文有一些基本的了解, 并
且在使用一些AI相关的工具。如果
是第一次与我互动, 请多包涵, 我

```
C: > Users > Administrator > .continue > {} config.json > [ ] models > {} 1
1  {
2    "models": [
3      {
4        "model": "claude-3-5-sonnet-latest",
5        "provider": "anthropic",
6        "apiKey": "",
7        "title": "Claude 3.5 Sonnet"
8      },
9      {
10       "title": "Qwen 2.5 Coder",
11       "model": "qwen2.5-coder:7b",
12       "provider": "ollama",
13       "apiBase": "http://192.168.1.15:11434"
14     },
15     {
16       "title": "R1DeepSeek",
17       "model": "deepseek-r1:7b",
18       "provider": "ollama",
19       "apiBase": "http://192.168.1.15:11434"
20     },
21   ]
22 }
```

CSDN @dayawoai

注意: “model”: “qwen2.5-coder:7b”,修改成贵公司服务器安装版本

“model”: “deepseek-r1:7b”,修改成贵公司服务器安装版本