

DeepSeek 部署及应用：保姆级别（本地部署、在线API调用，第三方插件调用）

原创

龙域S

已于 2025-02-14 13:42:26 修改

阅读量8.9k

收藏 51

点赞数 31

CC 4.0 BY-SA版权

文章标签：

数据挖掘

人工智能

自然语言处理

语言模型

数据分析

文心一言

0725
详细文档
碎杂多

1、硬件环境要求

最低配置（支持基础7B模型运行）：

CPU：Intel i5 第8代或AMD Ryzen 5 2600

RAM：16GB

存储：至少10GB可用空间

推荐配置（搭载高性能GPU，如NVIDIA RTX系列）：

GPU：NVIDIA RTX 3060或更高

RAM：32GB

存储：至少50GB可用空间

高端配置（适用于70B模型）：

GPU：NVIDIA A100 / RTX 4090

RAM：64GB+

存储：200GB+

不同规模模型对比

1.5B参数模型：轻量快速，适用于日常任务

7B参数模型：平衡选择，适合个人与开发者

32B参数模型：增强性能，适合高负载应用

70B参数模型：最佳性能，适用于专业AI应用

模型参数	Windows配置要求	Mac配置要求	适用场景
1.5B	- RAM: 4GB - GPU: 集成显卡（如GTX 1050）或现代CPU - 存储: 5GB	- 内存: 8GB（统一内存） - 芯片: M1/M2/M3 - 存储: 5GB	简单文本生成/基础代码补全
7B	- RAM: 8-10GB - GPU: GTX 1660（4-bit量化） - 存储: 8GB	- 内存: 16GB - 芯片: M2 Pro/M3 - 存储: 8GB	中等复杂度问答/代码调试
8B	- RAM: 12GB - GPU: RTX 3060（8GB VRAM） - 存储: 10GB	- 内存: 24GB - 芯片: M2 Max - 存储: 10GB	多轮对话/文档分析
14B	- RAM: 24GB - GPU: RTX 3090（24GB VRAM） - 存储: 20GB	- 内存: 32GB - 芯片: M3 Max - 存储: 20GB	复杂推理/技术文档生成
32B	- RAM: 48GB - GPU: RTX 4090（4-bit量化） - 存储: 40GB	- 内存: 64GB - 芯片: M3 Ultra - 存储: 40GB	科研计算/大规模数据处理
70B	- RAM: 64GB - GPU: 双RTX 4090（NVLink） - 存储: 80GB	- 内存: 128GB（需外接显卡坞） - 存储: 80GB	企业级AI服务/多模态处理
671B	- RAM: 256GB+ - GPU: 8xH100（通过NVLink连接） - 存储: 1TB+	暂不支持	超大规模云端推理

2、部署（Ollama）

软件依赖

操作系统：Windows、macOS或Linux。

Docker：如果使用Open Web UI，需要安装Docker。

①安装Ollama

Ollama是一个开源工具，用于在本地轻松运行和部署大型语言模型。

以下是安装Ollama的步骤：

访问Ollama官网（[Ollama](#)）：前往Ollama官网，点击“Download”按钮。

下载安装包：根据你的操作系统选择对应的安装包。下载完成后，直接双击安装文件并按照提示完成安装。

验证安装：安装完成后，在终端输入以下命令，检查Ollama版本：

```
ollama --version
```

如果输出版本号（例如ollama version is 0.5.6），则说明安装成功。

②下载并部署DeepSeek模型

Ollama支持多种DeepSeek模型版本，用户可以根据硬件配置选择合适的模型。以下是部署步骤：

选择模型版本：

入门级：1.5B版本，适合初步测试。

中端：7B或8B版本，适合大多数消费级GPU。

高性能：14B、32B或70B版本，适合高端GPU。

下载模型：

打开终端，输入以下命令下载并运行DeepSeek模型。例如，下载7B版本的命令为：

```
ollama run deepseek-r1:7b
```

如果需要下载其他版本，可以参考以下命令：

ollama run deepseek-r1:8b # 8B版本

ollama run deepseek-r1:14b # 14B版本

ollama run deepseek-r1:32b # 32B版本

```
C:\Users\Administrator>ollama run deepseek-r1:8b
```

```
pulling manifest
```

```
pulling 6340dc3229b0... 100%
```

```
4.9 GB
```

```
pulling 369ca498f347... 100%
```

```
387 B
```

```
pulling 6e4c38e1172f... 100%
```

```
1.1 KB
```

```
pulling f4d24e9138dd... 100%
```

```
148 B
```

```
pulling 0cb05c6e4e02... 100%
```

```
487 B
```

```
verifying sha256 digest
```

```
writing manifest
```

```
success
```

```
>>> 帮我找一个java删除
```

```
<think>
```

```
嗯，用户让我帮忙找一个Java删除的例子，但具体是要什么呢？可能是一个方法、类或者文件。首先，我需要确认他想要的是什么类型的删除操作。
```

安装向量模型

基于本地的deepseek搭建个人知识库。使用本地服务,安装嵌入模型，用于将文本数据转换为向量标识的模型。

需要先下载向量模型

命令行窗口执行拉取下即可。


```
ollama pull bge-m3
```

启动Ollama服务：

在终端运行以下命令启动Ollama服务：

```
ollama serve
```

快捷方式启动：



服务启动后，可以通过访问<http://localhost:11434> 来与模型进行交互。

再次使用窗口时，首先启动ollama，然后窗口启动对应的版本即可开启本地会话

```
管理员: 命令提示符 - ollama r X + v
Microsoft Windows [版本 10.0.22631.4751]
(c) Microsoft Corporation。保留所有权利。


C:\Users\Administrator>ollama run deepseek-r1:8b
>>> 早上好
<think>

</think>

早上好！希望你今天有美好的开始。有什么我可以帮你的吗？

>>> |Send a message (/? for help)
```

推荐一下阿里模型仓库：[魔搭社区](#)





③性能优化与资源管理

资源分配：根据硬件配置选择合适的模型版本。较小的模型（如1.5B到14B）在标准硬件上表现良好，而较大的模型（如32B和70B）需要更强大的GPU支持。

内存管理：确保系统有足够的内存和存储空间，以避免运行时出现资源不足的问题。

注意：模型部署在非C盘的配置：





3、部署 (DeepSeek Coder 和 DeepSeek Chat)

DeepSeek 目前提供多个开源模型，例如 DeepSeek Coder 和 DeepSeek Chat，你可以选择适合的模型进行本地部署。

①确保你的环境支持

- 硬件要求
 - GPU: 推荐 NVIDIA A100 / H100 (至少 16GB+ 显存)
 - CPU: 至少 16 核心
 - RAM: 至少 32GB (建议 64GB+)
 - 磁盘空间: 需要 10GB+ 空间
- 软件要求
 - 操作系统: Ubuntu 20.04 / Windows 10+ / macOS
 - Python: 3.8+

- **CUDA:** 11.8+（如果使用 GPU）
- **Pytorch:** 2.0+

②下载 DeepSeek 本地模型

DeepSeek 开源的 LLM 可以通过 Hugging Face 或者 GitHub 获取：

```
git clone https://huggingface.co/deepseek-ai/deepseek-chat
```

或者：

```
git clone https://github.com/deepseek-ai/deepseek-chat.git
```

你也可以直接使用 transformers 加载模型：

```
from transformers import AutoModelForCausalLM, AutoTokenizer

model_name = "deepseek-ai/deepseek-chat"
tokenizer = AutoTokenizer.from_pretrained(model_name)
model = AutoModelForCausalLM.from_pretrained(model_name)
```

③运行本地 API 服务器

如果你希望通过 API 方式调用本地部署的 DeepSeek，你可以使用 FastAPI 或 Flask 搭建 API 服务器。

安装 FastAPI 和 uvicorn：

```
pip install fastapi uvicorn torch transformers
```

创建 app.py:

```
from fastapi import FastAPI
from pydantic import BaseModel
from transformers import AutoModelForCausalLM, AutoTokenizer
import torch

# 初始化 FastAPI
app = FastAPI()

# 加载模型
model_name = "deepseek-ai/deepseek-chat"
tokenizer = AutoTokenizer.from_pretrained(model_name)
model = AutoModelForCausalLM.from_pretrained(model_name, torch_dtype=torch.float16, device_map="auto")

class ChatRequest(BaseModel):
    prompt: str

@app.post("/chat")
async def chat(request: ChatRequest):
    inputs = tokenizer(request.prompt, return_tensors="pt").to("cuda")
    outputs = model.generate(**inputs, max_length=200)
    response_text = tokenizer.decode(outputs[0], skip_special_tokens=True)
    return {"response": response_text}

# 运行服务器
if __name__ == "__main__":
```

```
import uvicorn
uvicorn.run(app, host="0.0.0.0", port=8000)
```

然后运行：

```
python app.py
```


本地API 就会在 `http://127.0.0.1:8000/chat` 运行。

二、本地使用方案


1、启动本地服务

①启动本地Ollama服务

a、快捷启动




b、命令启动




```
Microsoft Windows [版本 10.0.22631.4751]
(c) Microsoft Corporation. 保留所有权利。

C:\Users\Administrator>ollama serve
2025/02/07 09:18:20 routes.go:1187: INFO server config env="map[CUDA_VISIBLE_DEVICES: GPU_DEVICE_ORDINAL: HIP_VISIBLE_DEVICES: HSA_OVERRIDE_GFX_VERSION: HTTPS_PROXY: HTTP_PROXY: NO_PROXY: OLLAMA_DEBUG:false OLLAMA_FLASH_ATTENTION:false OLLAMA_GPU_OVERHEAD:0 OLLAMA_HOST:http://127.0.0.1:11434 OLLAMA_INTEL_GPU:false OLLAMA_KEEP_ALIVE:5m0s OLLAMA_KV_CACHE_TYPE: OLLAMA_LLM_LIBRARY: OLLAMA_LOAD_TIMEOUT:5m0s OLLAMA_MAX_LOADED_MODELS:0 OLLAMA_MAX_QUEUE:512 OLLAMA_MODELS:C:\\Users\\Administrator\\.ollama\\models OLLAMA_MULTIUSER_CACHE:false OLLAMA_NOHISTORY:false OLLAMA_NOPRUNE:false OLLAMA_NUM_PARALLEL:0 OLLAMA_ORIGINS:[http://localhost https://localhost http://localhost:* https://localhost:* http://127.0.0.1 https://127.0.0.1 http://127.0.0.1:* https://127.0.0.1:* http://0.0.0.0 https://0.0.0.0 http://0.0.0.0:* https://0.0.0.0:* app://* file://* tauri://* vscode-webview://*] OLLAMA_SCHED_SPREAD:false ROCR_VISIBLE_DEVICES:]"
time=2025-02-07T09:18:20.033+08:00 level=INFO source=images.go:432 msg="total blobs: 5"
time=2025-02-07T09:18:20.034+08:00 level=INFO source=images.go:439 msg="total unused blobs removed: 0"
time=2025-02-07T09:18:20.035+08:00 level=INFO source=routes.go:1238 msg="Listening on 127.0.0.1:11434 (version 0.5.7)"
time=2025-02-07T09:18:20.037+08:00 level=INFO source=routes.go:1267 msg="Dynamic LLM libraries" runners="[cpu_avx2 cuda_v11_avx cuda_v12_avx rocm_avx cpu cpu_avx]"
time=2025-02-07T09:18:20.037+08:00 level=INFO source=gpu.go:226 msg="looking for compatible GPUs"
time=2025-02-07T09:18:20.037+08:00 level=INFO source=gpu_windows.go:167 msg="packages count=1"
time=2025-02-07T09:18:20.037+08:00 level=INFO source=gpu_windows.go:214 msg="" package=0 cores=6 efficiency=0 threads=12
```

可以访问<http://localhost:11434/> 验证启动状态



②启动本地大模型：具体版本根据本地使用的模版版本而定



2、调用互联端服务（确保网络连接正常）

①DeepSeek 使用及领取API KEY

1. 打开地址：<https://www.deepseek.com>
2. 可以直接在网页进行chat对话，（如需拿到API key进行本地部署调用，请往下看）

🌈 DeepSeek-R1 已发布并开源，性能对标 OpenAI o1 正式版，在网页端、APP 和 API 全面上线，[点击查看详情](#)。

deepseek

探索未至之境

开始对话

免费与 DeepSeek-V3 对话
使用全新旗舰模型

获取手机 App

DeepSeek 官方推出的免费 AI 助手
搜索写作阅读解题翻译工具



我是 DeepSeek，很高兴见到你！

我可以帮你写代码、读文件、写作各种创意内容，请把任务交给我吧~

给 DeepSeek 发送消息

 深度思考 (R1)

 联网搜索



3.领取API KEY，右上角



4.自行注册完，到了这个页面，可以看到10元余额API KEY，然后点击左侧导航的API KEYS进行生成

deepseek 开放平台

用量信息

API keys

充值

账单

接口文档

常见问题

产品定价

用量信息

【价格提示】

1. deepseek-chat 模型优惠期至北京时间 2025 年 2 月 8 日 24:00，期间 API 调用享历史价格，优惠结束后将按每百万输入 tokens 2 元，每百万输出 tokens 8 元计费。

2. deepseek-reasoner 模型上线即按每百万输入 tokens 4 元，每百万输出 tokens 16 元计费。

[查看价格详情](#)

知道了

所有日期均按 UTC 时间显示，数据可能有 5 分钟延迟。

充值余额

¥0.00 CNY

去充值

赠送余额 查看有效期

¥10.00 CNY

余额领完未开账 (去设置)

本月消费

¥0.00 CNY

每月用量

消费金额 ¥0.00

¥1

2025 - 2月 导出

我刚注册的API KEY

sk-ab9ab416bb174b41bc250f83ac20ba75

注意：

- deepseek-chat 模型已全面升级为 DeepSeek-V3，接口不变。通过指定 model='deepseek-chat' 即可调用 DeepSeek-V3。

3、调用本地化部署服务

1. 使用 ollama list 命令查看本地已安装的模型

`ollama list` 是一个非常简单的命令，用于列出本地已安装的所有模型。

```
C:\Users\Administrator>ollama list
NAME                ID                SIZE    MODIFIED
deepseek-r1:8b      28f8fd6cdc67     4.9 GB  9 hours ago

C:\Users\Administrator>
```

2. 使用 `ollama search` 命令搜索可用的模型

如果你想查找 Ollama 支持的所有模型（包括尚未下载的模型），可以使用 `ollama search` 命令。

3. 使用 `ollama pull` 命令查看支持的模型

Ollama 默认运行在 `http://localhost:11434`，以下是常用的 API 端点：

- `/api/generate`: 用于生成文本。
- `/api/chat/completions`: 用于对话式交互（类似于 OpenAI 的 ChatCompletion API）。
- `/api/models`: 用于获取模型列表。
- `/api/info`: 用于获取模型的详细信息。

①Java 调用

POST

http://localhost:11434/api/chat

http/1.1

发送

保存

Header

Query

Path

Body (1)

认证

Cookie

预执行操作

后执行操作

none

form-data

urlencoded

binary

msgpack

raw

json

自动生成

生成注解

可视化编辑

字段描述

美化

简化

1

```
{ "prompt": "你好,sjava!", "model": "deepseek-r1:8b" }
```

实时响应

请求头 (8)

响应头 (3)

Cookie

响应示例

实际请求

控制台

状态: 200 时间: 11:35:09 27ms 大小: 0.14kb

美化

原生

预览

可视化

UTF-8

1

```
{
```

2

```
  "model": "deepseek-r1:8b",
```

3

```
  "created_at": "2025-02-07T03:35:09.448103Z",
```

4

```
  "message": {
```

5

```
    "role": "assistant",
```

6

```
    "content": ""
```

7

```
  },
```

8

```
  "done_reason": "load",
```

9

```
  "done": true
```

10

```
}
```

2025/7/23 09:10

DeepSeek 部署及应用：保姆级别（本地部署、在线API调用，第三方插件调用）_deepseek本地部署api调用-CSDN博客

设计 调试 接口用例 一键压测 Mock 分享 新建接口

POST http://localhost:11434/api/generate http/1.1 发送 保存

Header Query Path Body (1) 认证 Cookie 预执行操作 后执行操作

none form-data urlencoded binary msgpack raw json

自动生成 生成注解 可视化编辑 字段描述 美化 简化

```
1 {
2   "prompt": "介绍一下deepseek",
3   "model": "deepseek-r1:8b",
4   "stream": false
5 }
```

实时响应 请求头 (8) 响应头 (3) Cookie 响应示例 实际请求 控制台 状态: 200 时间: 14:34:12 3.722s 大小: 0.78kb

美化 原生 预览 可视化 UTF-8

```
1 {
2   "model": "deepseek-r1:8b",
3   "created_at": "2025-02-07T06:34:16.5970114Z",
4   "response": "<think>\n\n</think>\n\n深度求索人工智能基础技术研究有限公司（简称“深度求索”或“DeepSeek”），成立于2023年，是一家专注于实现AGI的中国公司。",
5   "done": true,
6   "done_reason": "stop",
7   "context": [
8     128011,
9     117814,
10    111230,
11    33980,
12    26797,
13    128012,
14    128013,
15    271,
16    128014,
17    271,
18    102987,
19    27479,
20    32018,
21    52084
```

《断言与校验

POST

http://localhost:11434/api/chat

http/1.1

发送

保存

Header

Query

Path

Body (1)

认证

Cookie

预执行操作

后执行操作

none

form-data

urlencoded

binary

msgpack

raw

json

自动生成

AI

生成注解

可视化编辑

字段描述

美化

简化

1

{

2

"model": "deepseek-r1:8b",

3

"messages": [

4

{

5

"role": "user",

6

"content": "介绍一下 deepseek"

7

}

8

],

9

"temperature": 0.7,

10

"max_tokens": 500,

11

"stream": false

12

}

实时响应

请求头 (8)

响应头 (3)

Cookie

响应示例

实际

...

状态: 200

时间: 14:29:00

6.189s

大小: 0.50kb

美化

原生

预览

可视化

UTF-8

1

{

2

"model": "deepseek-r1:8b",

3

"created_at": "2025-02-07T06:29:06.4179836Z",

4

"message": {

5

"role": "assistant",

6

"content": "<think>\n\n</think>\n\n深度求索人工智能基础技术研究有限公司 (简称“深度求索”或“DeepSeek”),

7

"content": "成立于2023年,是一家专注于实现AGI的中国公司。"

8

},

9

"done_reason": "stop",

10

"done": true,

"total_duration": 6183068000,

断言与校

```
11     "load_duration": 2447584400,  
12     "prompt_eval_count": 7,  
13     "prompt_eval_duration": 292000000,  
14     "eval_count": 49,  
15     "eval_duration": 3441000000  
16 }
```

验



```
import com.fasterxml.jackson.databind.ObjectMapper;  
import okhttp3.OkHttpClient;  
import okhttp3.Request;  
import okhttp3.RequestBody;  
import okhttp3.Response;  
import okhttp3.WebSocket;  
import okhttp3.WebSocketListener;  
import okio.ByteString;  
  
import java.io.IOException;  
import java.util.concurrent.CompletableFuture;  
import java.util.concurrent.ExecutionException;  
  
public class OllamaStreamingClient {  
    private static final String OLLAMA_API_URL = "http://localhost:11434/api/generate";  
    private OkHttpClient client = new OkHttpClient();  
    private ObjectMapper objectMapper = new ObjectMapper();  
  
    public CompletableFuture<String> generateText(String model, String prompt) {  
        CompletableFuture<String> future = new CompletableFuture<>();  
        Request request = new Request.Builder()  
            .url(OLLAMA_API_URL)  
            .post(RequestBody.create("{\n" +  
                "  \"model\": \"" + model + "\",\n" +  
                "  \"messages\": [\n" +
```

```
"    {"role\": \"user\", \"content\": \"\" + prompt + \"\"}\n" +  
" ],\n" +  
"  \"temperature\": 0.7,\n" +  
"  \"max_tokens\": 500,\n" +  
"  \"stream\": true\n" +  
"}"))  
.build();
```

```
client.newWebSocket(request, new WebSocketListener() {  
    private StringBuilder responseBuilder = new StringBuilder();  
  
    @Override  
    public void onOpen(WebSocket websocket, Response response) {  
        websocket.send(ByteString.encodeUtf8(prompt));  
    }  
  
    @Override  
    public void onMessage(WebSocket websocket, ByteString bytes) {  
        String chunk = bytes.utf8();  
        try {  
            // 解析 JSON 块  
            JsonNode node = objectMapper.readTree(chunk);  
            String content = node.get("message").get("content").asText();  
            responseBuilder.append(content);  
        } catch (Exception e) {  
            e.printStackTrace();  
        }  
    }  
}  
  
@Override  
public void onClose(WebSocket websocket, int code, String reason) {  
    future.complete(responseBuilder.toString());  
}
```

```
    }

    @Override
    public void onFailure(WebSocket websocket, Throwable t, Response response) {
        future.completeExceptionally(t);
    }
});

return future;
}

public static void main(String[] args) {
    try {
        OllamaStreamingClient client = new OllamaStreamingClient();
        String model = "deepseek-r1:8b";
        String prompt = "介绍一下 deepseek";
        String response = client.generateText(model, prompt).get();
        System.out.println("Final Response: " + response);
    } catch (InterruptedException | ExecutionException e) {
        e.printStackTrace();
    }
}
}
```

deepseek帮助文档：[对话补全 | DeepSeek API Docs](#)

调用官方在线API

```
OkHttpClient client = new OkHttpClient().newBuilder()
    .build();
```

```
MediaType mediaType = MediaType.parse("application/json");
RequestBody body = RequestBody.create(mediaType, "{\n  \"messages\": [\n    {\n      \"content\": \"You are a helpful assistant\", \"role\": \"assistant\"
Request request = new Request.Builder()
    .url("https://api.deepseek.com/chat/completions")
    .method("POST", body)
    .addHeader("Content-Type", "application/json")
    .addHeader("Accept", "application/json")
    .addHeader("Authorization", "Bearer <TOKEN>")
    .build();
Response response = client.newCall(request).execute();
```

POST

https://api.deepseek.com/chat/completions

http/1.1

发送

保存

Header (3)

Query

Path

Body (1)

认证

Cookie

预执行操作

后执行操作

none

form-data

urlencoded

binary

msgpack

raw

json

自动生成

AI 生成注解

可视化编辑

字段描述

美化

```
1 {
2   "messages": [
3     {
4       "content": "You are a helpful assistant",
5       "role": "system"
6     },
7     {
8       "content": "您好今天天气怎么样",
9       "role": "user"
10    }
11  ],
12  "model": "deepseek-chat",
13  "frequency_penalty": 0,
14  ...
15 }
```

实时响应

请求头 (9)

响应头 (12)

Cookie (2)

响应示例

实际请求

控制台

美化

原生

预览

可视化

UTF-8


```
1 {
2   "id": "a63b22d4-2618-47c6-acee-8d8a15c701a4",
3   "object": "chat.completion",
4   "created": 1738907243,
5   "model": "deepseek-chat",
6   "choices": [
7     {
8       "index": 0,
9       "message": {
10        "role": "assistant",
11        "content": "您好，我无法实时获取天气信息。建议您查看当地的天气预报应用或网站，以获取最新的天气情况。如果您告诉我您所在的城市或地区，我可以提供一些一般性的天气建议或信息。"
12      },
13      "logprobs": null,
14      "finish_reason": "stop"
15    }
16  ],
17   "usage": {
18     "prompt_tokens": 12,
19     "completion_tokens": 42,
20     "total_tokens": 54,
21     "prompt_tokens_details": {
22       "cached_tokens": 0
23     }
24   }
25 }
```

②Vue 调用

```
import axios from "axios";

export async function callDeepSeek(prompt) {
  const response = await axios.post("http://127.0.0.1:8000/chat", { prompt });
  return response.data.response;
}
```

4、命令窗口操作



```
Microsoft Windows [版本 10.0.22631.4751]
(c) Microsoft Corporation. 保留所有权利。

C:\Users\Administrator>ollama run deepseek-r1:8b
>>> 早上好
<think>

</think>

早上好！希望你今天有美好的开始。有什么我可以帮你的吗？

>>> | Send a message (/? for help)
```

5、第三方开源客户端、页面调用

①使用Open Web UI

为了更直观地与DeepSeek模型进行交互，可以使用Open Web UI。以下是安装和使用步骤：

安装Docker：确保你的机器上已安装Docker。

1. 访问 [Docker官网](#) ([Docker: Accelerated Container Application Development](#)) 下载Docker Desktop
2. 完成安装并启动Docker
3. 确保Docker服务正常运行，建议使用 `docker info` 命令检查

启动docekr

windows：



linux启动docker

Ubuntu：

```
sudo systemctl start docker
```

```
sudo systemctl status docker
```

CentOS

```
docker run -it centos /bin/bash
```

Open WebUI 会自动关联 `ollama` 已安装模型不需要额外设置。


官网推荐如下几种安装方式：

- - Docker：官方支持，建议大多数用户使用。
- - Python：适用于资源有限的环境，或适用于希望手动设置的用户。
- - Kubernetes：对于需要进行扩展和编排的企业级部署而言是理想之选。


a.python为载体安装

安装python


前往官网下载 python <https://www.python.org/downloads/windows/> 需要使用 3.11 以上的版本，笔者使用的是 3.11.9。




安装 python，步骤 2环境变量很重要记得勾选。



如下图所示 python 安装完成，如果报错，请卸载后再安装（操作最简单），记得勾如上步骤 2 环境变量。






使用**虚拟环境**安装 Open WebUI:


使用虚拟环境是为了方便日后管理。


笔者虚拟环境放在 F 盘（盘符随意，建议使用固态硬盘），创建了一个名为 LLM 文件夹。




知乎 @瞿同学(Darren)

进入 LLM 文件夹 `cd F:\LLM\` F 替换成你的盘符





使用如下命令创建虚拟环境 `python -m venv venv`



The screenshot shows a Windows PowerShell terminal window with two tabs. The active tab displays the following text:

```
Windows PowerShell
Copyright (C) Microsoft Corporation. All rights reserved.

Install the latest PowerShell for new features and improvements! https://aka.ms/PSWindows

PS C:\Users\quzq> cd F:\LLMs
PS F:\LLMs>
PS F:\LLMs>
PS F:\LLMs> python -m venv venv
PS F:\LLMs>
```

The command `python -m venv venv` is highlighted with a red rectangle.

知乎 @瞿同学(Darren)

激活虚拟环境 `venv\Scripts\activate` 如下图所示虚拟环境进入成功。

知乎 @瞿同学(Darren)

通过 pip 安装 Open WebUI `pip install open-webui`，需要安装插件较多，需要花费一些时间。

知乎 @瞿同学(Darren)

安装完成后如下所示

```
haviour change. A possible replacement is to enable the '--use-pep517' option. Discussion can be found at https://github.com/pypa/pip/issues/8559
Running setup.py install for compressed-rtf ... done
Attempting uninstall: setuptools
Found existing installation: setuptools 65.5.0
Uninstalling setuptools-65.5.0:
Successfully uninstalled setuptools-65.5.0
DEPRECATION: langdetect is being installed using the legacy 'setup.py install' method, because it does not have a 'pyproject.toml' and the 'wheel' package is not installed. pip 23.1 will enforce this behavi
our change. A possible replacement is to enable the '--use-pep517' option. Discussion can be found at https://github.com/pypa/pip/issues/8559
Running setup.py install for langdetect ... done
Successfully installed aiohttp-3.9.1 aiohttp-fs-0.8.0 aiohttp-jinja2-0.12.0 aiohttp-multipart-0.8.0 aiohttp-sse-client-0.1.0 aiohttp-zlib-ng-0.2.0 aiosignal-1.3.2 alembic-1.14.0 annotated-types-0.7.0 anthropic-0.45.2 anyio-4.8.0 appdirs-1.4.4 apscheduler-3.10.4 argon2-cffi-23.1.0 argon2-cffi-bindings-21.2.0 asgiref-3.8.1 async-timeout-5.0.1 att
rs-25.1.0 authlib-1.3.2 av-12.3.0 backoff-2.2.1 bcrypt-4.2.0 beautifulsoup4-4.12.3 bidict-0.23.1 bitarray-3.0.0 black-24.8.0 blinker-1.9.0 boto3-1.35.53 botocore-1.35.99 build-1.2.2.post1 cachetools-5.5.1 cer
tifi-2025.1.31 cffi-1.17.1 chardet-5.2.0 charset-normalizer-3.4.1 chroma-hnswlib-0.7.6 chromadb-0.6.2 click-8.1.8 colbert-ai-0.2.21 colorama-0.4.6 colorclass-2.2.2 coloredlogs-15.0.1 compressed-rtf-1.0.6 cryp
tography-44.0.0 ctranslate2-4.5.0 dataclasses-json-0.6.7 datasets-3.2.0 defusedxml-0.7.1 deprecated-1.2.18 dill-0.3.8 distro-1.9.0 dnspython-2.7.0 docker-7.1.0 docx2txt-0.8 duckduckgo-search-7.2.1 durationpy-
0.9 easygui-0.98.3 ebcidic-1.1.1 ecdsa-0.19.0 einops-0.8.0 email-validator-2.2.0 emoji-2.14.1 et-xmlfile-2.0.0 eval-type-backport-0.2.2 extract-msg-0.52.0 fake-useragent-1.5.1 fastapi-0.111.0 fastapi-cli-0.0.7
faster-whisper-1.0.3 filelock-3.17.0 filetype-1.2.0 flask-3.1.0 flask-cors-5.0.0 flatbuffers-25.1.24 fonttools-4.55.8 fpdf2-2.8.2 frozenlist-1.5.0 fs-2.4.16 fsspec-2024.9.0 ftfy-6.2.3 gcp-storage-emulator-20
24.8.3 git-python-1.0.3 gitdb-4.0.12 gitpython-3.1.44 google-ai-generativelanguage-0.6.6 google-api-core-2.24.1 google-api-python-client-2.160.0 google-auth-2.38.0 google-auth-httplib2-0.2.0 google-auth-oauth
lib-1.2.1 google-cloud-core-2.4.1 google-cloud-storage-2.19.0 google-crc32c-1.6.0 google-generativeai-0.7.2 google-resumable-media-2.7.2 googleapis-common-protos-1.63.2 greenlet-3.1.1 grpcio-1.67.1 grpcio-sta
tus-1.62.3 grpcio-tools-1.62.3 h11-0.14.0 h2-4.2.0 hpack-4.1.0 httpcore-1.0.7 httplib2-0.22.0 httptools-0.6.4 https-0.28.1 httpx-sse-0.4.0 huggingface-hub-0.28.1 humanfriendly-10.0 hyperframe-6.1.0 idna-3.10
importlib-metadata-8.4.0 importlib-resources-6.5.2 iniconfig-2.0.0 itsdangerous-2.2.0 jinja2-3.1.5 jiter-0.8.2 jmespath-1.0.1 joblib-1.4.2 jsonpatch-1.33 jsonpath-python-1.0.6 jsonpointer-3.0.0 kubernetes-32
.0.0 langchain-0.3.7 langchain-community-0.3.7 langchain-core-0.3.33 langchain-text-splitters-0.3.5 langdetect-1.0.9 langfuse-2.44.0 langsmith-0.1.147 lark-1.1.9 ldap3-2.9.1 lxml-5.3.0 markdown-3.7 markdown-it
-py-3.0.0 marshmallow-3.26.1 mdurl-0.1.2 mmh3-5.1.0 monotonic-1.6 moto-5.0.28 mpmath-1.3.0 msoffcrypto-tool-5.4.2 multidict-6.1.0 multiprocessing-0.70.16 mpyy-extensions-1.0.0 nest-asyncio-1.6.0 networkx-3.4.2 n
inja-1.11.1.3 nltk-3.9.1 numpy-1.26.4 oauthlib-3.2.2 olefile-0.47 oledtools-0.60.2 onnxruntime-1.20.1 open-webui-0.5.7 openai-1.61.0 opencv-python-4.11.0.86 opencv-python-headless-4.10.0.84 openpyxl-3.1.5 open
search-py-2.7.1 opentelemetry-api-1.27.0 opentelemetry-exporter-otlp-proto-common-1.27.0 opentelemetry-exporter-otlp-proto-grpc-1.27.0 opentelemetry-instrumentation-0.48b0 opentelemetry-instrumentation-asgi-0
.48b0 opentelemetry-instrumentation-fastapi-0.48b0 opentelemetry-proto-1.27.0 opentelemetry-sdk-1.27.0 opentelemetry-semantic-conventions-0.48b0 opentelemetry-util-http-0.48b0 orjson-3.10.15 overrides-7.7.0 p
ackaging-23.2 pandas-2.2.3 passlib-1.7.4 pathspec-0.12.1 pcodedmp-1.2.6 peewee-3.17.8 peewee-migrate-1.12.2 pyvector-0.3.5 platformdirs-4.3.6 pluggy-1.5.0 portalocker-2.10.1 posthog-3.11.0 primp-0.11.0 propca
che-0.2.1 proto-plus-1.26.0 protobuf-4.25.6 psutil-6.1.1 pycocot-binary-2.9.9 py-partiql-parser-0.6.1 pyarrow-19.0.0 pyasn1-0.6.1 pyasn1-modules-0.4.1 pyclicker-1.3.0.post6 pycparser-2.22 pydantic-2.9.2 pyda
ntic-core-2.23.4 pydantic-settings-2.7.1 pydub-0.25.1 pygments-2.19.1 pyjwt-2.10.1 pymdown-extensions-10.11.2 pymilvus-2.5.0 pymongo-4.11 pymysql-1.1.1 pyppandoc-1.13 pyparsing-3.2.1 pypdf-4.3.1 pypika-0.48.9
pyproject_hooks-1.2.0 pyreadline3-3.5.4 pytest-8.3.4 pytest-docker-3.1.2 python-dateutil-2.9.0.post0 python-dotenv-1.0.1 python-engineio-4.11.2 python-iso639-2025.1.28 python-jose-3.3.0 python-magic-0.4.27 py
thon-multipart-0.0.18 python-oxmsg-0.0.2 python-pptx-1.0.0 python-socketio-5.11.3 pytube-15.0.0 pytz-2025.1 pywin32-308 pyxlsb-1.0.10 qdrant-client-1.12.2 rank-bm25-0.2.2 rapidfuzz-3.12.1 rapidocr-onnxruntime
-1.3.24 red-black-tree-mod-1.20 redis-5.2.1 regex-2024.11.6 requests-2.32.3 requests-oauthlib-2.0.0 requests-toolbelt-1.0.0 responses-0.25.6 rich-13.7.1 rich-click-1.10.0 safetensors-0.10.4 safetenso
rs-0.5.2 scikit-learn-1.6.1 scipy-1.15.1 sentence-transformers-3.3.1 sentencepiece-0.2.0 setuptools-75.8.0 shellingham-1.5.4 simple-websocket-1.0.17.1 simple-websocket-client-1.0.17.1 simple-websocket-server-1.0.17.1
simplipy-0.1.0 six-1.17.0 sqlalchemy-2.0.35 sqlalch-2.0.35 starlette-0.37.2 sympy-1.13.1 tabulate-0.9.0 tenacity-9.0.0 threadpoolctl-3.5.0 tiktoken-0.8.0 tokenizers-0.21.0 tomli-2.0.1 tomlkit-0.12.0 transformers-4.48.0 typer-0.15.1 typing-exten
sions-4.12.2 typing-inspect-0.9.0 tzdata-2025.1 tzlocal-5.2 ujson-5.10.0 unstructured-0.15.9 unstructured-client-0.28.1 writemplate-4.1.1 urllib3-2.3.0 uvicorn-0.30.6 validators-0.34.0 watchfiles-1.0.4 wcwidt
h-0.2.13 websocket-client-1.8.0 websockets-14.2 win-unicode-console-0.5 wrapt-1.17.2 wsproto-1.2.0 xlrd-2.0.1 xmltodict-0.14.2 xxhash-3.5.0 yarl-1.18.3 youtube-transcript-api-0.6.3 zipp-3.21.0
```

启动 Open WebUI

通过 `open-webui serve` 命令启动，该命令启动后需要让 powershell 一直运行不能关闭，首次启动需要加载相关插件需要等待一下，如果报错请检查 8080 端口是否被禁用。

```
(venv) PS F:\LLM> python open_webui.py
Loading WEBUI_SECRET_KEY from file, not provided as an environment variable.
Generating a new secret key and saving it to F:\LLM\webui_secret_key
Loading WEBUI_SECRET_KEY from F:\LLM\webui_secret_key
F:\LLM\venv\Lib\site-packages\open_webui
F:\LLM\venv\Lib\site-packages
F:\LLM\venv\Lib
Running migrations
INFO [alembic.runtime.migration] Context impl SQLiteImpl.
INFO [alembic.runtime.migration] Will assume non-transactional DDL.
INFO [alembic.runtime.migration] Running upgrade -> 7e5b5dc7342b, init
INFO [alembic.runtime.migration] Running upgrade 7e5b5dc7342b -> ca81bd47c050, Add config table
INFO [alembic.runtime.migration] Running upgrade ca81bd47c050 -> c0fbf31ca0db, Update file table
INFO [alembic.runtime.migration] Running upgrade c0fbf31ca0db -> 6a39f3d8e55c, Add knowledge table
Creating knowledge table
Migrating data from document table to knowledge table
INFO [alembic.runtime.migration] Running upgrade 6a39f3d8e55c -> 242a2047eae0, Update chat table
Converting 'chat' column to JSON
Renaming 'chat' column to 'old_chat'
Adding new 'chat' column of type JSON
Dropping 'old_chat' column
INFO [alembic.runtime.migration] Running upgrade 242a2047eae0 -> 1af9b942657b, Migrate tags
INFO [alembic.runtime.migration] Running upgrade 1af9b942657b -> 3ab32c4b8f59, Update tags
Primary Key: {'name': None, 'constrained_columns': []}
Unique Constraints: [{'name': 'uq_id_user_id', 'column_names': ['id', 'user_id']}]
Indexes: [{'name': 'tag_id', 'column_names': ['id'], 'unique': 1, 'dialect_options': {}}]
Creating new primary key with 'id' and 'user_id'.
Dropping unique constraint: uq_id_user_id
Dropping unique index: tag_id
INFO [alembic.runtime.migration] Running upgrade 3ab32c4b8f59 -> c69f45358db4, Add folder table
INFO [alembic.runtime.migration] Running upgrade c69f45358db4 -> c29facfe716b, Update file table path
INFO [alembic.runtime.migration] Running upgrade c29facfe716b -> af906e964978, Add feedback table
INFO [alembic.runtime.migration] Running upgrade af906e964978 -> 4ace53fd72c8, Update folder table and change DateTime to BigInteger for timestamp fields
INFO [alembic.runtime.migration] Running upgrade 4ace53fd72c8 -> 922e7a387820, Add group table
INFO [alembic.runtime.migration] Running upgrade 922e7a387820 -> 57c599a3cb57, Add channel table
INFO [alembic.runtime.migration] Running upgrade 57c599a3cb57 -> 7826ab40b532, Update file table
INFO [alembic.runtime.migration] Running upgrade 7826ab40b532 -> 3781e22d8b01, Update message & channel tables
INFO [open_webui.env] 'DEFAULT_LOCALE' loaded from the latest database entry
INFO [open_webui.env] 'DEFAULT_PROMPT_SUGGESTIONS' loaded from the latest database entry
WARNI [open_webui.env]

WARNING: CORS_ALLOW_ORIGIN IS SET TO '*' - NOT RECOMMENDED FOR PRODUCTION DEPLOYMENTS.

INFO [open_webui.env] Embedding model set: sentence-transformers/all-MiniLM-L6-v2
WARNI [langchain_community.utils.user_agent] USER_AGENT environment variable not set, consider setting it to identify your requests.
```

Open WebUI

v0.5.7 - building the best open-source AI user interface.

<https://github.com/open-webui/open-webui>


```
I_Pooling/config.json: 100%|██████████| 190/190 [00:00<?, ?B/s]
README.md: 100%|██████████| 10.7k/10.7k [00:00<00:00, 10.6MB/s]
config_sentence_transformers.json: 100%|██████████| 116/116 [00:00<?, ?B/s]
F:\LLM\venv\Lib\site-packages\huggingface_hub\file_download.py:140: UserWarning: `huggingface_hub` cache-system uses symlinks by default to efficiently store duplicated files but your machine does not support them in C:\Users\quzq\.cache\huggingface\hub\models--sentence-transformers--all-MiniLM-L6-v2. Caching files will still work but in a degraded version that might require more space on your disk. This warning can be disabled by setting the `HF_HUB_DISABLE_SYMLINKS_WARNING` environment variable. For more details, see https://huggingface.co/docs/huggingface_hub/how-to-cache#limitations. To support symlinks on Windows, you either need to activate Developer Mode or to run Python as an administrator. In order to activate developer mode, see this article: https://docs.microsoft.com/en-us/windows/apps/get-started/enable-your-device-for-development
warnings.warn(message)
modules.json: 100%|██████████| 349/349 [00:00<?, ?B/s]
.gitattributes: 100%|██████████| 1.23k/1.23k [00:00<?, ?B/s]
```

```
Fetching 30 files: 7%|
data_config.json: 100%|
config.json: 100%|
model_03.onnx: 100%|
model.safetensors: 100%|
model.onnx: 100%|
model_04.onnx: 100%|
model_01.onnx: 100%|
model_02.onnx: 100%|
ERROR [open_webui.retrieval.utils] Cannot determine model snapshot path: [WinError 1314] A required privilege is not held by the client: '..\\..\\blobs\\8cfec92309f5626a223304af2423e332f6d31887' -> 'C:\\Users\\quzq\\.cache\\huggingface\\hub\\models--sentence-transformers--all-MiniLM-L6-v2\\snapshots\\fa97f6e7cbl59073dff9e6b13e2715cf7475ac9\\README.md'
Traceback (most recent call last):
  File "F:\\LLM\\venv\\Lib\\site-packages\\open_webui\\retrieval\\utils.py", line 417, in get_model_path
    model_repo_path = snapshot_download(**snapshot_kwargs)
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "F:\\LLM\\venv\\Lib\\site-packages\\huggingface_hub\\utils\\validators.py", line 114, in _inner_fn
    return fn(*args, **kwargs)
    ^^^^^^^^^^^^^^^^^^^^^^^^^
  File "F:\\LLM\\venv\\Lib\\site-packages\\huggingface_hub\\snapshot_download.py", line 296, in snapshot_download
    thread_map(
  File "F:\\LLM\\venv\\Lib\\site-packages\\tqdm\\contrib\\concurrent.py", line 69, in thread_map
    return _executor_map(ThreadPoolExecutor, fn, *iterables, **tqdm_kwargs)
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "F:\\LLM\\venv\\Lib\\site-packages\\tqdm\\contrib\\concurrent.py", line 51, in _executor_map
    return list(tqdm_class(ex.map(fn, *iterables, chunksize=chunksize), **kwargs))
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "F:\\LLM\\venv\\Lib\\site-packages\\tqdm\\std.py", line 1181, in __iter__
    for obj in iterable:
  File "C:\\Users\\quzq\\AppData\\Local\\Programs\\Python\\Python311\\Lib\\concurrent\\futures\\_base.py", line 619, in result_iterator
    yield _result_or_cancel(fs.pop())
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "C:\\Users\\quzq\\AppData\\Local\\Programs\\Python\\Python311\\Lib\\concurrent\\futures\\_base.py", line 317, in _result_or_cancel
    return fut.result(timeout)
    ^^^^^^^^^^^^^^^^^^^^^^^^^
  File "C:\\Users\\quzq\\AppData\\Local\\Programs\\Python\\Python311\\Lib\\concurrent\\futures\\_base.py", line 449, in result
    return self.__get_result()
    ^^^^^^^^^^^^^^^^^^^^^^^^^
  File "C:\\Users\\quzq\\AppData\\Local\\Programs\\Python\\Python311\\Lib\\concurrent\\futures\\_base.py", line 401, in __get_result
    raise self._exception
  File "C:\\Users\\quzq\\AppData\\Local\\Programs\\Python\\Python311\\Lib\\concurrent\\futures\\thread.py", line 58, in run
    result = self.fn(*self.args, **self.kwargs)
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "F:\\LLM\\venv\\Lib\\site-packages\\huggingface_hub\\snapshot_download.py", line 270, in _inner_hf_hub_download
    return hf_hub_download(
    ^^^^^^^^^^^^^^^^^^^^^
  File "F:\\LLM\\venv\\Lib\\site-packages\\huggingface_hub\\utils\\validators.py", line 114, in _inner_fn
    return fn(*args, **kwargs)
    ^^^^^^^^^^^^^^^^^^^^^^^^^
  File "F:\\LLM\\venv\\Lib\\site-packages\\huggingface_hub\\file_download.py", line 860, in hf_hub_download
    return _hf_hub_download_to_cache_dir(
    ^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
  File "F:\\LLM\\venv\\Lib\\site-packages\\huggingface_hub\\file_download.py", line 1020, in _hf_hub_download_to_cache_dir
    _create_symlink(blob_path, pointer_path, new_blob=True)
  File "F:\\LLM\\venv\\Lib\\site-packages\\huggingface_hub\\file_download.py", line 584, in _create_symlink
    os.symlink(src_rel_or_abs, abs_dst)
OSError: [WinError 1314] A required privilege is not held by the client: '..\\..\\blobs\\8cfec92309f5626a223304af2423e332f6d31887' -> 'C:\\Users\\quzq\\.cache\\huggingface\\hub\\models--sentence-transformers--all-MiniLM-L6-v2\\snapshots\\fa97f6e7cbl59073dff9e6b13e2715cf7475ac9\\README.md'
sentence_bert_config.json: 100%|
tokenizer_config.json: 100%|
vocab.txt: 100%|
tokenizer.json: 100%|
special_tokens_map.json: 100%|
INFO: Started server process [24488]
INFO: Waiting for application startup.
INFO: Application startup complete.
INFO: Uvicorn running on http://0.0.0.0:8080 (Press CTRL+C to quit)
INFO: 127.0.0.1:44595 - "GET / HTTP/1.1" 200 OK
INFO: 127.0.0.1:44595 - "GET /_app/immutable/entry/start.BlibnFLA.js HTTP/1.1" 200 OK
INFO: 127.0.0.1:44596 - "GET /_app/immutable/chunks/entry.B71ECrEP.js HTTP/1.1" 200 OK
```

知乎 @瞿同学(Darren)

使用 Open WebUI

访问 <http://localhost:8080> 点击开始使用



创建管理员账户信息。

开始使用 Open WebUI

① Open WebUI 不会与外部建立任何连接，您的数据会安全地存储在本地托管的服务器上。

名称

Darren

电子邮箱


ql[REDACTED]@gmail.com

密码


.....

创建管理员账号

确认版本信息开始使用



此处显示正在使用的模型，多个模型可以切换使用。



运行 Open WebUI

在 PowerShell 使用快速启动 `F:\LLM\venv\Scripts\python.exe F:\LLM\venv\Scripts\open-webui.exe serve`
(`F:\LLM\venv\Scripts\` 替换成你的文件路径) , 启动后不能关闭窗口。

恢复操作

如果你忘记的了管理员密码可在参考官方文档 <https://docs.openwebui.com/troubleshooting/password-reset> 。
恢复初始配置可以删除 DB 文件，文件目录为 `F:\LLM\venv\Lib\site-packages\open_webui\data.db` 此操作需要谨慎，会删除所
以得账户和聊天记录，忘记密码也可以使用釜底抽薪。

b.docker为载体

三  README

以下内容由 AI 翻译，如有问题请点击[提交 issue 反馈](#)  [查看原文](#)  [自动翻译](#)

开放式WebUI（原名Ollama WebUI）

Stars69k

Forks8.2k

Watchers329

repo size163.6 MiB

languages11

javascript42.4%

last commitlast wednesday

hits18797 / 9624627

Discord

Open WebUI

赞助

开放式WebUI是一款可扩展的、功能丰富的用户友好型自托管Web界面，旨在完全离线运行。它支持包括Ollama和与OpenAI兼容的API在内的多种LLM运行器。欲了解更多信息，请查阅我们的[开放式WebUI文档](#)。

New Chat

Workspace

Search

OpenAI / GPT 4 +

🔍 llama3

pulling manifest

No results found

Downloading "llama3"



OpenAI / GPT 4

How can I help you today?

Suggested

Help me study
vocabulary for a college entrance
exam

Give me ideas
for what to do with my kids' art

Overcome procrastination
give me tips

Tell me a fun fact
about the Roman Empire

file:///C:/Users/Administrator/Downloads/DeepSeek+部署及应用：保姆级别（本地部署、在线API调用，第三方插件调用）.html

47/114

```
C:\Users\Administrator>docker run -d -p 3000:8080 -e OLLAMA_BASE_URL=https://yourserverurl -v open-webui:/app/backend/data --name open-webui --restart always ghcr.io/open-webui/open-webui:main
Unable to find image 'ghcr.io/open-webui/open-webui:main' locally
main: Pulling from open-webui/open-webui
c29f5b76f736: Pull complete
73c4bbda278d: Pull complete
acc53c3e87ac: Pull complete
ad3b14759e4f: Pull complete
b874b4974f13: Pull complete
4f4fb700ef54: Pull complete
dfcf69fcbc2b: Pull complete
e8bfaf4ee0e0: Pull complete
17b8c991f4f9: Downloading 8.098MB/323.2MB
cac7b012c1cf: Download complete
19163ec7da38: Downloading 9.179MB/982MB
2d09bb3f2f68: Download complete
fc4e66cac1ed: Download complete
2ef6555085fd: Download complete
9ab170b77d23: Download complete
```

在终端运行以下命令安装并启动Open Web UI：


```
docker run -d -p 3000:8080 \
--add-host=host.docker.internal:host-gateway \
-v open-webui:/app/backend/data \
--name open-webui \
--restart always \
```

ghcr.io/open-webui/open-webui:main


等候指令完成，安装完成后，系统会增加一个openwebui图标；

打开本地项目

1.打开openwebui应用，进入项目选择界面，你会看到一个项目管理页面，上面有一个可以点击的地址，默认为：
http://localhost:3000/




- 2.点击地址、跳转至登陆注册页面，此处的登录注册是创建管理员账号，可以根据自己的习惯进行输入；
- 3.完成后会进入因为项目启动需要一点时间，刚开始页面会是一篇空白，稍等一下就行，结束后会看到这样一个界面。



拉取deep seek模型

1.通过页面左下角的角色入口，进入管理员身份，会有一个模型管理页面，在模型页面可以实现各类模型加载。



2.在模型管理页面，输入模型拉取的指令名称；

模型指令

1.5b: ollama run deepseek-r1:1.5b


7b:ollama run deepseek-r1:7b

8b:ollama run deepseek-r1:8b

14b:ollama run deepseek-r1:14b

一般来说，1.5b的运行速度比较快，也不卡,如果追求极致性能，可以尝试下7b及以上的。

3.模型安装成功后，在选择对话框处就可以看到选择对话模型。这样你的私人Ai助理就完成了。



安装完成后，访问 <http://localhost:3000>，选择deepseek-r1:latest模型即可开始使用。

②可视化图文交互界面 Chatbox

点击 [Chatbox AI官网：办公学习的AI好助手，全平台AI客户端，官方免费下载](#) 进入 Chatbox 官网，Chatbox 虽然有本地客户端，

进入 Chatbox 网页版本后点击使用自己的 [API Key](#) 或本地模型。



Chatbox AI

[首页](#)
[下载](#)
[定价](#)
[帮助](#)

 Stars
  26k

 中文

Chatbox AI, 办公学习好助手

Chatbox AI 是一款 AI 客户端应用和智能助手，支持众多先进的 AI 模型和 API，可在 Windows、MacOS、Android、iOS、Linux 和网页版上使用。

免费下载 (for Windows)

启动网页版


获取移动版

iOS

Android

APK


+ 更多选项




★★★★★

Join 500000+ happy users


 什么值得买



点击后会进入模型提供方选择界面，这里选择 Ollama API 。



这里需要注意的是，为了能够 Ollama 能[远程链接](#)，这里我们最好看一下 Chatbox 提供的教程，根据这个教程操作一下。



这个教程还是非常简单的，如果是 Windows 操作系统则只需要配置一下环境变量即可，配置完环境变量后需重启一下 Ollama 程序。

在 MacOS 上配置

1. 打开命令行终端，输入以下命令：

```
launchctl setenv OLLAMA_HOST "0.0.0.0"
launchctl setenv OLLAMA_ORIGINS "*"

```

2. 重启 Ollama 应用，使配置生效。

在 Windows 上配置

在 Windows 上，Ollama 会继承你的用户和系统环境变量。


- 1. 通过任务栏退出 Ollama。
- 2. 打开设置（Windows 11）或控制面板（Windows 10），并搜索“环境变量”。
- 3. 点击编辑你账户的环境变量。

为你的用户账户编辑或创建新的变量 **OLLAMA_HOST**，值为 **0.0.0.0**；为你的用户账户编辑或创建新的变量 **OLLAMA_ORIGINS**，值为 *****。

- 4. 点击确定/应用以保存设置。
- 5. 从 Windows 开始菜单启动 Ollama 应用程序。

在 Linux 上配置


如果 Ollama 作为 systemd 服务运行，应使用 systemctl 设置环境变量：




重启 Ollama 程序后，我们需要将 Chatbox 设置界面关闭并重新打开，重新打开 Chatbox 设置界面后即可选择 Deepseek 模型了，选择后 Deepseek 模型后点击保存即可。



接下来只需要在 Chatbox 中新建对话即可使用 Deepseek 模型了，以下图为例，上方是它的思考过程，下方是它给出的答案。




Chatbox 可视化图文交互界面还有一个特点就是可以创建专属智能体，只需点击我的搭档即可创建，此功能是 Deepseek 官方暂时还没有的功能。



基于本地的deepseek搭建个人知识库。使用本地服务,安装嵌入模型,用于将文本数据转换为向量标识的模型。

```
pulling daec91ffb5dd... 100% ██████████ 1.2 GB
```


根据自己的环境下载cherry studio




安装的时候，注意安装到其他磁盘，不要在c盘安装。

本地模型知识库

配置本地ollama





操作步骤：

- 1. 找到左下角设置图标
- 2. 选择模型服务
- 3. 选择ollama

4. 点击管理
5. 点击模型后面的加号（会自动查找到本地安装的模型）
6. 减号表示已经选择了

知识库配置



1. **选择知识库**
2. **选择添加**
3. **选择嵌入模型**
4. **填写知识库名称**

添加知识文档

cherry可以添加文档，也可以**添加目录（这个极其方便）**，添加完以后出现绿色的对号，表示向量化完成。

local

+ 添加

文件

+ 添加文件

拖拽文件到这里

支持 pdf, docx, pptx, xlsx, txt, md 格式

04、小红书的搜索排名机制.md

1

3

2

目录

+ 添加目录

C:\Users\yxxong\Downloads\xhs

网址

+ 添加网址

网站

+ 站点地图

笔记

+ 添加笔记

模型信息

bge-m3:latest

1024 维

Ollama

搜索知识库

公众号 · 5ycode

搜索验证




1. 点击搜索知识库

2. 输入搜索顺序

3. 点击搜索 大家可以看下我搜索的内容和并没有完全匹配，不过已经和意境关联上了。

大模型处理



1. 点击左上角的聊天图标
2. 点击助手
3. 点击默认助手（你也可以添加助手）
4. 选择大模型
5. 选择本地deepseek，也可以选择自己已经开通的在线服务
6. 设置知识库（不设置不会参考）
7. 输入提问内容
8. 发问



大家可以看到deepseek已经把结果整理了，并告诉了我们参考了哪些资料。


满血版

差别就是大模型的选择，在模型服务里配置下在线的deepseek服务即可。

如果你的知识库有隐私数据，不要联网！


④基于AnythingLLM搭建（AnythingLLM 的体验没有cherry好。AnythingLLM就像一个包壳的web应用。AnythingLLM 得具备一定的程序思维，给技术人员用的）

下载AnythingLLM Desktop



下载以后，安装的时候，注意安装到其他磁盘，不要在c盘安装。

AnythingLLM 配置

 AnythingLLM | Your personal LLM trained on anything

点击左下角的设置

Anything LLM

设置

人工智能提供商

LLM 首选项

向量数据库

Embedder 首选项

文本分割

语音和讲话

转录模型

管理员

代理技能

Community Hub

Explore Trending

Your Account

Import Item

LLM 首选项

这些是您首选的 LLM 聊天和嵌入提供商的凭据和设置。重要的是，这些密钥是最新的和正确的，否则 AnythingLLM 将无法正常运行。

LLM 提供商

Ollama

Run LLMs locally on your own machine.

Ollama Model

deepseek-r1:32b

Choose the Ollama model you want to use for your conversations.

Max Tokens

4096

Maximum number of tokens for context and response.

Hide advanced settings

Ollama Base URL

http://127.0.0.1:11434

Enter the URL where Ollama is running.

Ollama Keep Alive

5 minutes

Choose how long Ollama should keep your model in memory before unloading. [Learn more](#)

Performance Mode

Base (Default)

Choose the performance mode for the Ollama model.

Save changes

1

2


3

4

5

公众号 · 5ycode

1. 点击 LLM首选项
2. 选择ollama作为模型提供商
3. 选择已安装的deepseek 模型
4. 注意下地址
5. 保存





1. 向量数据库不用动即可，使用自带的（ps:如果没有选择安装目录，默认在c盘，如果后续有需要可以挪走）
2. 嵌入模型配置

3. 可以使用自带的，也可以使用ollama安装好的


4. 配置完点击左下角的返回即可

配置工作区







1. 新建的工作区
2. 默认会话
3. 上传知识库文档




将文档拖拽到上传框。ps: 只需要拖拽一次就行了，它在聊天框能看到。不知道为什么，我这拖拽以后，没看到上传成功，然后又拖拽了几次。然后聊天框就好多份。





当然你可以配置远程文档，confluence、github都可以。



ps: 需要注意的是文档在工作区间内是共用的。

api功能

AnythingLLM 可以提供api访问的功能，这个可以作为公共知识库使用。

Anything LLM

设置

系统

对话历史记录

代理技能

Community Hub

Explore Trending

Your Account

Import Item

外观

工具

事件日志

API 密钥

浏览器扩展

实验功能

API 密钥

API 密钥允许持有者以编程方式访问和管理此 AnythingLLM 实例。

[阅读 API 文档 →](#)


生成新的 API 密钥

API 密钥	创建者	创建		
ACCBX2V-Q5E4Z1V-H3ZHS7W-G9HRRFK	-	2025-02-04T09:20:04.020Z	Copy API Key	


公众号 · 5ycode

如何投喂数据（训练AI）



1.在工作区界面，点击【上传】。



2. 点击 Upload，选择需要上传的文件（支持 PDF、TXT、Word、Excel、PPT 等常见文档格式）。勾选需要上传的文件。点击 Move to Workspace 将文件移动到工作区



DeepSeek-R1应用展示




⑤集成ChatGPT-Next-Web界面

安装

下载之后默认安装即可

<https://github.com/ChatGPTNextWeb/NextChat/releases/>



配置

打开ChatGPT-Next-Web界面 设置，进行基础配置：

- 配置服务商：选择Open Ai
- 自定义模型名：选择 deepseek-r1:8b
- 模型：选择 deepseek-r1:8b
- 接口地址：<http://127.0.0.1:11434>

NextChat

Build your own AI assistant.

面具

发现

新的聊天

2 条对话2025/1/31 13:22:02

新的聊天

0 条对话2025/1/31 13:19:07

新的聊天

2 条对话2025/1/31 12:52:43

`` { "error": { "message": "...

92 条对话2024/10/13 14:10:07

`` { "error": { "message": "...

12 条对话2024/10/13 10:35:04

新的聊天

设置

所有设置选项

由 NextChat 官方维护, 零配置开箱即用, 支持 OpenAI o1, GPT-4o, Claude-3.5 等最新大模型

立刻对话

模型服务商

切换不同的服务商

OpenAI

接口地址

除默认地址外, 必须包含 http(s)://

http://127.0.0.1:11434

API Key

使用自定义 OpenAI Key 绕过密码访问限制

OpenAI API Key

自定义模型名

增加自定义模型可选项, 使用英文逗号隔开

qwen2:7b,codegemma:7l

模型 (model)

deepseek-r1:8b

随机性 (temperature)

值越大, 回复越随机

0.5

核采样 (top_p)

与随机性类似, 但不要和随机性一起更改

1.0

单次回复限制 (max tokens)

4096

file:///C:/Users/Administrator/Downloads/DeepSeek+部署及应用：保姆级别（本地部署、在线API调用，第三方插件调用）.html

91/114

关闭配置页面。所有工作已经完成， 可以试试在ChatGPT-Next-Web 里点击 新的聊天， 来与大模型进行聊天了。

NextChat

Build your own AI assistant.

面具

发现

新的聊天

2 条对话2025/1/31 13:22:02

新的聊天

0 条对话2025/1/31 13:19:07

新的聊天

2 条对话2025/1/31 12:52:43

`` { "error": { "message": "...

92 条对话2024/10/13 14:10:07

`` { "error": { "message": "...

12 条对话2024/10/13 10:35:04

新的聊天

新的聊天

共 2 条对话

1 想要零配置开箱即用，[点击这里立刻开启对话](#)

2 如果你想消耗自己的 OpenAI 资源，[点击这里修改设置](#)

预设提示词

你好

2025/1/31 13:21:53

deepseek-r1:8b

<think> </think>

你好！很高兴见到你，有什么我可以帮忙的吗？

2025/1/31 13:21:53

Enter 发送，Shift + Enter 换行，/ 触发补全，: 触发命令

发送

file:///C:/Users/Administrator/Downloads/DeepSeek+部署及应用：保姆级别（本地部署、在线API调用，第三方插件调用）.html

93/114

问题解决：

ChatGPT-Next-Web无法聊天,提示failed to fetch: 可能是你没有执行setx OLLAMA_ORIGINS *, 或者是你搞乱了步骤, 先安装了ollama,然后在执行环境变量设置后没有重启ollama.

解决方法-查看环境变量是否正常：执行set OLLAMA_ORIGINS 检查输出是否是OLLAMA_ORIGINS=*

解决方法-重启ollama, 且重新打开新命令行窗口运行ollma run。

ChatGPT-Next-Web无法聊天,提示gpt3.5tubo xxxx: 选择模型有误, 在聊天窗口点击模型切换按钮, 选择qwen2:7b模型

模型运行缓慢：检查显卡是否正常

显卡检查：执行nvidia-smi查看显存占用和显卡使用情况

⑥Page Assist

首先打开谷歌应用商店, 搜索“Page Assist”：

Q

Page Assist

X



Page Assist - 本地 AI 模型的 Web UI

📌 精选

4.9 ★ (106) ⓘ

使用本地运行的 AI 模型来辅助您的网络浏览。

CSDN @轻口味

Page Assist插件官网介绍：

Page Assist 是一款开源浏览器扩展程序，可为您的本地 AI 模型提供侧边栏和 Web UI。它允许您从任何网页与您的模型进行交互。

- 1、本地 AI 模型的 Web UI，支持可视化交互操作（不用安装 Docker 环境，也不用安装 Python 环境）
- 2、支持联网搜索功能

概述

使用本地运行的 AI 模型来辅助您的网络浏览。

Page Assist - 您本地AI模型的侧边栏和网页界面

利用您本地运行的AI模型，在浏览网页时进行交互，或者作为本地AI模型提供者（如Ollama、Chrome AI等）的网页界面。

仓库地址：<https://github.com/n4ze3m/page-assist>

当前功能：

- 各类任务的侧边栏
- 支持视觉模型
- 本地AI模型的简约网页界面
- 网络搜索功能
- 在侧边栏与PDF进行对话
- 与文档对话（支持pdf、csv、txt、md、docx格式）

支持的提供商：

- Ollama
- [测试版] Chrome AI (Gemini Nano)
- [测试版] 支持OpenAI兼容的API（LM Studio、Llamafire以及更多提供商）。

Github 官网：<https://github.com/n4ze3m/page-assist>

Page Assist插件浏览器支持

浏览器	侧边栏	通过网页聊天	Web 用户界面
铬合金	✓	✓	✓
勇敢的	✓	✓	✓
火狐	✓	✓	✓
维瓦尔第	✓	✓	✓
边缘	✓	✗	✓
自由狼	✓	✓	✓
Zen 浏览器	✓	✓	✓
歌剧	✗	✗	✓
弧	✗	✗	✓

安装方法，这里分为两种情况：

- 1、可以科学上网，推荐使用 Chrome 谷歌浏览器
- 2、无法进行科学上网，推荐使用 Firefox 火狐浏览器或者 Brave 浏览器


具体操作步骤



这里只给介绍两种浏览器（**Chrome** 和 **Firefox**）的安装方式，其他的浏览器的插件安装方式都类似，需要注意的是，**Edge** 浏览器目前我还没有找到这个在线插件。


Chrome 浏览器


1. 前提：自行解决科学上网（这里不做介绍，懂的都懂）

- 2. 打开谷歌应用商店：<https://chromewebstore.google.com/>
- 3. 输入【Page Assist】搜索插件
- 4. 选择【Page Assist - 本地 AI 模型的 Web UI】
- 5. 点击【添加到 Chrome】即可，然后固定到 Chrome 浏览器的导航栏上（固不固定都可以）
- 6. 点击【Page Assist】插件即可打开 DeepSeek 的可视化界面
- 7. 右上角齿轮【设置】——》【RAG 设置】——》选择文本嵌入模型——》点击【保存】按钮即可











Firefox 浏览器

- 1. 不需要科学上网，同样是通过扩展打开，地址栏输入：about:addons
- 2. 输入【Page Assist】搜索插件
- 3. 选择【Page Assist - A Web UI for Local AI Models】
- 4. 点击【添加】即可，然后固定到 Firefox 浏览器的导航栏上（固不固定都可以）
- 5. 点击【Page Assist】插件即可打开 DeepSeek 的可视化界面

6. 右上角齿轮【设置】——》【RAG 设置】——》选择文本嵌入模型——》点击【保存】按钮即可





附加组件管理器

"Page Assist"的搜索结果 - Firefox

+

https://addons.mozilla.org/zh-CN/firefox/search/?q=Page Assist%20

Firefox 附加组件博客 扩展工坊 开发者中心 登录

 Firefox Browser

ADD-ONS

扩展 主题 更多...

Page Assist

找到 464 条有关“Page Assist”的结果

过滤结果

排序方式

相关性

附加组件类型

所有

徽章

任何

搜索结果

...

Page Assist - A Web UI for Local AI Models

使用本地运行的 AI 模型来辅助您的网络浏览。

★★★★☆ Muhammed Nazeem

1,866 个用户

Orbit [Beta]: AI Assistant and Content Summarizer

Firefox 出品

Save time with Orbit while juggling emails, diving into lengthy docs, skimming articles, or watching videos. Orbit provides concise summaries, helping you grasp essential information quickly without sacrificing your privacy.

★★★★☆ Mozilla Firefox

8,950 个用户

Maps Assist & Custom Web Search

Install the Maps Assist & Custom Web Search extension to get

149,764 个用户

附加组件管理器

Page Assist - A Web UI for Local AI Models

+

https://addons.mozilla.org/zh-CN/firefox/addon/page-assist/?utm_source=addons.mozilla.org&utm_medium=referral&utm_content=search

Firefox 附加组件博客 扩展工坊 开发者中心 登录

Firefox Browser ADD-ONS 扩展 主题 更多...

查找附加组件

可在 Android™ 版 Firefox 上使用

Page Assist - A Web UI for Local AI Models

作者: Muhammed Nazeem

此附加组件未经 Mozilla 主动安全审计，安装前请确认您对其信任。

详细了解

使用本地运行的 AI 模型来辅助您的网络浏览。

添加到 Firefox

1,866 用户

25 评价

4.4 星

5 星 19

4 星 2

3 星 1

2 星 0


1 星 3


为您的体验打分


屏幕截图


file:///C:/Users/Administrator/Downloads/DeepSeek+部署及应用：保姆级别（本地部署、在线API调用，第三方插件调用）.html


105/114















注意事项

- 1、Ollama 服务必须启动起来。否则会报错
- 2、如果是用的 Chrome 浏览器，需要科学上网，否则打不开谷歌商店，也就没办法在线安装插件

如何查看 Ollama 服务是否开启？

看到这个 Ollama 的任务栏图标即表示服务已开启。



如何开启 Ollama 服务？

非常简单，任务栏的搜索框里面输入【Ollama】——》找到 Ollama 应用，直接单机即可

