

ubuntu系统vllm部署deepseek-70B(DeepSeek-R1-Distill-Llama-70B)

原创

打工乞丐

已于 2025-02-21 17:46:13 修改

阅读量6.5k

★ 收藏

68

👍 点赞数 36

CC 4.0 BY-SA版权

文章标签：

ubuntu

elasticsearch

linux

服务器

深度学习

配置：8张 英伟达 H800显卡，硬盘14T，内存 2T；

本次部署 显卡驱动 和Miniconda都已安装，所以直接从步骤4的 创建虚拟环境 开始；nvidia-smi命令查看显卡；

1. 系统更新和依赖安装

```
# 更新系统包
```

```
sudo apt update && sudo apt upgrade -y
```

```
# 安装基础依赖
```

```
sudo apt install -y build-essential python3-pip curl git wget
```

2. 安装NVIDIA驱动和CUDA Toolkit

```
# 添加NVIDIA驱动仓库（Ubuntu 22.04默认仓库可能版本较低）
```

```
sudo add-apt-repository ppa:graphics-drivers/ppa -y
```

```
sudo apt update
```

```
# 安装推荐驱动（H800需要535+版本）
```

```
sudo apt install -y nvidia-driver-550
```

```
sudo reboot # 重启生效
```

```
# 验证驱动安装
```

```
nvidia-smi # 应显示8张H800信息
```

```
# 安装CUDA 12.2（需与vLLM兼容）
```

```
wget https://developer.download.nvidia.com/compute/cuda/12.2.2/local_installers/cuda_12.2.2_535.104.05_linux.run
```

```
sudo sh cuda_12.2.2_535.104.05_linux.run
```

```
# 安装时取消勾选驱动（已安装），其他默认
```

```
# 添加环境变量
```

```
echo 'export PATH=/usr/local/cuda-12.2/bin:$PATH' >> ~/.bashrc
```

```
echo 'export LD_LIBRARY_PATH=/usr/local/cuda-12.2/lib64:$LD_LIBRARY_PATH' >> ~/.bashrc
```

```
source ~/.bashrc
```

3. 安装cuDNN

```
# 从NVIDIA官网下载cuDNN 8.9.7 for CUDA 12.x（需注册账号）
```

```
# 假设下载到 ~/Downloads/cudnn-linux-x86_64-8.9.7.29_cuda12-archive.tar.xz
```

```
tar -xvf ~/Downloads/cudnn-linux-x86_64-8.9.7.29_cuda12-archive.tar.xz
```

```
sudo cp cudnn-*-archive/include/cudnn*.h /usr/local/cuda/include/
```

```
sudo cp -P cudnn-*-archive/lib/libcudnn* /usr/local/cuda/lib64/
```

```
sudo chmod a+r /usr/local/cuda/include/cudnn*.h /usr/local/cuda/lib64/libcudnn*
```

4. 配置Python环境

```
# 安装Miniconda（如未安装）
```

```
wget https://repo.anaconda.com/miniconda/Miniconda3-latest-Linux-x86_64.sh
bash Miniconda3-latest-Linux-x86_64.sh -b -p $HOME/miniconda
echo 'export PATH="$HOME/miniconda/bin:$PATH"' >> ~/.bashrc
source ~/.bashrc
```

创建虚拟环境

```
conda create -n vllm python=3.9 -y
```

#启用虚拟环境

```
conda activate vllm
```

#启用虚拟环境后，命令行前缀就都会有虚拟环境名称显示（如下）

```
%(vllm) root@hgx-h800-204:
```

#退出虚拟环境进入基础环境

```
#conda deactivate
```

安装PyTorch

```
pip install torch==2.1.2 --index-url https://download.pytorch.org/whl/cu121
```

#如果pip下载失败，可以使用如下命令

```
conda install pytorch==2.1.2 torchvision==0.16.2 torchaudio==2.1.2 pytorch-cuda=12.1 -c pytorch -c nvidia
```

安装vLLM

```
pip install vllm>=0.4.1 # 确保版本支持H800
```

验证安装

安装完成后，运行以下命令验证PyTorch是否正确安装：

```
python -c "import torch; print(torch.__version__); print(torch.cuda.is_available())"
```

如果输出类似以下内容，说明安装成功：

```
2.1.2+cu121
True
```

5. 下载DeepSeek模型

安装 ModelScope 包：ModelScope 是一个模型中心，我们使用它来下载模型。在终端或命令提示符中执行以下命令安装 ModelScope Python 包

```
pip install modelscope
```

#创建模型存放文件夹

```
mkdir -p /data/deepseek-ai/models/deepseek-70b
```

例如DeepSeek-R1-Distill-Llama-70B模型

```
modelscope download --local_dir /data/deepseek-ai/models/deepseek-70b --model deepseek-ai/DeepSeek-R1-Distill-Llama-70B
```

例如deepseek-r1-awq量化模型（该命令为r1向量模型下载命令，该模型启动未验证）

```
modelscope download --local_dir /data/deepseek-ai/models/deepseek-r1-awq --model cognitivecomputations/DeepSeek-R1-awq
```

6. 启动vLLM API服务

```
# 使用8卡张量并行
python -m vllm.entrypoints.openai.api_server \
    --model ./deepseek-70b \
    --tensor-parallel-size 8 \
    --trust-remote-code \ # 如果模型需要自定义代码
    --gpu-memory-utilization 0.85 \ # 显存利用率
    --served-model-name deepseek-70b # API中的模型名称
```

7. 测试API接口

```
# 发送测试请求
curl http://localhost:8000/v1/completions \
    -H "Content-Type: application/json" \
    -d '{
        "model": "deepseek-70b",
        "prompt": "北京的著名景点有",
        "max_tokens": 100,
        "temperature": 0.3
    }'
```

```
# 或使用Python客户端
pip install openai
```

```
from openai import OpenAI
client = OpenAI(base_url="http://localhost:8000/v1")
```

```
response = client.completions.create(  
    model="deepseek-70b",  
    prompt="中国的首都是",  
    max_tokens=100  
)  
print(response.choices[0].text)
```

注意事项

1. **模型兼容性**：确保DeepSeek模型的格式与vLLM兼容（HF格式）。
2. **显存分配**：67B模型需要约130GB显存，8卡H800（每卡80GB）足够。
3. **安全加固**：如需对外开放API，建议配置反向代理和认证。
4. **性能调优**：可通过`--max-num-seqs`和`--max-model-len`调整吞吐量。

如遇到CUDA版本不匹配等问题，可尝试通过`conda install cuda -c nvidia`补充依赖。