

私有化部署DeepSeek-R1 671B，公司内部团队使用

原创

赵橙晔

于 2025-02-10 08:14:43 发布

阅读量8.1k

收藏 31

点赞数 27

分类专栏：

AI模型

 文章标签：

人工智能

python

CC 4.0 BY-SA版权

一、背景与目标



随着深度学习技术的高速发展，越来越多的企业选择在内部搭建大模型推理与训练平台，以确保数据安全、降低外部依赖并满足企业级自定义需求。DeepSeek-R1 671B 作为一款超大规模预训练模型，具有强大的自然语言处理与理解能力，适合在文本生成、知识问答、内容审核等企业场景中提供高质量的解决方案。

本报告主要介绍如何在公司内部使用以下环境完成 DeepSeek-R1 671B 模型的私有化部署：

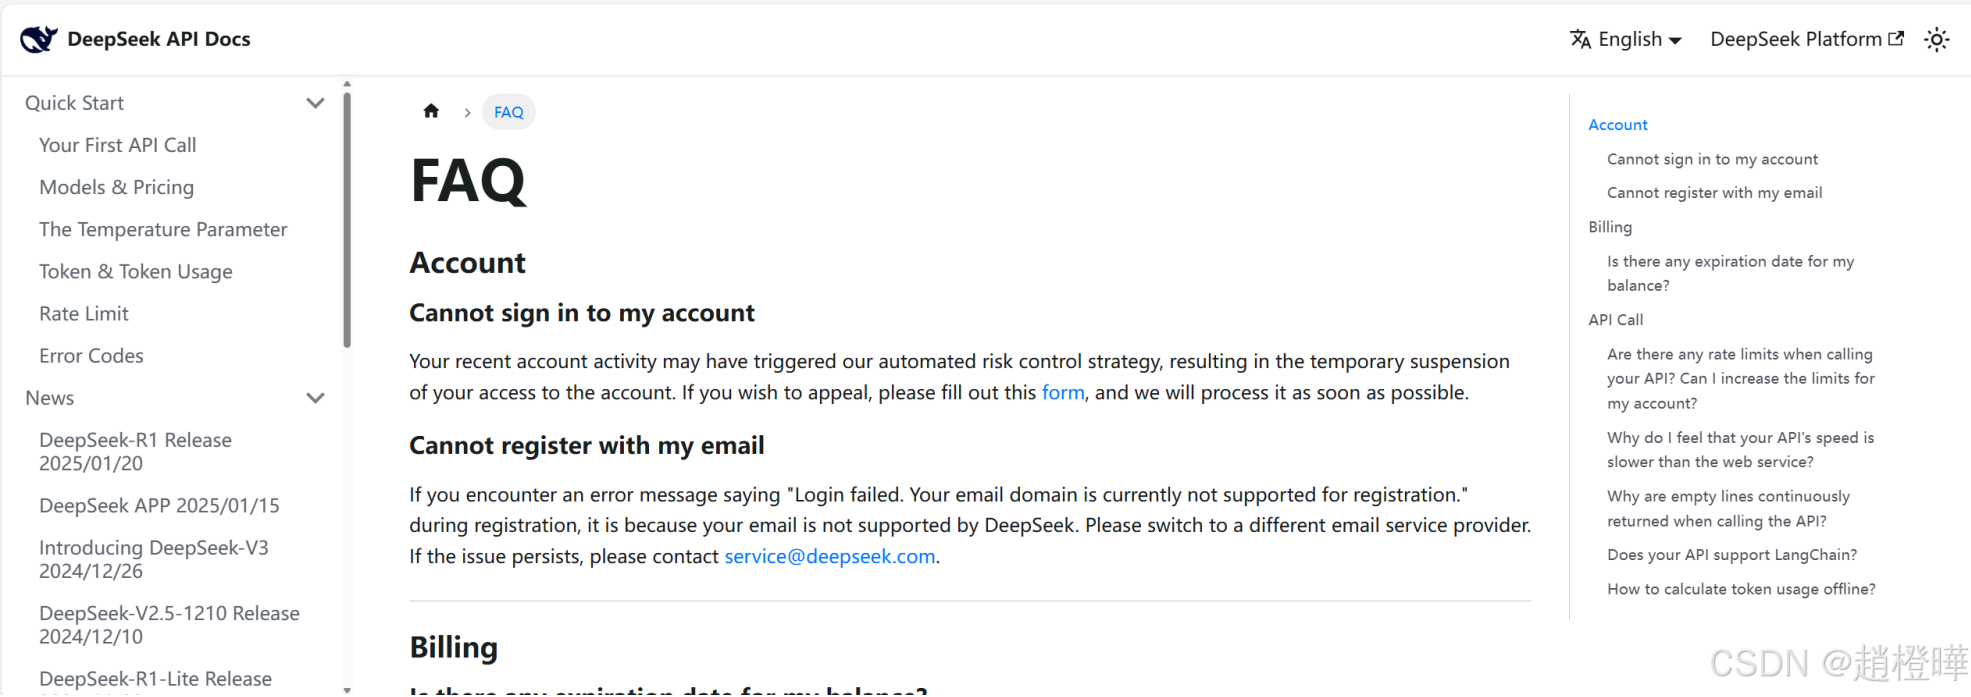
- 硬件环境
 - CPU：ThreadRipper 7980X * 1

- GPU: RTX 4090 * 4 (总显存 96GB)
- 内存: 96 GB * 4 (总计 384GB)
- 存储: SSD 2TB * 1
- **软件环境**
 - 操作系统: CentOS 8.2
 - Python: 3.10+
 - 管理工具: Ollama
 - 前端可视化 UI: AnythingLLM

在本次部署方案中，我们的目标是：

1. **离线部署**，保证数据安全与快速响应；
2. 使用 **Ollama** 进行统一管理与调度；
3. 通过 **AnythingLLM** 提供友好的可视化界面；
4. 确保模型的推理性能与稳定性，支持企业内部多并发访问；
5. 后续可扩展为微调场景或上线更多模型。

二、环境参数与前期准备



1. 硬件参数核对与 BIOS 配置

1. CPU 与内存

- 1. 线程撕裂者（ThreadRipper）系列 CPU 通常支持较高并发与多通道内存。请在 BIOS 中检查内存通道是否全部开启，保证 4 条 96GB 内存均处于可用状态，并充分利用 NUMA 特性。

2. GPU 检查

- 1. 确认 4 块 RTX 4090 均正常安装，驱动已正确识别，执行 `nvidia-smi` 确认显存总量（96GB）是否与预期一致。
- 2. 若需考虑运维性，可将 GPU 风扇与功耗模式设置为合适档位，以平衡性能与能耗。


3. 存储空间

- 1. SSD 2TB 可安装系统与存放初步部署文件，若模型文件体积较大，可考虑使用多块 SSD 或网络存储（如 NAS）。

4. 电源与散热


1. 深度学习工作负载大，需确保电源稳定，以及机箱具备良好的散热方案。

2. 系统与软件依赖




1. 操作系统

- 1. CentOS 8.2，建议开启自动更新或定期手动更新安全补丁；
- 2. 若有生产环境安全合规要求，可加装 SELinux 或其他企业级安全方案；




1. Python 环境

1. 使用 Python 3.10+, 建议通过 Miniconda 或 pyenv 独立管理环境;
2. 建议创建一个名为 deepseek_env 的虚拟环境, 避免与系统原生包冲突;




1. 显卡驱动与 CUDA

1. 安装与 RTX 4090 相匹配的 NVIDIA 驱动（建议最新稳定版）；
2. 安装与驱动配套的 CUDA Toolkit（例如 CUDA 11.x 或 CUDA 12.x，根据需求选择）；



1. 管理工具 Ollama


1. Ollama 提供了模型管理与推理调用的统一接口，需要根据官方文档在 Linux 环境下进行编译或安装相应二进制；
2. 安装完成后，可通过命令 `ollama version` 来查看版本信息；



CSDN @趙橙曄

1. 可视化 UI: AnythingLLM

1. 该工具为前端可视化管理与对话界面，便于业务部门使用与演示；
2. 建议将 AnythingLLM 部署在与模型同一台服务器或者局域网内，减少网络延迟；



1. 其他 Python 库依赖

- 1. 常用深度学习框架（PyTorch 或 TensorFlow），具体取决于 DeepSeek-R1 671B 的兼容性；
- 2. 若 DeepSeek-R1 提供的是 PyTorch 权重，则需安装对应版本的 PyTorch（推荐与 CUDA 版本相符）；
- 3. 分布式训练或推理可能需要 DeepSpeed、Horovod 等库，但若仅是推理，大多数情况只需普通的多 GPU 并行即可。
- 4. 其他常见库：numpy, scipy, scikit-learn, transformers, sentencepiece 等（根据官方文档确认）。

三、部署前的准备工作

1. 模型文件获取

- 1. DeepSeek-R1 671B 的模型文件（可能是多个分片），需在公司内部的存储或私有服务器上做好备份；
- 2. 若模型文件较大（通常 671B 参数的模型体积数400多GB 级别），需确保下载/传输方式安全可控；
- 3. 校验模型文件的哈希值，确保完整性；

```
ollama run deepseek-r1:671b
```

1. 安全合规审查

1. 在正式部署前，确认模型内容、功能符合公司内部相关规范；
2. 根据合规要求，对模型可能产生的文本进行过滤或监测机制设置；

2. Python 虚拟环境创建

```
# 使用 conda 创建虚拟环境
conda create -n deepseek_env python=3.10 -y
conda activate deepseek_env
# 安装 PyTorch（示例） pip install torch torchvision torchaudio --extra-index-url https://download.pytorch.org/whl/cu11X
# 安装其他必要依赖
pip install transformers sentencepiece numpy scipy
```

3. 安装并配置 Ollama

1. 根据 Ollama 官方指导编译或者下载安装包；
2. 安装后，将 Ollama 的可执行文件路径加入到系统环境变量或虚拟环境中；

4. 安装并配置 AnythingLLM

1. 参考官方文档进行安装，若需要前后端分离，需在服务器上安装 Node.js、Nginx 或其他代理；
2. 将 AnythingLLM 连接到 Ollama 后端或直接对接 Python 服务（视实际情况而定）。

四、部署步骤

步骤 1：启动并配置 Ollama

1. Ollama 配置文件

1. 在 `/etc/ollama/config.yaml`（路径示例）中填入必要配置，包括：

1. 模型所在路径;
2. 默认 GPU 使用策略;
3. 最大并发请求数;
4. 日志记录级别 (INFO、WARN、ERROR) 。

2. 多 GPU 支持

1. 若 Ollama 自带多 GPU 并行策略，可在配置文件中指定 `gpus = [0, 1, 2, 3]`;
2. 若需要手动管理模型切分，可考虑结合 DeepSpeed 或 PyTorch 的分布式特性;

3. 启动 Ollama 服务

```
ollama serve --config /etc/ollama/config.yaml
```

1. 若正常启动，可在命令行看到 Ollama 的启动日志，确认已加载 DeepSeek-R1 671B 模型或等待命令加载。

4. 验证

1. 通过 `curl localhost:port/health` (端口 `port` 为 Ollama 默认) 验证服务健康状况;
2. 检查日志是否有报错。

步骤 2：整合 AnythingLLM 前端

1. 安装与初始配置

1. 按照官方文档或预先编写的脚本，将 AnythingLLM 的前端组件安装在同一台服务器或局域网内;
2. 配置反向代理 (如 Nginx) 时，将 `/api` 请求转发给 Ollama 或后端 Python API;

2. 联调测试

1. 在浏览器中打开 AnythingLLM UI;
2. 输入测试文本或提问，观察是否能正常调用后台的 Ollama 接口，并得到 DeepSeek-R1 671B 的推理结果;

3. 若出现跨域问题（CORS）或访问权限限制，需要在配置文件中开放相关域名或 IP。

3. 界面自定义

- 1. 可在 UI 中根据公司品牌或项目需求进行样式调整；
- 2. 若需要提供特定领域问答的模板或固定回复，也可在前端接入公司自定义的 Prompt 设计。

步骤 3：深度优化与资源调度

1. 模型并行与管线并行

- 1. 对于 671B 级别参数的模型，需要考虑显存分配与并行策略：
 - 1. **张量切分**：将参数在 4 块 GPU 间进行拆分；
 - 2. **流水线并行**：将前向与后向传递拆分到不同 GPU；
 - 3. **ZeRO 技术**：如使用 DeepSpeed 的 ZeRO Stage 2/3 减少显存占用。

2. 配置高并发

- 1. 如果需要在支持同时多个请求，需要在 Ollama 或后端框架层面设置并行队列；
- 2. 适当配置 batch size 或微批次（micro-batch），减少 GPU 空转；

3. 日志与监控

- 1. 在生产环境中，需要采集 GPU/CPU 利用率、内存占用、推理时延、出错率等指标；
- 2. 可通过 Prometheus + Grafana 或其他监控体系实现可视化监控。

4. 容错与重试机制

- 1. 若某块 GPU 出现故障或温度过高，可自动切换至其他 GPU；
- 2. 若推理超时，可返回友好提示给用户端。

五、测试与验收

1. 功能性测试

1. 模型问答准确度

1. 通过企业内部常见问题或领域文档，测试模型回答的准确性与一致性；
2. 若回答较差，需考虑后处理或提示词工程（Prompt Engineering）来优化。

2. 文本生成稳定性

1. 让模型生成多种长度与体裁的文本，观察是否产生乱码或重复段落；
2. 调整推理参数（temperature、top_k、top_p 等）提升生成质量。

2. 性能与负载测试

1. 并发压力测试

1. 使用 Apache JMeter、Locust 等工具模拟并发请求，监测响应时间、吞吐量；
2. 根据需求决定能支持多少并发用户，需要与硬件资源相匹配。

2. 显存与内存占用测试

1. 同时记录 `nvidia-smi` 与系统内存占用，观察极端并发下的资源瓶颈；
2. 若资源消耗过高，可以启用分布式策略或限制 batch size。

3. 安全与合规测试

1. 敏感词/违规内容

1. 检查模型在回答时是否触发敏感信息、违规词汇；
2. 如有必要，部署文本过滤器（可以使用正则、关键字匹配或小模型检测），在 UI 层或后端层面统一过滤。

2. 数据安全

1. 确认只有内部 IP 或 VPN 才能访问部署接口，避免外泄；
2. 确保日志中不会记录用户输入的敏感信息，或做脱敏处理。

六、上线与持续维护

1. 正式上线

1. 生产环境切换

1. 在测试通过后，将 Ollama 服务端口暴露到公司内网指定地址；
2. 确保相关负载均衡（如 Nginx、HAProxy）配置到正确后端。

2. 版本管理

1. 建立模型与服务的版本号，对新增功能或优化迭代进行版本记录；
2. 定期对模型进行校验与更新，若有新版本 DeepSeek-R1 释出，可在内网完成模型切换或升级。

2. 监控与告警

1. 日志监控

1. 将 Ollama、AnythingLLM 和系统日志统一收集；
2. 设置告警规则，如 GPU 利用率异常、响应时间过长、出现大量报错等。

2. 健康检查

1. 定时做推理 API 自检，看响应是否超时或出错；
2. 结合自动化脚本，在出现故障时自动重启或通知维护人员。

3. 持续优化

1. Prompt 工程与微调

1. 随着业务发展或问答场景多样化，需要不断迭代提示词或做小规模微调；
2. 可在私有数据集上微调 DeepSeek-R1 671B，以提高对垂直领域的理解深度。

2. 算力扩展

1. 当用户量大幅增长或场景更复杂，可增加 GPU 数量或搭建分布式集群；
2. 使用高带宽互联（InfiniBand / NVLink）可进一步提升多机多卡效率。

4. 故障及风险应对

1. GPU 故障或性能退化

- 1. 及时更换故障 GPU，或在配置中暂时屏蔽该卡；
- 2. 定期测试 GPU 的算力、显存健康度，防止硬件老化。

2. 数据合规

- 1. 定期审计用户输入与输出文本，确保不违反政策；
- 2. 对易引发争议的内容设立人工审核机制。

七、总结

1. 环境搭建与验证

- 1. 通过对硬件、操作系统与 Python 环境的确认，保证了运行环境的可靠性；
- 2. 使用 Ollama 进行统一管理，并结合 AnythingLLM 提供可视化交互界面。

2. 模型下载与部署测试

- 1. 顺利地加载 DeepSeek-R1 671B 预训练模型；
- 2. 进行了基础功能、性能与安全性测试，并取得预期结果。

3. 正式上线与持续维护机制

- 1. 构建了上线流程、监报告警系统、与后续的扩容和优化思路；
- 2. 为未来模型微调、分布式扩展等高阶需求预留空间。

win系统：个人也可以使用docker进行部署，下载是我自己部署的14B的模型。

名称

修改日期

类型

大小

 sha256-0cb05c6e4e02614fa7f4c5d9ddcd5ae7e6...	2025/2/5 12:13	文件	1 KB
 sha256-3c24b0c80794f0eb6e0de0033f8e32030...	2025/2/8 7:48	文件	1 KB
 sha256-6e4c38e1172f42fdbff13edf9a7a017679f...	2025/2/5 12:13	文件	2 KB
 sha256-6e9f90f02bb3b39b59e81916e8cfce9deb...	2025/2/8 7:48	文件	8,777,452 KB
 sha256-31df23ea7daa448f9ccdbbcece6c14689...	2025/2/6 11:14	文件	1 KB
 sha256-369ca498f347f710d068cbb38bf0b8692...	2025/2/5 12:13	文件	1 KB
 sha256-970aa74c0a90ef7482477cf803618e776e...	2025/2/6 11:14	文件	267,862 KB
 sha256-6340dc3229b0d08ea9cc49b75d409870...	2025/2/5 12:13	文件	4,805,407 KB
 sha256-c71d239df91726fc519c6eb72d318ec658...	2025/2/6 11:14	文件	12 KB
 sha256-ce4a164fc04605703b485251fe9f1a1816...	2025/2/6 11:14	文件	1 KB
 sha256-f4d24e9138dd4603380add165d2b0d97...	2025/2/5 12:13	文件	1 KB

选择要预览的文件。

CSDN @趙橙曄

CSDN @趙橙曄