

知识篇 | DeepSeek企业部署模式主要有6种

原创

ZStack开发者社区

已于 2025-02-18 23:03:56 修改

阅读量993

收藏 21

点赞数 26

文章标签：

人工智能

云计算

CC 4.0 BY-SA版权

国际数据公司IDC近日发文《DeepSeek爆火的背后，大模型/生成式AI市场生态潜在影响引人关注》表示：

“大模型的部署过程需同时满足高并发与低延迟的严苛要求，并需全面考量数据安全、隐私保障、资源弹性扩展以及系统维护等多重因素，DeepSeek推出了多种部署模式许可也挑战了全球大模型技术提供商的主要商业化方法，**目前推出的方式有云端部署、本地/内网部署、边缘部署、混合部署、容器化/微服务部署，以及联邦部署模式等。**”

由此可见，对于企业用户，DeepSeek大模型的部署方式主要有以上6种。那么，这6种模式各有什么特点，又分别适用于什么场景呢？

1.云端部署：DeepSeek大模型部署在公有云或私有云上，利用云厂商的基础设施和资源。适用场景：

- 弹性需求：需要根据负载动态调整资源。
- 快速扩展：业务增长迅速，需快速扩展系统。
- 成本优化：希望通过按需付费模式降低IT成本。

2. 本地/内网部署：DeepSeek大模型部署在企业内部服务器或数据中心，数据和应用完全在企业内网中运行。适用场景：

- 数据敏感：对数据安全要求高，需完全掌控数据。
- 合规要求：需满足特定行业或地区的合规要求。
- 网络限制：内网环境无法连接外部网络。

3. 边缘部署：将DeepSeek大模型部署在靠近数据源的边缘节点，减少数据传输延迟。适用场景：

- 低延迟需求：如物联网、实时监控等需要快速响应的场景。
- 带宽有限：数据传输成本高或带宽有限时，边缘计算可减少数据上传。

- 离线运行：需要在网络不稳定或离线时仍能正常运行。

4. 混合部署：结合云端和本地部署，DeepSeek大模型部分系统在云端，部分在本地。适用场景：

- 灵活需求：部分数据需本地处理，部分需云端处理。
- 过渡阶段：从本地逐步迁移到云端时，混合部署可作为过渡方案。
- 灾备需求：本地和云端互为备份，提升系统可靠性。

5. 容器化/微服务部署：将DeepSeek大模型系统拆分为多个微服务，使用容器技术（如Docker）进行部署和管理。适用场景：

- 敏捷开发：需要快速迭代和发布新功能。
- 资源隔离：不同服务需要独立运行环境，避免相互干扰。
- 弹性扩展：根据需求独立扩展特定服务。

6. 联邦部署：DeepSeek大模型多个独立系统通过联邦协议协作，共享数据和资源，但各自保持独立。适用场景：

- 跨组织协作：多个组织需共享数据但保持独立管理。
- 数据隐私：需在保护数据隐私的前提下进行数据共享。
- 分布式计算：需要在多个节点上分布式处理数据，如联邦学习。

由此可见，一般意义上来看：

云端部署，通过云厂商实现弹性扩展和成本优化；

本地/内网部署，通过本地数据中心实现数据完全掌控；

边缘部署，通过边缘节点实现低延迟和实时处理；

混合部署，通过本地和云端结合实现灵活性和灾备需求；

容器化/微服务部署，通过容器技术和微服务架构实现敏捷开发和资源隔离；

联邦部署，通过联邦协议和分布式架构实现跨组织协作和数据隐私保护。

企业用户可以根据具体需求选择合适的部署模式，可以优化系统性能和成本。

云轴科技 ZStack 2月2日宣布 AI Infra 平台智塔全面支持企业私有化部署 DeepSeek V3/R1/ Janus Pro三种模型，并可基于海光、昇腾、英伟达、英特尔等多种国内外 CPU/GPU 适配。

作为DeepSeek企业级专家，ZStack智塔不仅可以全面支持以上6种DeepSeek企业部署模式，在第5种模式上不仅可以支持容器化/微服务部署，也可支持虚拟机、裸金属部署。



云轴科技ZStack智塔功能架构图

作为新一代AI Infra平台，ZStack 智塔以其算力调度、DeepSeek等各种大模型训推、AI应用服务开发的All-in-One一站式平台优势入选该报告，可以帮助企业用户提升异构硬件利用率，降低AI成本；多模型协同加速，优化AI性能；全域计量计费，实现AI自服化，从而加速AI私有化企业级应用。