


万元服务器运行满血版deepseek



本地部署满血版deepseek需要什么配置:

高奢版:

假设并发量在100左右, 一个稳定的方案是双节点服务器。

(单节点服务价格在185万左右, 总成本350-370万左右, 国内GPU价格水深)

- 1、每个节点服务器配置是8张A100 GPU (80G)
- 2、两颗intel志强8358或6348 CPU
- 3、配置512GB内存和5T硬盘。

注意: 配置A100 GPU还需要额外将deepseek R1模型权重精度由原先的BF8 (Brain Floating Point8) 转化为FP16。


进一步提升性能, 考虑将GPU升级H200或者H800, 原生支持BF8推理。

希望进行满血版deepseek R1微调, 目前最高效方案采用ColossalAI的分布式LoRA高效微调, 优点节省50%显存占用, 仅需四个节点8卡A100服务器即可运行。

省钱版:

低成本高性能部署三种方案:

- 1、将GPU更换为推理芯片, 放弃模型训练功能
- 2、将Deepseek R1模型更换量化模型或蒸馏模型, 放弃部分模型性能
- 3、采用CPU+GPU混合推理, 牺牲部分推理速度



大模型推理：聊天、完成任务

大模型训练（微调）：输入大量数据、让模型学习、调整模型能力

降低成本方案一

更换芯片是牺牲模型训练能力来换更低服务器成本

不需要训练的话，可以使用只适合模型推理的显卡（比如英伟达专业图形显卡，RTX6000（ada）48G显存，市场价5万左右）

场景	RTX 6000 Ada	A100 80GB
大模型推理	✓ 可行，性能优秀，尤其适合单卡推理	✓✓✓ 最佳选择，显存带宽和计算能力无与伦比
大模型训练	✓ 适用于中型大模型训练，单卡训练可能较慢	✓✓✓ 专为大模型训练设计，多卡互连极其高效
3D 渲染 / CAD	✓ 专为这类应用优化，性能强大	✗ 无专门优化，适用于图形任务但不如 RTX 6000 强
视频编辑 / 流媒体	✓ 强大的编码/解码能力，支持高性能视频处理	✗ 不专门为视频任务设计
科学计算 / HPC	✓ 优秀的计算性能，适合多种计算任务	✓✓✓ 业界标准，适合大规模计算任务
深度学习推理/加速	✓ Tensor 核心和 FP16 性能强，适合推理任务	✓✓✓ FP16、TF32 性能优化，训练和推理均适用

降低成本方案二

适度牺牲模型推理性能来降低服务器成本。

量化模型经过了精度压缩之后的模型，模型精度降低，使用硬件门槛下降。

量化等级Q2-Q8，Q2\Q4\Q8,也被称为INT2\INT4\INT8量化。数值越高代表的保留的精度也越高、模型体积更大。（基于llama.cpp）Q4_K_M模型公认比较好平衡模型性能与计算效率的量化模型。

进一步放宽模型性能要求，蒸馏模型型组，适配从消费级显卡到服务器级显卡等各类硬件。

DeepSeek R1模型组硬件配置概览



赋范大模型社区

>> 扫码领取原图&R1课程资料包

模型名称	显存需求 (推理)	推荐CPU	推荐GPU	推荐内存
DeepSeek-R1-1.5B	4GB+	Xeon W-2400系列	GTX 1660	8GB+
DeepSeek-R1-3B	8GB+	Xeon W-2400系列	RTX 3060	16GB+
DeepSeek-R1-7B	14GB+	Xeon W-2400系列	RTX 4080	16GB+
DeepSeek-R1-8B	16GB+	Xeon W-2400系列	RTX 4080	16GB+
DeepSeek-R1-14B	28GB+	Xeon W-3400系列	RTX 3090 * 2	32GB+
DeepSeek-R1-32B	58GB+	Xeon W-3400系列	RTX 3090 * 4	64GB+
DeepSeek-R1-70B	140GB+	EPYC 7002系列	A100 * 2	128GB+
DeepSeek-R1-671B (Q4_K_M)	490GB+	EPYC 7002系列	A100 * 8 * 1	512GB+
DeepSeek-R1-671B	1200GB+	EPYC 7002系列	A100 * 8 * 2	1T+

降低成本方案三

同时借助CPU和GPU进行混合推理，由于采用CPU执行计算任务，GPU的负载大幅降低。CPU不适合深度学习，推理速度会变慢，所以整体推理速度会变慢。


借用llama.cpp可以纯CPU模式来运行deepseek R1模型，但是需要大量的内存来加载模型权重，并且运行速度非常慢。

清华大学团队发起KTransformers可以借助R1模型的MoE架构特性，将专家模型的权重加载到内存上并分配CPU完成相关计算工作。同时将MLA/KV Cache加载到GPU上，进而实现CPU+GPU混合推理。

14G显存+382G内存即可运行deepseek R1 Q4-K-M模型，硬件价格不超过5万。

问题模型运行速度大幅收到CPU性能影响，需要4代志强芯片才能达到10个以上token每秒，而且KTransformers对CPU性能挖掘不足，高并发场景下表现比较差，个人使用或者小团队使用。

Unsloth团队 提出动态量化方案更综合，动态量化技术围绕模型的不同层进行不同程度的量化。关键层量化的少一些，非关键层量化多一些，最终了一组比Q2量化程度更深的模型组。尽管量化程度很深，但性能不弱。



unsloth



1. Dynamic Quantized versions

We provide 4 dynamic quantized versions. The first 3 uses an importance matrix to calibrate the quantization process (imatrix via llama.cpp) to allow lower bit representations. The last 212GB version is a general 2bit quant with no calibration done.

MoE Bits	Disk Size	Type	Quality	Link	Down_proj
1.58-bit	131GB	IQ1_S	Fair	Link	2.06/1.56bit
1.73-bit	158GB	IQ1_M	Good	Link	2.06bit
2.22-bit	183GB	IQ2_XXS	Better	Link	2.5/2.06bit
2.51-bit	212GB	Q2_K_XL	Best	Link	3.5/2.5bit

此外还提供可以将模型权重分别加载到CPU和GPU上的方法，用户可以根据自己的实际硬件情况，选择加载若干层模型权重到GPU上，然后选择剩下的模型权重加载到CPU内存上进行计算。

Quant	File Size	24GB GPU	80GB GPU	2x80GB GPU
1.58bit	131GB	7	33	All layers 61
1.73bit	158GB	5	26	57
2.22bit	183GB	4	22	49
2.51bit	212GB	2	19	32

小tips:

1. 确认运行的模型版本

我们要确认到底运行的是哪个R1模型
以及是不是经过量化后的模型或者蒸馏模型

1. 确认运行的模型版本

2. 确认硬件型号和运行模式

如果是CPU+GPU混合推理，那4代志强CPU推理性能更强

如果是纯GPU推理，需要确认是图形显卡、如A6000，还是推理训练一体显卡，如A100

如果图形显卡，那未来可能无法进行模型训练和模型微调；

1. 确认运行的模型版本

2. 确认硬件型号和运行模式

3. 确认响应速度和并发量

一般来说单人响应速度在6 tokens每秒属于能够接受的范围

14 tokens每秒属于比较舒服的响应速度

同时还要考虑服务器并发量，也就是假设团队多人使用情况下能不能保证每人14 tokens每秒

1. 确认运行的模型版本

2. 确认硬件型号和运行模式

3. 确认响应速度和并发量

4. 确认下硬件是否全新以及未来保修策略

硬件市场鱼龙混杂，有很多以次充好和翻新的硬件
需要仔细确认硬件情况以及保修策略