

vLLM专题（八）-使用Run:ai模型流加载模型



大模型专题系列 专栏收录该内容

¥49.90
¥99.00

111 篇文章

已订阅

8折续

👑 您已是超级会员，正在免费阅读会员专享内容

查看更多超级会员权益 >

Run:ai 模型流（Run:ai Model Streamer）是一个用于并发读取张量并将其流式传输到 GPU 内存的库。更多详细信息可以在 Run:ai 模型流文档中查阅。

vLLM 支持使用 Run:ai 模型流加载 Safetensors 格式的权重。首先，您需要安装 vLLM 的 RunAI 可选依赖项：

```
pip3 install vllm[runai]
```

要将其作为与 OpenAI 兼容的服务器运行，请添加 `--load-format runai_streamer` 标志：

```
vllm serve /home/meta-llama/Llama-3.2-3B-Instruct --load-format runai_streamer
```

要从 AWS S3 对象存储运行模型，请执行以下命令：

```
vllm serve s3://core-llm/Llama-3-8b --load-format runai_streamer
```

要从兼容 S3 的对象存储运行模型，请执行以下命令：

```
RUNAI_STREAMER_S3_USE_VIRTUAL_ADDRESSING=0 AWS_EC2_METADATA_DISABLED=true AWS_ENDPOINT_URL=https://storage.googleapis.com vllm serve s3://core-llm/Llama-3-8b --load-format runai_streamer
```

可调参数

您可以使用 `--model-loader-extra-config` 来调整参数：

您可以调整控制并发级别的参数以及从文件读取张量到 CPU 缓冲区的操作系统线程数。对于从 S3 读取数据，这将表示主机向 S3 服务器打开的客户端实例数量。

```
vllm serve /home/meta-llama/Llama-3.2-3B-Instruct --load-format runai_streamer --model-loader-extra-config '{"concurrency":16}'
```

您可以控制从文件读取张量到 CPU 内存缓冲区的大小，并限制此大小。您可以在此处进一步了解有关 CPU 缓冲区内存限制的信息。

```
vllm serve /home/meta-llama/Llama-3.2-3B-Instruct --load-format runai_streamer --model-locator-extra-config '{"memory_limit":5368709120}'
```

注意

有关可调参数及通过环境变量配置的额外参数的更多说明，请阅读环境变量文档。