

## vLLM专题（十）-LoRA Adapters



大模型专题系列 专栏收录该内容

¥49.90  
¥99.00

111 篇文章

已订阅

8折续

👑 您已是超级会员，正在免费阅读会员专享内容

[查看更多超级会员权益](#) >

本文档向您展示如何在基础模型之上使用vLLM的LoRA适配器。

LoRA适配器可用于任何实现了SupportsLoRA接口的vLLM模型。

适配器可以高效地按请求进行服务，且开销极小。首先，我们下载适配器并将其保存到本地。

```
from huggingface_hub import snapshot_download

sql_lora_path = snapshot_download(repo_id="yard1/llama-2-7b-sql-lora-test")
```

然后我们实例化基础模型，并传入 enable\_lora=True 参数：

```
from vllm import LLM, SamplingParams
from vllm.lora.request import LoRARequest

llm = LLM(model="meta-llama/Llama-2-7b-hf", enable_lora=True)
```

现在，我们可以提交提示词（prompts）并调用 `llm.generate` 方法，同时传入 `lora_request` 参数。`LoRARequest` 的第一个参数是一个人类可识别的名称，第二个参数是适配器的全局唯一 ID，第三个参数是 LoRA 适配器的路径。

```

sampling_params = SamplingParams(
    temperature=0,
    max_tokens=256,
    stop=["[/assistant]"]
)

prompts = [
    "[user] Write a SQL query to answer the question based on the table schema.\n\n context: CREATE TABLE table_name_74 (icao VARCHAR, airport VARCHAR)\n\n question: Name the IC\n\n AO for lilongwe international airport [/user] [assistant]",
    "[user] Write a SQL query to answer the question based on the table schema.\n\n context: CREATE TABLE table_name_11 (nationality VARCHAR, elector VARCHAR)\n\n question: When\n\n Anchero Pantaleone was the elector what is under nationality? [/user] [assistant]",
]

outputs = llm.generate(
    prompts,
    sampling_params,
    lora_request=LoRARequest("sql_adapter", 1, sql_lora_path)
)

```

请查看 [examples/offline\\_inference/multilora\\_inference.py](#) 中的示例，了解如何将 LoRA 适配器与异步引擎结合使用，以及如何使用更高级的配置选项。

## 1、服务 LoRA 适配器

LoRA 适配的模型也可以通过兼容 OpenAI 的 vLLM 服务器提供服务。为此，我们在启动服务器时使用

`--lora-modules {name}={path} {name}={path}` 来指定每个 LoRA 模块：

```

vllm serve meta-llama/Llama-2-7b-hf \
    --enable-lora \
    --lora-modules sql-lora=$HOME/.cache/huggingface/hub/models--yard1--llama-2-7b-sql-lora-test/snapshots/0dfa347e8877a4d4ed19ee56c140fa518470028c/

```

### 注意

提交 ID `0dfa347e8877a4d4ed19ee56c140fa518470028c` 可能会随时间变化。请检查您环境中的最新提交 ID，以确保使用的是正确的版本。

服务器入口点接受所有其他 LoRA 配置参数（例如 `max_loras`、`max_lora_rank`、`max_cpu_loras` 等），这些参数将应用于所有后续请求。在查询 `/models` 端点时，我们应该可以看到 LoRA 及其基础模型的信息：

```
curl localhost:8000/v1/models | jq .
{
  "object": "list",
  "data": [
    {
      "id": "meta-llama/Llama-2-7b-hf",
      "object": "model",
      ...
    },
    {
      "id": "sql-lora",
      "object": "model",
      ...
    }
  ]
}
```

请求可以通过 `model` 请求参数指定 LoRA 适配器，就像指定其他模型一样。这些请求将根据服务器全局的 LoRA 配置进行处理（例如，与基础模型请求并行处理，如果提供了其他 LoRA 适配器且 `max_loras` 设置得足够高，还可能与其他 LoRA 适配器请求并行处理）。

以下是一个示例请求：

```
curl http://localhost:8000/v1/completions \
-H "Content-Type: application/json" \
-d '{
  "model": "sql-lora",
  "prompt": "San Francisco is a",
  "max_tokens": 7,
  "temperature": 0
}' | jq
```

## 2、动态服务 LoRA 适配器

除了在服务器启动时加载 LoRA 适配器外，vLLM 服务器现在还支持通过专用 API 端点在运行时动态加载和卸载 LoRA 适配器。当需要灵活地动态切换模型时，此功能尤其有用。

**注意：**在生产环境中启用此功能存在风险，因为用户可能会参与模型适配器的管理。

要启用动态 LoRA 加载和卸载功能，请确保环境变量 `VLLM_ALLOW_RUNTIME_LORA_UPDATING` 设置为 `True`。启用此选项后，API 服务器将记录一条警告日志，以指示动态加载功能已激活。

```
export VLLM_ALLOW_RUNTIME_LORA_UPDATING=True
```

加载 LoRA 适配器：

要 动态加载 LoRA 适配器，请向 `/v1/load_lora_adapter` 端点发送 POST 请求，并提供适配器的相关信息。请求的数据载荷（payload）需要包含 LoRA 适配器的名称和路径。

示例请求（加载 LoRA 适配器）：

```
curl -X POST http://localhost:8000/v1/load_lora_adapter \
-H "Content-Type: application/json" \
-d '{
  "lora_name": "sql_adapter",
  "lora_path": "/path/to/sql-lora-adapter"
}'
```

成功请求响应：

如果请求成功，API 将返回 00 OK 状态码。

如果发生错误（例如找不到或无法加载适配器），API 将返回 相应的错误消息。

---

卸载 LoRA 适配器：

要卸载 先前加载的 LoRA 适配器，请向 `/v1/unload_lora_adapter` 端点发送 POST 请求，并提供 要卸载的适配器名称或 ID。

示例请求卸载 LoRA 适配器）：

```
curl -X POST http://localhost:8000/v1/unload_lora_adapter \
-H "Content-Type: application/json" \
-d '{
  "lora_name": "sql_adapter"
}'
```

### 3、新的 `--lora-modules` 格式

在 之前的版本中，用户可以通过以下格式提供 LoRA 模块，可以是 键值对格式或 JSON 格式。例如：

```
--lora-modules sql-lora-$HOME/.cache/huggingface/hub/models--yard1--llama-2-7b-sql-lora-test/snapshots/0dfa347e8877a4d4ed19ee56c140fa518470028c/
```

之前的格式仅包含每个 LoRA 模块 的名称和路径，但无法指定 `base_model_name`。现在，您可以在 JSON 格式中同时指定 `base_model_name`、名称和路径。例如：

```
--lora-modules '{"name": "sql-lora", "path": "/path/to/lora", "base_model_name": "meta-llama/Llama-2-7b"}'
```

为了支持向后兼容，您仍然可以使用旧的 键值对格式（name=path），但在这种情况下，base\_model\_name将保持未指定。

#### 4、LoRA 模型血统在模型卡中的显示

新的 --lora-modules格式主要用于支持在模型卡中显示父模型信息。以下是您的当前响应如何支持这点的解释：

-LoRA 模型 `sql-lora` 的 parent字段现在链接到其基础模型 `meta-llama/Llama-2-7b-hf`。这正确地反映了基础模型和 LoRA 适配器之间的层次关系。

- root\*字段指向LoRA 适配器的工件位置。

```
$ curl http://localhost:8000/v1/models
```

```
{  
  
  "object": "list",  
  "data": [  
    {  
  
      "id": "meta-llama/Llama-2-7b-hf",  
      "object": "model",  
      "created": 1715644056,  
      "owned_by": "vllm",  
      "root": "~/.cache/huggingface/hub/models--meta-llama--Llama-2-7b-hf/snapshots/01c  
7f73d771dfac7d292323805ebc428287df4f9/",  
      "parent": null,  
      "permission": [  
        {  
  
          .....  
        }  
      ]  
    },  
    {  
  
      "id": "sql-lora",  
      "object": "model",  
      "created": 1715644056,  
      "owned_by": "vllm",  
      "root": "~/.cache/huggingface/hub/models--yard1--llama-2-7b-sql-lora-test/snapsho  
ts/0dfa347e8877a4d4ed19ee56c140fa518470028c/",  
      "parent": meta-llama/Llama-2-7b-hf,  
      "permission": [  
        {  
  
          ....  
        }  
      ]  
    }  
  ]  
}
```