

vLLM专题（十七）-兼容性矩阵



大模型专题系列 专栏收录该内容

¥49.90
¥99.00

111 篇文章

订阅专栏

超级会员

下面的表格显示了互斥特性以及在某些硬件上的支持情况。

使用的符号具有以下含义：

☐ = 完全兼容

☐ = 部分兼容

☐ = 不兼容

注意

请检查带有 ☐ 或 ☐ 的链接，以查看不支持的特性/硬件组合的跟踪问题。

1. 特性 x 特性

Feature	CP	APC	LoRA	prmt adptr	CUDA graph	pooling	enc-dec	logP	prmt logP	async output	multi-step	mm	best-of	beam-search	guided dec
CP	✓														
APC	✓	✓													
LoRA	✓	✓	✓												
prmt adptr	✓	✓	✓	✓											
SD	✓	✓	✗	✓	✓										
CUDA graph	✓	✓	✓	✓	✓	✓									
pooling	✗	✗	✗	✗	✗	✗	✓								
enc-dec	✗	🔄✗	✗	✗	🔄✗	✓	✓	✓							
logP	✓	✓	✓	✓	✓	✓	✗	✓	✓						
prmt logP	✓	✓	✓	✓	✓	✓	✗	✓	✓	✓					
async output	✓	✓	✓	✓	✗	✓	✗	✗	✓	✓	✓				
multi-step	✗	✓	✗	✓	✗	✓	✗	✗	✓	✓	✓	✓			
mm	✓	🔄🟠	🔄🟠	?	?	✓	✓	✓	✓	✓	✓	?	✓		
best-of	✓	✓	✓	✓	🔄✗	✓	✗	✓	✓	✓	?	🔄✗	✓	✓	
beam-search	✓	✓	✓	✓	🔄✗	✓	✗	✓	✓	✓	?	🔄✗	?	✓	✓
guided dec	✓	✓	?	?	🔄✗	✓	✗	?	✓	✓	✓	🔄✗	?	✓	✓

2. 特性 x 硬件

Feature	Volta	Turing	Ampere	Ada	Hopper	CPU	AMD
CP	 						
APC	 						
LoRA							
prmt adptr						 	
SD							
CUDA graph							
pooling							
enc-dec							
mm							
logP							
prmt logP							
async output							
multi-step						 	
best-of							
beam-search							
guided dec							