

VLLM专题（三十）——基准测试套件（Benchmark Suites）

原创

无声之钟

已于 2025-03-19 10:21:57 修改

阅读量142

收藏

点赞数

版权

分类专栏：

大模型专题系列

 文章标签：

算法

 大模型专题系列 专栏收录该内容

 您已是超级会员，正在免费阅读会员专享内容

查看更多超级会员权益 >

vLLM 包含两套基准测试：

- 1. 性能基准测试（Performance Benchmarks）
- 2. 夜间基准测试（Nightly Benchmarks）

1. 性能基准测试（Performance Benchmarks）

性能基准测试用于开发过程中，以确认新更改是否在各种工作负载下提升了性能。每次提交带有 `perf-benchmarks` 和 `ready` 标签的代码时，以及当 PR 合并到 vLLM 时，都会触发这些测试。

最新的性能测试结果可以在 [vLLM 性能仪表盘](#) 上查看。

有关性能基准测试及其参数的更多信息，请参阅[此处](#)。

2. 夜间基准测试（Nightly Benchmarks）

这些测试用于在 vLLM 有重大更新时（例如升级到新版本），将 vLLM 的性能与其他替代方案（如 `tgi`、`trt-llm` 和 `lmdeploy`）进行比较。它们主要面向用户，帮助评估何时选择 vLLM 而不是其他选项。每次提交带有 `perf-benchmarks` 和 `nightly-benchmarks` 标签的代码时，都会触发这些测试。

最新的夜间基准测试结果会在主要版本发布的博客文章中分享，例如 [vLLM v0.6.0](#)。

有关夜间基准测试及其参数的更多信息，请参阅[此处](#)。

 无声之钟

已关注

 0

 0

 0

 0

分享

...

专栏目录

已订阅

 VLLM 推理引擎性能分析 基准 测试

技术分享，读书笔记，面试宝典，算法积累，应有尽...

8352

~

本文为 vLLM 推理引擎根据官方提供的数据集进行的性能 基准 测试，主要 测试分析 --enable-chunked-prefill 的启用/禁用以及 --max-num-batched-tokens 参数的调整对性能的影响情况...

 只需 24G 显存，用 vllm 跑起来 Yi-34B 中英双语大模型 arkohut的博客  6794

上次介绍了用 vllm 去部署 mixtral 8x7b 的 GPTQ 量化版本，只是跑了一下 benchmark，这次玩一下 Yi-34b 这个模型的量化版本，看看怎么使用 vllm 直接暴露出来一个 API 服务。

 浅谈语言模型推理框架 vLLM 0.6.0性能优化 最新发布 Ucloud_TShare的博客  2524

上优刻得AI推理平台，享极速推理体验！ 优刻得AI推理平台上线高性能推理服务框架 vLLM，新版 vLLM升级「服务推理进程分离」、「多步调度」、「异步输出处理」等机制，以降低CPU争抢开销、减少GPU空闲等待，并使得模型推理和输出处理异步进行。通过不断优化硬件资源利用率，让模型推理更高效。