

VLLM专题（二十三）—引擎参数



大模型专题系列 专栏收录该内容

¥49.90
¥99.00

111 篇文章

已订阅

8折续

👑 您已是超级会员，正在免费阅读会员专享内容

[查看更多超级会员权益](#) >

1. 参数说明

** 以下是 vLLM 中每个引擎参数的说明：**

```
usage: vllm serve [-h] [--model MODEL]
                  [--task {
                    auto,generate,embedding,embed,classify,score,reward,transcription}]
                  [--tokenizer TOKENIZER] [--hf-config-path HF_CONFIG_PATH]
                  [--skip-tokenizer-init] [--revision REVISION]
                  [--code-revision CODE_REVISION]
                  [--tokenizer-revision TOKENIZER_REVISION]
                  [--tokenizer-mode {
                    auto,slow,mistral,custom}]
                  [--trust-remote-code]
                  [--allowed-local-media-path ALLOWED_LOCAL_MEDIA_PATH]
                  [--download-dir DOWNLOAD_DIR]
                  [--load-format {
                    auto,pt,safetensors,npcache,dummy,tensorizer,sharded_state,gguf,bitsandbytes,
                    mistral,runai_streamer}]
                  [--config-format {
                    auto,hf,mistral}]
                  [--dtype {
                    auto,half,float16,bfloat16,float,float32}]
                  [--kv-cache-dtype {
                    auto,fp8,fp8_e5m2,fp8_e4m3}]
                  [--max-model-len MAX_MODEL_LEN]
                  [--guided-decoding-backend GUIDED_DECODING_BACKEND]
                  [--logits-processor-pattern LOGITS_PROCESSOR_PATTERN]
                  [--model-impl {
                    auto,vllm,transformers}]
                  [--distributed-executor-backend {
                    ray,mp,uni,external_launcher}]
                  [--pipeline-parallel-size PIPELINE_PARALLEL_SIZE]
                  [--tensor-parallel-size TENSOR_PARALLEL_SIZE]
                  [--enable-expert-parallel]
```

```

[--max-parallel-loading-workers MAX_PARALLEL_LOADING_WORKERS]
[--ray-workers-use-nsight] [--block-size {
8,16,32,64,128}]
[--enable-prefix-caching | --no-enable-prefix-caching]
[--disable-sliding-window] [--use-v2-block-manager]
[--num-lookahead-slots NUM_LOOKAHEAD_SLOTS] [--seed SEED]
[--swap-space SWAP_SPACE] [--cpu-offload-gb CPU_OFFLOAD_GB]
[--gpu-memory-utilization GPU_MEMORY_UTILIZATION]
[--num-gpu-blocks-override NUM_GPU_BLOCKS_OVERRIDE]
[--max-num-batched-tokens MAX_NUM_BATCHED_TOKENS]
[--max-num-partial-prefills MAX_NUM_PARTIAL_PREFILLS]
[--max-long-partial-prefills MAX_LONG_PARTIAL_PREFILLS]
[--long-prefill-token-threshold LONG_PREFILL_TOKEN_THRESHOLD]
[--max-num-seqs MAX_NUM_SEQS] [--max-logprobs MAX_LOGPROBS]
[--disable-log-stats]
[--quantization {
aqlm,awq,deepspeedfp,tpu_int8,fp8,ptpc_fp8,fbgemm_fp8,modelopt,nvfp4,marlin,g
guf,gptq_marlin_24,gptq_marlin,awq_marlin,gptq,compressed-tensors,bitsandbytes,qqq,hqq,ex
perts_int8,neuron_quant,ipex,quark,moe_wna16,None}]
[--rope-scaling ROPE_SCALING] [--rope-theta ROPE_THETA]
[--hf-overrides HF_OVERRIDES] [--enforce-eager]
[--max-seq-len-to-capture MAX_SEQ_LEN_TO_CAPTURE]
[--disable-custom-all-reduce]
[--tokenizer-pool-size TOKENIZER_POOL_SIZE]
[--tokenizer-pool-type TOKENIZER_POOL_TYPE]
[--tokenizer-pool-extra-config TOKENIZER_POOL_EXTRA_CONFIG]
[--limit-mm-per-prompt LIMIT_MM_PER_PROMPT]
[--mm-processor-kwarg MM_PROCESSOR_KWARG]
[--disable-mm-preprocessor-cache] [--enable-lora]
[--enable-lora-bias] [--max-loras MAX_LORAS]
[--max-lora-rank MAX_LORA_RANK]
[--lora-extra-vocab-size LORA_EXTRA_VOCAB_SIZE]
[--lora-dtype {
auto,float16,bfloat16}]
[--long-lora-scaling-factors LONG_LORA_SCALING_FACTORS]
[--max-cpu-loras MAX_CPU_LORAS] [--fully-sharded-loras]
[--enable-prompt-adapter]
[--max-prompt-adapters MAX_PROMPT_ADAPTERS]
[--max-prompt-adapter-token MAX_PROMPT_ADAPTER_TOKEN]
[--device {
auto,cuda,neuron,cpu,openvino,tpu,xpu,hpu}]
[--num-scheduler-steps NUM_SCHEDULER_STEPS]
[--use-tqdm-on-load | --no-use-tqdm-on-load]
[--multi-step-stream-outputs [MULTI_STEP_STREAM_OUTPUTS]]
[--scheduler-delay-factor SCHEDULER_DELAY_FACTOR]
[--enable-chunked-prefill [ENABLE_CHUNKED_PREFILL]]
[--speculative-model SPECULATIVE_MODEL]
[--speculative-model-quantization {

```

```

aqlm,awq,deepspeedfp,tpu_int8,fp8,ptpc_fp8,fbgemm_fp8,modelopt,nvfp4,marlin,g
guf,gptq_marlin_24,gptq_marlin,awq_marlin,gptq,compressed-tensors,bitsandbytes,qqq,hqq,ex
perts_int8,neuron_quant,ipex,quark,moe_wna16,None}]
    [--num-speculative-tokens NUM_SPECULATIVE_TOKENS]
    [--speculative-disable-mqa-scorer]
    [--speculative-draft-tensor-parallel-size SPECULATIVE_DRAFT_TENSOR_PARA
LLEL_SIZE]
    [--speculative-max-model-len SPECULATIVE_MAX_MODEL_LEN]
    [--speculative-disable-by-batch-size SPECULATIVE_DISABLE_BY_BATCH_SIZE]
    [--ngram-prompt-lookup-max NGRAM_PROMPT_LOOKUP_MAX]
    [--ngram-prompt-lookup-min NGRAM_PROMPT_LOOKUP_MIN]
    [--spec-decoding-acceptance-method {
rejection_sampler,typical_acceptance_sampler}]
    [--typical-acceptance-sampler-posterior-threshold TYPICAL_ACCEPTANCE_SA
MPLER_POSTERIOR_THRESHOLD]
    [--typical-acceptance-sampler-posterior-alpha TYPICAL_ACCEPTANCE_SAMPLE
R_POSTERIOR_ALPHA]
    [--disable-logprobs-during-spec-decoding [DISABLE_LOGPROBS_DURING_SPEC_
DECODING]]
    [--model-loader-extra-config MODEL_LOADER_EXTRA_CONFIG]
    [--ignore-patterns IGNORE_PATTERNS]
    [--preemption-mode PREEMPTION_MODE]
    [--served-model-name SERVED_MODEL_NAME [SERVED_MODEL_NAME ...]]
    [--qlora-adapter-name-or-path QLORA_ADAPTER_NAME_OR_PATH]
    [--show-hidden-metrics-for-version SHOW_HIDDEN_METRICS_FOR_VERSION]
    [--otlp-traces-endpoint OTLP_TRACES_ENDPOINT]
    [--collect-detailed-traces COLLECT_DETAILED_TRACES]
    [--disable-async-output-proc]
    [--scheduling-policy {
fcfs,priority}]
    [--scheduler-cls SCHEDULER_CLS]
    [--override-neuron-config OVERRIDE_NEURON_CONFIG]
    [--override-pooler-config OVERRIDE_POOLER_CONFIG]
    [--compilation-config COMPILATION_CONFIG]
    [--kv-transfer-config KV_TRANSFER_CONFIG]
    [--worker-cls WORKER_CLS]
    [--worker-extension-cls WORKER_EXTENSION_CLS]
    [--generation-config GENERATION_CONFIG]
    [--override-generation-config OVERRIDE_GENERATION_CONFIG]
    [--enable-sleep-mode] [--calculate-kv-scales]
    [--additional-config ADDITIONAL_CONFIG] [--enable-reasoning]
    [--reasoning-parser {
deepseek_r1}]

```

以下是每个 vLLM 引擎参数的详细说明：

模型相关参数

`--model`

- 使用的 Hugging Face 模型的名称或路径。
- 默认值: `"facebook/opt-125m"`

`--task`

- 模型用于的任务类型。可选值: `auto` (自动选择)、`generate` (生成)、`embedding` (嵌入)、`embed` (嵌入)、`classify` (分类)、`score` (评分)、`reward` (奖励)、`transcription` (转录)。
- 每个 vLLM 实例仅支持一个任务, 即使模型可以用于多个任务。
- 默认值: `"auto"`

`--tokenizer`

- 使用的 Hugging Face 分词器的名称或路径。如果未指定, 则使用模型名称或路径。

`--hf-config-path`

- 使用的 Hugging Face 配置文件的名称或路径。如果未指定, 则使用模型名称或路径。

`--skip-tokenizer-init`

- 跳过分词器和反分词器的初始化。输入需要提供有效的 `prompt_token_ids`, 且 `prompt` 为 `None`。生成的输出将包含 token ID。

`--revision`

- 使用的模型版本 (分支名称、标签名称或提交 ID)。如果未指定, 则使用默认版本。

`--code-revision`

- 使用的 Hugging Face Hub 上模型代码的特定版本 (分支名称、标签名称或提交 ID)。如果未指定, 则使用默认版本。

`--tokenizer-revision`

- 使用的 Hugging Face 分词器的版本 (分支名称、标签名称或提交 ID)。如果未指定, 则使用默认版本。

`--tokenizer-mode`

- 分词器模式。可选值：`auto`（自动选择）、`slow`（慢速分词器）、`mistral`（Mistral 分词器）、`custom`（自定义分词器）。
- 默认值：`"auto"`

`--trust-remote-code`

- 信任 Hugging Face 的远程代码。

`--allowed-local-media-path`

- 允许 API 请求从服务器文件系统指定的目录读取本地图像或视频。这是一个安全风险，仅在受信任的环境中启用。

`--download-dir`

- 下载和加载权重的目录，默认为 Hugging Face 的默认缓存目录。

`--load-format`

- 加载模型权重的格式。可选值：`auto`（自动选择）、`pt`（PyTorch 格式）、`safetensors`（安全张量格式）、`npcache`（带 NumPy 缓存的 PyTorch 格式）、`dummy`（随机初始化权重）、`tensorizer`（使用 CoreWeave 的 Tensorizer）、`sharded_state`（分片状态）、`gguf`（GGUF 格式）、`bitsandbytes`（bitsandbytes 量化）、`mistral`（Mistral 格式）、`runai_streamer`（使用 Run:ai 的 Safetensors 流式加载）。

- 默认值：`"auto"`

`--config-format`

- 加载模型配置的格式。可选值：`auto`（自动选择）、`hf`（Hugging Face 格式）、`mistral`（Mistral 格式）。

- 默认值：`"ConfigFormat.AUTO"`

`--dtype`

- 模型权重和激活的数据类型。可选值：`auto`（自动选择）、`half`（FP16）、`float16`（FP16）、`bfloat16`（BF16）、`float`（FP32）、`float32`（FP32）。

- 默认值：`"auto"`

`--kv-cache-dtype`

- KV 缓存的数据类型。可选值：`auto`（自动选择）、`fp8`（FP8）、`fp8_e5m2`（FP8 E5M2 格式）、`fp8_e4m3`（FP8 E4M3 格式）。

- 默认值：`"auto"`

`--max-model-len`

- 模型的上下文长度。如果未指定，则从模型配置中自动推导。

`--guided-decoding-backend`

- 用于引导解码（JSON 模式、正则表达式等）的默认引擎。当前支持 `outlines-dev/outlines`、`mlc-ai/xgrammar` 和 `noamgat/lm-format-enforcer`。
- 默认值: `"xgrammar"`

`--logits-processor-pattern`

- 指定可以通过 `logits_processors` 参数传递的有效 logits 处理器名称的正则表达式模式。默认为 `None`，表示不允许任何处理器。

`--model-impl`

- 使用的模型实现。可选值: `auto`（自动选择）、`vllm`（vLLM 实现）、`transformers`（Transformers 实现）。
- 默认值: `"auto"`

分布式与并行相关参数

`--distributed-executor-backend`

- 分布式模型工作器的后端。可选值: `ray`（Ray）、`mp`（多进程）、`uni`（单机）、`external_launcher`（外部启动器）。
- 默认值: `"ray"`

`--pipeline-parallel-size`（`-pp`）

- 流水线并行的阶段数。
- 默认值: `1`

`--tensor-parallel-size`（`-tp`）

- 张量并行的副本数。
- 默认值: `1`

`--enable-expert-parallel`

- 对 MoE 层使用专家并行而不是张量并行。

`--max-parallel-loading-workers`

- 在多个批次中顺序加载模型，以避免在使用张量并行和大模型时出现内存不足（OOM）问题。

`--ray-workers-use-nsight`

- 如果指定，则使用 Nsight 分析 Ray 工作器。

缓存与调度相关参数

`--block-size`

- 连续 token 块的 token 大小。可选值: `8`、`16`、`32`、`64`、`128`。
- 默认值: `16`

`--enable-prefix-caching`

- 启用自动前缀缓存。使用 `--no-enable-prefix-caching` 显式禁用。

`--disable-sliding-window`

- 禁用滑动窗口，限制为滑动窗口大小。

`--use-v2-block-manager`

- [已弃用] 块管理器 v1 已被移除，`SelfAttnBlockSpaceManager`（即块管理器 v2）现在是默认值。设置此标志对 vLLM 行为无影响。

`--num-lookahead-slots`

- 实验性调度配置，用于推测解码。未来将被推测配置取代。

- 默认值: `0`

资源与性能相关参数

`--seed`

- 操作的随机种子。

`--swap-space`

- 每个 GPU 的 CPU 交换空间大小（GiB）。

- 默认值: `4`

`--cpu-offload-gb`

- 每个 GPU 卸载到 CPU 的空间（GiB）。默认值为 `0`，表示不卸载。

- 默认值: `0`

`--gpu-memory-utilization`

- 用于模型执行器的 GPU 内存利用率（0 到 1 之间）。例如，`0.5` 表示 50% 的 GPU 内存利用率。

- 默认值: `0.9`

`--num-gpu-blocks-override`

- 如果指定，则忽略 GPU 分析结果并使用此 GPU 块数。用于测试抢占。

`--max-num-batched-tokens`

- 每次迭代的最大批处理 token 数。

`--max-num-partial-prefills`

- 对于分块预填充，最大并发部分预填充数。

- 默认值: `1`

`--max-long-partial-prefills`

- 对于分块预填充，超过 `--long-prefill-token-threshold` 的长提示的最大并发预填充数。

- 默认值: `1`

预填充与序列相关参数

`--long-prefill-token-threshold`

- 对于分块预填充，如果提示的 token 数超过此值，则视为长提示。默认值为模型上下文长度的 4%。
- 默认值：`0`

`--max-num-seqs`

- 每次迭代的最大序列数。

`--max-logprobs`

- 返回的最大 log probs 数量（当在 `SamplingParams` 中指定 `logprobs` 时）。
- 默认值：`20`

`--disable-log-stats`

- 禁用统计日志记录。

量化相关参数

`--quantization` (`-q`)

- 用于量化权重的方法。可选值：`aqlm`、`awq`、`deepspeedfp`、`tpu_int8`、`fp8`、`ptpc_fp8`、`fbgemm_fp8`、`modelopt`、`nvfp4`、`marlin`、`gguf`、`gptq_marlin_24`、`gptq_marlin`、`awq_marlin`、`gptq`、`compressed-tensors`、`bitsandbytes`、`qqq`、`hqq`、`experts_int8`、`neuron_quant`、`ipex`、`quark`、`moe_wna16`、`None`。
- 如果为 `None`，则首先检查模型配置文件中的 `quantization_config` 属性。如果该属性为 `None`，则假设模型权重未量化，并使用 `dtype` 确定权重数据类型。

RoPE 相关参数

`--rope-scaling`

- RoPE 缩放的 JSON 配置。例如：`{"rope_type":"dynamic","factor":2.0}`。

`--rope-theta`

- RoPE theta 值。与 `rope_scaling` 一起使用。在某些情况下，更改 RoPE theta 可以提高缩放模型的性能。

HuggingFace 配置覆盖

`--hf-overrides`

- HuggingFace 配置的额外参数。应为 JSON 字符串，解析为字典。

性能优化相关参数

`--enforce-eager`

- 始终使用 PyTorch 的 eager 模式。如果为 `False`，则使用混合模式（eager 模式和 CUDA 图）以获得最大性能和灵活性。

`--max-seq-len-to-capture`

- CUDA 图覆盖的最大序列长度。当序列的上下文长度超过此值时，回退到 eager 模式。

- 默认值: `8192`

`--disable-custom-all-reduce`

- 参见 `ParallelConfig`。

分词器池相关参数

`--tokenizer-pool-size`

- 用于异步分词的分词器池大小。如果为 `0`，则使用同步分词。

- 默认值: `0`

`--tokenizer-pool-type`

- 用于异步分词的分词器池类型。如果 `tokenizer_pool_size` 为 `0`，则忽略此参数。

- 默认值: `"ray"`

`--tokenizer-pool-extra-config`

- 分词器池的额外配置。应为 JSON 字符串，解析为字典。如果 `tokenizer_pool_size` 为 `0`，则忽略此参数。

多模态相关参数

`--limit-mm-per-prompt`

- 对于每个多模态插件，限制每个提示允许的输入实例数。例如: `image=16,video=2` 表示每个提示最多允许 16 张图片和 2 个视频。

- 默认值: 每种模态为 `1`。

`--mm-processor-kwags`

- 多模态输入映射/处理的覆盖参数。例如: `{"num_crops": 4}`。

`--disable-mm-preprocessor-cache`

- 如果为 `true`，则禁用多模态预处理器/映射器的缓存（不推荐）。

LoRA 相关参数

`--enable-lora`

- 如果为 `True`，则启用 LoRA 适配器的处理。

`--enable-lora-bias`

- 如果为 `True`，则为 LoRA 适配器启用偏置。

`--max-loras`

- 单个批次中的最大 LoRA 数量。
- 默认值: `1`

`--max-lora-rank`

- 最大 LoRA 秩。
- 默认值: `16`

`--lora-extra-vocab-size`

- LoRA 适配器中额外词汇表的最大大小（添加到基础模型词汇表中）。
- 默认值: `256`

`--lora-dtype`

- LoRA 的数据类型。可选值: `auto`（自动选择）、`float16`（FP16）、`bfloat16`（BF16）。
- 默认值: `"auto"`

`--long-lora-scaling-factors`

- 指定多个缩放因子（可以与基础模型缩放因子不同，例如 Long LoRA），以允许同时使用使用这些缩放因子训练的 LoRA 适配器。

`--max-cpu-loras`

- 存储在 CPU 内存中的最大 LoRA 数量。必须大于或等于 `max_loras`。默认为 `max_loras`。

`--fully-sharded-loras`

- 默认情况下，只有一半的 LoRA 计算与张量并行分片。启用此选项将使用完全分片的层。

`--enable-prompt-adapter`

- 如果为 `True`，则启用 PromptAdapter 的处理。

`--max-prompt-adapters`

- 单个批次中的最大 PromptAdapter 数量。
- 默认值: `1`

`--max-prompt-adapter-token`

- 最大 PromptAdapter token 数量。
- 默认值: `0`

设备与调度相关参数

`--device`

- vLLM 执行的设备类型。可选值: `auto` (自动选择)、`cuda` (CUDA)、`neuron` (Neuron)、`cpu` (CPU)、`openvino` (OpenVINO)、`tpu` (TPU)、`xpu` (XPU)、`hpu` (HPU)。
- 默认值: `"auto"`

`--num-scheduler-steps`

- 每次调度器调用的最大前向步骤数。
- 默认值: `1`

`--use-tqdm-on-load`

- 是否在加载模型权重时启用进度条。
- 默认值: `True`

`--multi-step-stream-outputs`

- 如果为 `False`，则多步骤将在所有步骤结束时流式输出。
- 默认值: `True`

`--scheduler-delay-factor`

- 在调度下一个提示之前应用延迟 (延迟因子乘以上一个提示的延迟)。
- 默认值: `0.0`

`--enable-chunked-prefill`

- 如果设置，则可以根据 `max_num_batched_tokens` 对预填充请求进行分块。

推测解码相关参数

`--speculative-model`

- 用于推测解码的草稿模型名称。

`--speculative-model-quantization`

- 草稿模型权重的量化方法。可选值与 `--quantization` 相同。

`--num-speculative-tokens`

- 在推测解码中从草稿模型采样的推测 token 数量。

`--speculative-disable-mqa-scorer`

- 如果为 `True`，则在推测解码中禁用 MQA 评分器并回退到批次扩展。

`--speculative-draft-tensor-parallel-size` (`--spec-draft-tp`)

- 草稿模型的张量并行副本数。

`--speculative-max-model-len`

- 草稿模型支持的最大序列长度。超过此长度的序列将跳过推测。

`--speculative-disable-by-batch-size`

- 如果新传入请求的排队请求数大于此值，则禁用推测解码。

`--ngram-prompt-lookup-max`

- 推测解码中 ngram 提示查找窗口的最大大小。

`--ngram-prompt-lookup-min`

- 推测解码中 ngram 提示查找窗口的最小大小。

`--spec-decoding-acceptance-method`

- 推测解码中草稿 token 验证的接受方法。可选值：`rejection_sampler`（拒绝采样器）、`typical_acceptance_sampler`（典型接受采样器）。

- 默认值：`"rejection_sampler"`

`--typical-acceptance-sampler-posterior-threshold`

- 设置 token 接受的后验概率下限阈值。此阈值由 `TypicalAcceptanceSampler` 用于在推测解码中做出采样决策。

- 默认值：`0.09`

`--typical-acceptance-sampler-posterior-alpha`

- 在 `TypicalAcceptanceSampler` 中，用于基于熵的 token 接受阈值的缩放因子。通常默认为 `--typical-acceptance-sampler-posterior-threshold` 的平方根（即 `0.3`）。

`--disable-logprobs-during-spec-decoding`

- 如果为 `True`，则在推测解码期间不返回 token 的 log 概率。如果为 `False`，则根据 `SamplingParams` 的设置返回 log 概率。如果未指定，则默认为 `True`。
- 禁用 log 概率可以减少延迟，因为跳过了提议采样、目标采样和接受 token 确定后的 log 概率计算。

模型加载相关参数

`--model-loader-extra-config`

- 模型加载器的额外配置。这将传递给与所选 `load_format` 对应的模型加载器。应为 JSON 字符串，解析为字典。

4. `--ignore-patterns`

- 加载模型时要忽略的模式。默认为 `original/**/*`，以避免重复加载 LLaMA 的检查点。
- 默认值: `[]`

抢占模式与模型名称

`--preemption-mode`

- 如果为 `recompute`，则引擎通过重新计算执行抢占；如果为 `swap`，则引擎通过块交换执行抢占。

`--served-model-name`

- API 中使用的模型名称。如果提供多个名称，服务器将响应任何提供的名称。响应中的 `model` 字段将使用此列表中的第一个名称。如果未指定，则模型名称将与 `--model` 参数相同。
- 注意：此名称也将用于 Prometheus 指标的 `model_name` 标签内容。如果提供多个名称，指标标签将使用第一个名称。

QLoRA 适配器与指标

`--qlora-adapter-name-or-path`

- QLoRA 适配器的名称或路径。

`--show-hidden-metrics-for-version`

- 启用自指定版本以来已隐藏的弃用 Prometheus 指标。例如，如果某个指标自 `v0.7.0` 版本以来已被隐藏，则可以使用 `--show-hidden-metrics-for-version=0.7` 作为临时解决方案，同时迁移到新指标。
- 该指标可能会在未来的版本中完全移除。

OpenTelemetry 跟踪与性能

`--otlp-traces-endpoint`

- 发送 OpenTelemetry 跟踪数据的目标 URL。

`--collect-detailed-traces`

- 有效选项: `model`、`worker`、`all`。仅在设置了 `--otlp-traces-endpoint` 时有意义。如果设置，将为指定模块收集详细跟踪数据。这可能会涉及高成本或阻塞操作，从而影响性能。

`--disable-async-output-proc`

- 禁用异步输出处理。这可能会导致性能下降。

调度策略与调度器

`--scheduling-policy`

- 使用的调度策略。可选值：`fcfs`（先到先服务，默认值）或 `priority`（基于优先级和到达时间处理请求，优先级值越低越早处理）。
- 默认值：`"fcfs"`

`--scheduler-cls`

- 使用的调度器类。默认值为 `vllm.core.scheduler.Scheduler`。可以是类本身，也可以是类路径（如 `mod.custom_class`）。
- 默认值：`"vllm.core.scheduler.Scheduler"`

Neuron 配置与池化方法

`--override-neuron-config`

- 覆盖或设置 Neuron 设备配置。例如：`{"cast_logits_dtype": "bfloat16"}`。

`--override-pooler-config`

- 覆盖或设置池化模型的池化方法。例如：`{"pooling_type": "mean", "normalize": false}`。

编译与 KV 缓存传输配置

`--compilation-config`（`-O`）

- 模型的 `torch.compile` 配置。如果是数字（`0`、`1`、`2`、`3`），则解释为优化级别。
- `0`：默认级别，无优化。
- `1` 和 `2`：仅用于内部测试。
- `3`：推荐的生产级别。
- 要指定完整的编译配置，请使用 JSON 字符串。

`--kv-transfer-config`

- 分布式 KV 缓存传输的配置。应为 JSON 字符串。
-

工作器与生成配置

`--worker-cls`

- 用于分布式执行的工作器类。
- 默认值：`"auto"`

`--worker-extension-cls`

- 在工作器类之上扩展的工作器扩展类。如果只想在不更改现有功能的情况下添加新功能，则非常有用。
- 默认值：`""`

--generation-config

- 生成配置的文件夹路径。默认为 `auto`，生成配置将从模型路径加载。如果设置为 `vllm`，则不加载生成配置，使用 vLLM 默认值。如果设置为文件夹路径，则从指定路径加载生成配置。

- 默认值: `auto`

--override-generation-config

- 以 JSON 格式覆盖或设置生成配置。例如: `{"temperature": 0.5}`。如果与 `--generation-config=auto` 一起使用，则覆盖参数将与模型的默认配置合并。如果 `generation-config` 为 `None`，则仅使用覆盖参数。

睡眠模式与动态 KV 缩放

--enable-sleep-mode

- 启用引擎的睡眠模式（仅支持 CUDA 平台）。

--calculate-kv-scales

- 当 `kv-cache-dtype` 为 `fp8` 时，启用动态计算 `k_scale` 和 `v_scale`。如果为 `false`，则从模型检查点加载缩放因子（如果可用）。否则，缩放因子默认为 `1.0`。

平台特定配置与推理功能

--additional-config

- 以 JSON 格式指定平台的额外配置。不同平台可能支持不同的配置。确保配置对所使用的平台有效。输入格式为 `{"config_key": "config_value"}`。

--enable-reasoning

- 是否启用模型的 `reasoning_content` 功能。如果启用，模型将能够生成推理内容。

--reasoning-parser

- 根据使用的模型选择推理解析器。用于将推理内容解析为 OpenAI API 格式。启用 `--enable-reasoning` 时必须指定。

- 可选值: `deepseek_r1`

2. Async Engine Arguments

以下是与异步引擎相关的附加参数：

```
vllm serve [-h] [--disable-log-requests]
```

命名参数

`--disable-log-requests`

禁用请求日志记录。