

VLLM专题（二十九）—优化与调优



大模型专题系列 专栏收录该内容

¥49.90
¥99.00

111 篇文章

已订阅

8折续

👑 您已是超级会员，正在免费阅读会员专享内容

查看更多超级会员权益 >

1. 抢占（Preemption）

由于 Transformer 架构的自回归特性，有时 KV 缓存空间不足以处理所有批处理请求。vLLM 可以通过抢占请求来释放 KV 缓存空间，以供其他请求使用。被抢占的请求会在 KV 缓存空间再次充足时重新计算。当发生这种情况时，系统会打印以下警告：

```
WARNING 05-09 00:49:33 scheduler.py:1057 由于 KV 缓存空间不足，序列组 0 被 PreemptionMode.SWAP 模式抢占。这可能会影响端到端性能。请增加 gpu_memory_utilization 或 tensor_parallel_size 以提供更多的 KV 缓存内存。total_cumulative_preemption_cnt=1
```

虽然这种机制确保了系统的鲁棒性，但抢占和重新计算可能会对端到端延迟产生不利影响。如果您经常遇到 vLLM 引擎的抢占问题，可以考虑以下操作：

增加 `gpu_memory_utilization`

vLLM 通过使用 `gpu_memory_utilization%` 的内存预分配 GPU 缓存。通过增加此利用率，可以提供更多的 KV 缓存空间。

减少 `max_num_seqs` 或 `max_num_batched_tokens`

这可以减少批处理中的并发请求数量，从而减少对 KV 缓存空间的需求。

增加 `tensor_parallel_size`

这种方法会对模型权重进行分片，使每个 GPU 有更多的内存可用于 KV 缓存。

增加 `pipeline_parallel_size`

这种方法将模型层分布到多个 GPU 上，减少每个 GPU 上模型权重所需的内存，从而间接为 KV 缓存留出更多内存。

您还可以通过 vLLM 暴露的 Prometheus 指标监控抢占请求的数量。此外，您可以通过设置

`disable_log_stats=False` 来记录抢占请求的累计数量。

2. 分块预填充（Chunked Prefill）

vLLM 支持一项实验性功能——分块预填充（Chunked Prefill）。该功能允许将大型预填充任务分块为较小的块，并将它们与解码请求一起批处理。

您可以通过在命令行中指定 `--enable-chunked-prefill` 或在 LLM 构造函数中设置 `enable_chunked_prefill=True` 来启用此功能。

```
llm = LLM(model="meta-llama/Llama-2-7b-hf", enable_chunked_prefill=True)
# 设置 max_num_batched_tokens 以调整性能。
# 注意：2048 是分块预填充的默认 max_num_batched_tokens。
# Llm = LLM(model="meta-llama/Llama-2-7b-hf", enable_chunked_prefill=True, max_num_batched_tokens=2048)
```

默认情况下，vLLM 调度器会优先处理预填充请求，并且不会将预填充和解码请求批处理到同一批次中。这种策略优化了 TTFT（首字时间），但会导致 ITL（字间延迟）变慢以及 GPU 利用率降低。

启用分块预填充后，策略将更改为优先处理解码请求。它会将所有挂起的解码请求批处理到同一批次中，然后再调度任何预填充请求。当有可用的 `token_budget`（即 `max_num_batched_tokens`）时，它会调度挂起的预填充请求。如果最后一个挂起的预填充请求无法完全放入 `max_num_batched_tokens`，则会将其分块处理。

这种策略有两个好处：

改善 ITL 和解码生成性能

由于解码请求被优先处理，因此 ITL 和解码生成性能会得到提升。

提高 GPU 利用率

通过将计算密集型（预填充）和内存密集型（解码）请求放在同一批次中，可以更好地利用 GPU。

您可以通过调整 `max_num_batched_tokens` 来优化性能。默认情况下，它设置为 2048。较小的 `max_num_batched_tokens` 可以实现更好的 ITL，因为较少的预填充请求会中断解码。较大的 `max_num_batched_tokens` 可以实现更好的 TTFT，因为可以将更多的预填充请求放入批次中。

如果 `max_num_batched_tokens` 与 `max_model_len` 相同，则几乎等同于默认调度策略（除了它仍然优先处理解码请求）。

需要注意的是，`max_num_batched_tokens` 的默认值（2048）是为了优化 ITL 而设置的，其吞吐量可能低于默认调度器。

建议您将 `max_num_batched_tokens` 设置为大于 2048 以提高吞吐量。