

VLLM专题（二十八）—使用 Nginx



大模型专题系列 专栏收录该内容

¥49.90
¥99.00

111 篇文章

已订阅

8折续



您已是超级会员，正在免费阅读会员专享内容

查看更多超级会员权益 >

本文档展示了如何启动多个 vLLM 服务容器，并使用 Nginx 作为服务器之间的负载均衡器。

1. 构建 Nginx 容器

本指南假设您已经克隆了 vLLM 项目，并且当前位于 vLLM 根目录。

```
export vllm_root=`pwd`
```

创建一个名为 `Dockerfile.nginx` 的文件，内容如下：

```
FROM nginx:latest
RUN rm /etc/nginx/conf.d/default.conf
EXPOSE 80
CMD ["nginx", "-g", "daemon off;"]
```

构建容器：

```
docker build . -f Dockerfile.nginx --tag nginx-lb
```

2. 创建简单的 Nginx 配置文件

创建一个名为 `nginx_conf/nginx.conf` 的文件。请注意，您可以根据需要添加任意数量的服务器。在以下示例中，我们从两个服务器开始。如果需要添加更多服务器，只需在 `upstream backend` 中添加一个新的 `server vllmN:8000 max_fails=3 fail_timeout=10000s;` 条目即可。

```
upstream backend {
    least_conn;
    server vllm0:8000 max_fails=3 fail_timeout=10000s;
    server vllm1:8000 max_fails=3 fail_timeout=10000s;
}

server {
    listen 80;
    location / {
        proxy_pass http://backend;
        proxy_set_header Host $host;
        proxy_set_header X-Real-IP $remote_addr;
        proxy_set_header X-Forwarded-For $proxy_add_x_forwarded_for;
        proxy_set_header X-Forwarded-Proto $scheme;
    }
}
```

3. 构建 vLLM 容器

进入 vLLM 项目的根目录：

```
cd $vllm_root
```

使用以下命令构建 Docker 镜像：

```
docker build -f Dockerfile . --tag vllm
```

如果您在代理后面，可以通过以下方式将代理设置传递给 `docker build` 命令：

```
docker build -f Dockerfile . --tag vllm --build-arg http_proxy=$http_proxy --build-arg https_proxy=$https_proxy
```

4. 创建 Docker 网络

运行以下命令创建一个名为 `vllm_nginx` 的 Docker 网络：

```
docker network create vllm_nginx
```

5. 启动 vLLM 容器

注意事项：

HuggingFace 模型缓存

如果您的 HuggingFace 模型缓存位于其他目录，请更新以下命令中的 `hf_cache_dir`。

模型下载

如果您没有现有的 HuggingFace 缓存，建议先启动 `vllm0` 并等待模型下载完成且服务器准备就绪。这样可以确保 `vllm1` 可以复用已下载模型，而无需重新下载。

GPU 后端

以下示例假设使用 GPU 后端。如果使用 CPU 后端，请移除 `--gpus device=ID`，并添加 `VLLM_CPU_KVCACHE_SPACE` 和 `VLLM_CPU_OMP_THREADS_BIND` 环境变量。

模型名称

如果您不想使用 `meta-llama/Llama-2-7b-chat-hf` 模型，请调整为您所需的模型名称。

```
mkdir -p ~/.cache/huggingface/hub/  
hf_cache_dir=~/.cache/huggingface/  
docker run -itd --ipc host --network vllm_nginx --gpus device=0 --shm-size=10.24gb -v $hf_cache_dir:/root/.cache/huggingface/ -p 8081:8000 --name vllm0 vllm --model meta-llama/Llama-2-7b-chat-hf  
docker run -itd --ipc host --network vllm_nginx --gpus device=1 --shm-size=10.24gb -v $hf_cache_dir:/root/.cache/huggingface/ -p 8082:8000 --name vllm1 vllm --model meta-llama/Llama-2-7b-chat-hf
```

注意

如果您在代理后面，可以通过以下方式将代理设置传递给 `docker run` 命令：

```
-e http_proxy=$http_proxy -e https_proxy=$https_proxy
```

6. 启动 Nginx

运行以下命令来启动 Nginx 容器：

```
docker run -itd -p 8000:80 --network vllm_nginx -v ./nginx_conf:/etc/nginx/conf.d/ --name nginx-lb nginx-lb
```

- `-itd`：以交互模式启动容器并在后台运行。
- `-p 8000:80`：将容器的 80 端口映射到主机的 8000 端口。
- `--network vllm_nginx`：连接到名为 `vllm_nginx` 的 Docker 网络。
- `-v ./nginx_conf:/etc/nginx/conf.d/`：将本地的 `nginx_conf` 目录挂载到容器中的 Nginx 配置目录。
- `--name nginx-lb`：为容器指定名称 `nginx-lb`。
- `nginx-lb`：使用之前构建的容器镜像。

这样，Nginx 容器就会启动并监听 8000 端口。

7. 验证 vLLM 服务器是否已准备好

运行以下命令以检查 vLLM 服务器的日志：

```
docker logs vllm0 | grep Uvicorn
docker logs vllm1 | grep Uvicorn
```

这两个输出应类似于以下内容：

```
INFO:      Uvicorn running on http://0.0.0.0:8000 (Press CTRL+C to quit)
```

如果您看到此信息，则表示 vLLM 服务器已成功启动并准备好处理请求。