

像 DeepSeek-R1 这类模型到底该用哪个框架，这份对比指南从企业生产角度出发，帮你理清 vLLM、SGLang、Ollama 等主流框架的定位差异、性能表现、适用场景和部署成本，助你精准决策。

一、主流企业级推理框架核心定位与适用场景

1. vLLM: 高并发生产环境的首选引擎

- 定位：专为高吞吐、低延迟的企业级推理设计，支持分布式扩展。
- 技术亮点：
 - **PagedAttention**：像操作系统分页管理内存一样高效分配显存，显存利用率 >95%（传统框架仅约 60%）。
 - **Continuous Batching**：动态合并请求，吞吐量可达 Ollama 的 5 倍以上（如 7B 模型同硬件下：Ollama 45 token/s → vLLM 240 token/s）。
- 适用场景：
 - 客服机器人、金融实时分析、API 服务（QPS ≥ 200）
 - 千亿参数模型部署（如 DeepSeek-R1 67B）。
- 代表案例：某电商平台用 8 台 H100 + vLLM 支撑日均 1 亿请求，延迟 <500ms。

vllm
优点：
同时处理很多用户请求，响应快。
高效利用显存。
多台服务器，多卡一起调用，处理超大量。
缺点：
技术团队、高端GPU如A100/H100、运维成本高。
不适合简单任务。W

2. SGLang: 结构化输出与高并发优化的新锐框架

- 定位：企业级复杂任务处理，特别擅长结构化输出（如 JSON、函数调用）。
- 技术亮点：
 - 零开销批处理 + 缓存感知调度 → 结构化输出速度提升 10 倍。
 - 对 DeepSeek 等模型深度优化，适合精细化业务场景。
- 适用场景：
 - 对话系统、数据处理管道、需要严格输出格式的应用
 - 需 A100/H100 高端 GPU 支持。
- 代表案例：大型企业的内部知识引擎，需实时返回结构化数据。

SGLang
优点：
输出JSON/表格等结构化数据，速度很快。
DeepSeek优化好，复杂任务很高效。
缺点：
高端GPU如A100/H100
不需要结构化输出，优势不明显

3. Ollama: 仅适合轻量级验证，不推荐企业生产

- 定位：个人开发/快速原型验证，强调易用性。
- 局限：
 - 无分布式支持，并发能力弱（>50 请求易崩溃）。
 - 显存利用率低（~60%），吞吐量仅为 vLLM 的 1/5。
- 适用场景：
 - PoC 验证、边缘设备（如笔记本 + RTX 4090）
 - 内部工具开发（非核心业务）。

Ollama
优点：
一键安装、零运维。
家用显卡就行、资源要求低。
缺点：
并发能力弱，人多请求就崩溃
吞吐量低，显存浪费多
不支持分布式（多张显卡调用）

🔗 企业生产部署的核心需求：高并发、低延迟、易扩展、高显存利用 —— vLLM 和 SGLang 才是真正企业级选择。

🔧 二、企业级框架详细对比：vLLM vs SGLang

维度	vLLM	SGLang	Ollama（参考）
核心优势	吞吐量极高（企业首选）	结构化输出快（适合复杂任务）	部署极简（5 分钟启动）
吞吐量	↑ 420 token/s (A100,13B)	↑ 1.9×批处理效率	↓ 78 token/s（同硬件）
延迟	首 Token 210ms	中低（依赖任务复杂度）	首 Token 350ms（实时性好）
部署复杂度	需配置多GPU/分布式	需API集成，适合技术团队	一键运行，无需运维
硬件要求	专业级 GPU（A100/H100 x2+）	高端 GPU（A100/H100）	消费级 GPU（RTX 4090）
扩展性	✅ 支持多机集群/K8s	✅ 多GPU优化	❌ 仅单机
成本	高（硬件/运维投入）	高（高端 GPU 刚需）	极低（适合小团队）

🌳 三、企业选型决策树：什么场景选谁？

- 选 vLLM 当 →
 - 需要千亿模型 + 高并发 API 服务（如客服系统、金融分析平台）
 - 已有专业运维团队，追求吞吐量最大化。
- 选 SGLang 当 →
 - 业务依赖结构化输出（如合同解析、数据抽取）
 - 已部署高端 GPU 集群，需深度优化 DeepSeek 等模型。
- 选 Ollama 仅限 →
 - 内部 PoC 验证、边缘设备部署（法律团队用 Ollama + DeepSeek 审核合同↑400%）
 - 切忌用于生产流量！50+并发可能崩溃。

💎 四、总结：企业部署的黄金原则

- 要性能 → vLLM：吞吐为王，显存近 100% 利用，支撑千亿级模型；
- 要结构化 → SGLang：10 倍输出效率提升，适合严谨业务流；

- 要快试错 → **Ollama**：原型阶段利器，但勿上生产！

最后附上 企业级框架核心特性对比表，助你快速决策：

特性	vLLM	SGLang	Ollama
企业级部署	✓ 最佳	✓ 推荐	✗ 不适用
千亿模型支持	✓	✓	✗（显存不足）
吞吐量	★★★★★	★★★★☆	★★☆☆☆
输出结构化	基础支持	★★★★★	有限
运维成本	高	高	极低

企业真正需要的是：生产级并发能力、可扩展架构、高资源利用率——在vLLM 和SGLang 之间做选择，取决于你的业务是否需要“极致结构化输出”。如果是，选SGLang；否则，vLLM 是企业部署的通用最优解。