

一文详解八款主流大模型推理框架



AIGC开发者

关注

10 人赞同了该文章 >

生成式 AI 的飞速发展推动了大模型在企业、科研和个人开发中的广泛应用。然而，如何将这些超大模型高效、稳定地推理部署在各类硬件环境上，始终是落地应用的核心难题。

本文将从技术原理、性能指标、部署方式及适用场景等多个维度，对当前市场上主流的八款大模型推理平台/引擎进行深入解析，并通过直观的对比表格帮助您快速甄选最合适的解决方案。

一、主流推理平台/引擎详解

1. vLLM+ —— 高效多 GPU 推理的企业级方案



Easy, fast, and cheap LLM serving for everyone

图片

项目地址：github.com/vllm-project

技术特点

PagedAttention 技术：vLLM 利用智能管理 KV 缓存页，结合动态批处理和异步调度机制，有效降低内存占用，同时显著提升推理吞吐量。

多 GPU 分布式部署：支持在多卡 GPU 集群上运行，即便面对千亿参数级模型，也能在低延迟下稳定处理海量并发请求。

量化优化支持：内置 GPTQ+、AWQ+ 等量化技术，有效压缩模型体积，进一步提升 GPU 资源利用率。

优势与局限

优势：适用于高并发在线服务，如金融交易、智能客服和文档处理；低首次响应时间（TTFT）表现出色。

局限：依赖高端 NVIDIA GPU（如 A100、H100，H20），硬件投入成本较高；代码架构较复杂，对定制开发和维护要求较高。

适用场景

适用于对延迟和吞吐量要求极高的企业级应用，特别是需要大规模在线推理服务的场景。

2. Ollama+ —— 零门槛、易用的本地推理平台



图片

项目地址：github.com/ollama/ollama

技术特点

跨平台一键安装：Ollama 支持 Windows、macOS 与 Linux 平台，提供直观的用户界面，降低使用门槛。

内置大模型库：内置超过 1700 款预训练模型，默认提供 int4 量化处理后的权重，大幅降低显存需求，使普通消费级硬件也能流畅运行。

离线推理保障：支持完全离线运行，确保数据安全与隐私，适合对本地数据保护有高要求的应用。

封装 llama.cpp：在 llama.cpp 的基础上提供了更高层次的抽象，使模型调用与管理更加简单便捷。

优势与局限

优势：操作简单、易上手，适合个人开发者、学生和快速原型验证；低硬件资源要求及离线数据安全。

局限：在高并发场景下，响应性能可能存在瓶颈；扩展性和插件定制能力较弱，不适合大规模在线部署。

适用场景

适用于个人原型开发、教育演示、数据隐私要求较高的本地推理场景等轻量级应用。

3. SGLang —— 高吞吐量与极致响应的前沿引擎



图片

项目地址：github.com/sgl-project/

技术特点

RadixAttention+ 优化：通过共享前缀请求和高效缓存策略，SGLang 能在理论上实现十万级 token/s 的超高吞吐量，同时显著降低响应延迟。

高效结构化输出：内置高性能 JSON 解析模块，便于构建面向结构化数据查询的 API 服务，适合复杂自动化工作流。

轻量模块化架构：采用灵活的模块化设计，便于快速集成新技术（如 FlashInfer+ 内核），不断优化推理效率。

优势与局限

优势：适用于大批量结构化查询和实时响应要求极高的应用；在高并发场景下表现出色。

局限：当前版本仅支持 Linux 平台，跨平台兼容性待提升；对多模态任务支持较弱，生态尚在起步阶段。

适用场景

适用于金融、医疗、搜索引擎等领域的高并发实时响应场景，特别适合结构化数据处理应用。

4. LMDeploy+ —— 国产硬件下的性能优化专家



图片

项目地址: github.com/InternLM/lmd

技术特点

国产 GPU 深度适配: LMDeploy 针对华为昇腾等国产 GPU 进行专门优化, 充分发挥硬件优势, 显著提升推理效率与显存利用率。

多模态融合支持: 在视觉-语言混合模型上具备明显优势, 能同时处理图像和文本数据, 满足复杂业务场景需求。

优势与局限

优势: 在国产硬件环境下成本优势明显, 适合政府、企业级定制化部署; 多模态支持能力强。

局限: 更新迭代速度较慢; 分布式部署和高并发处理能力有待进一步提升。

适用场景

适用于国内企业和政府机构在国产 GPU 平台上的大模型部署, 特别是多模态交互和视觉语言任务领域。

5. Llama.cpp —— 资源受限环境下的轻量级推理解决方案



图片

项目地址: github.com/ggml-org/llama

技术特点

纯 CPU 推理: 完全基于 CPU 实现, 无需高性能 GPU, 适合在嵌入式设备、边缘计算及资源受限环境下运行。

轻量级与开源: 架构简单、易于部署, 社区活跃, 用户可以根据需求自行定制和优化推理过程。

优势与局限

优势: 零硬件门槛, 成本极低; 适合边缘设备和低负载任务; 开源生态丰富, 便于快速迭代。

局限: 与 GPU 加速方案相比, 推理速度较慢, 不适合大规模在线服务; 高并发处理能力有限。

适用场景

适用于边缘计算、物联网和低负载场景, 为无 GPU 环境下的基本推理需求提供可行方案。

6. TensorRT-LLM —— 基于 NVIDIA TensorRT 的深度优化引擎

项目地址: github.com/NVIDIA/TensorRT-LLM

TensorRT-LLM

A TensorRT Toolbox for Optimized Large Language Model Inference

图片

技术特点

深度链路优化: 借助 NVIDIA TensorRT, 对大模型进行全链路优化, 确保在推理过程中极低延迟和超高吞吐量。

量化与预编译支持: 通过预编译和多种量化方案 (如 FP8/INT4), 最大化利用 NVIDIA GPU 的计算潜力, 进一步提升性能。

优势与局限

优势：在 NVIDIA GPU 环境下表现出色，极大缩短响应时间，适合对推理速度要求苛刻的生产级应用。

局限：预编译过程可能会带来冷启动延迟；仅限于 NVIDIA CUDA 平台，跨平台部署存在局限。

适用场景

适用于大规模实时响应系统、在线服务和需要极致性能优化的企业级应用。

7. Hugging Face TGI+ —— 生产级稳定推理服务平台



text-generation-inference

知乎 @AIGC开发者

图片

项目地址：github.com/huggingface/

技术特点

成熟稳定的生态系统：作为 Hugging Face Inference API 的核心组件，TGI 在云端推理服务中已被广泛验证。

标准化 API 接口：提供 RESTful API 与 OpenAI 兼容接口，支持连续批处理和流式输出，便于与现有应用无缝集成。

优势与局限

优势：文档丰富、生态成熟，易于集成和扩展；适合大规模云端部署和 API 推理。

局限：在极端高并发场景下，定制化优化能力可能略逊于专用解决方案；部分高级功能依赖云端服务。

适用场景

适用于企业级云端服务和 API 推理平台，能够提供稳定、可靠的生产级推理支持。

8. MLC-LLM+ —— 新兴的 ML 编译器推理引擎

MLC LLM

知乎 @AIGC开发者



项目地址: github.com/mlc-ai/mlc-llm

技术特点

基于 Apache TVM 的编译优化：MLC-LLM 利用 ML 编译技术对大模型进行全链路优化，有效降低首次响应时间（TTFT），为快速原型验证提供支持。

实验性与前沿探索：在低并发场景下表现优异，展示了编译优化技术在推理领域的巨大潜力。

优势与局限

优势：在小规模、低延迟需求场景中表现突出，适合研发初期和实验性应用。

局限：当前版本多为 nightly 构建，稳定性和文档支持仍有待完善；部署流程相对复杂，对编译与配置要求较高。

适用场景

适用于研发初期、实验性低延迟场景，未来稳定版本问世后有望在大规模生产部署中发挥更大作用。

二、各平台综合对比表

为了更直观地对比上述八款平台/引擎的技术特点、优势局限和适用场景，整理了以下综合对比表：

平台/引擎	核心技术/亮点	优势	局限	适用场景
vLLM	PagedAttention、动态批处理、异步调度、多 GPU 分布式	高并发、低延迟，适合大规模在线服务	依赖高端 GPU、代码复杂，二次开发门槛较高	金融、智能客服、文档处理等企业级应用
Ollama	基于 llama.cpp 封装，跨平台支持、内置 1700+ 模型、int4 量化	安装便捷、易上手、低硬件要求、数据离线保障	并发处理能力较弱，扩展性和插件定制能力有限	个人原型开发、教育展示、本地隐私要求场景
SGLang	RadixAttention、高效缓存、结构化输出、轻量模块化架构	超高吞吐量、极低响应延迟、适合高并发结构化查询	目前仅支持 Linux、对多模态任务支持能力有限	金融、医疗、搜索引擎等高并发实时响应场景
LMDeploy	国产 GPU 深度适配、显存优化、多模态融合支持	在国产硬件上性能优异、成本优势明显，适合多模态复杂场景	更新迭代较慢、分布式部署和高并发处理能力待加强	国内企业、政府机构部署，视觉语言混合任务
Llama.cpp	纯 CPU 推理、轻量级设计、开源社区支持	零硬件门槛、低成本、适合边缘和嵌入式设备	推理速度较慢，高并发能力有限	边缘计算、物联网、低负载场景
TensorRT-LLM	基于 NVIDIA TensorRT 的深度优化、量化与预编译支持	极低延迟、高吞吐量、充分发挥 NVIDIA GPU 优势	预编译过程可能带来冷启动延迟，仅限 NVIDIA CUDA 平台	企业级大规模在线服务、实时响应系统
Hugging Face TGI	生产级推理服务、标准化 RESTful API、OpenAI 兼容接口	生态成熟、稳定可靠、易于云端集成	高并发定制化优化能力稍弱，部分功能依赖云端服务	云端部署、API 推理、企业级生产环境
MLC-LLM	基于 Apache TVM 的编译优化、低 TTFT、实验性原型验证	在低并发、低延迟场景下表现突出，展示编译优化潜力	当前版本稳定性待提高，部署流程较复杂	研发初期、实验性应用，未来大规模部署探索

三、综合选择建议与未来展望

综合建议

企业级高并发应用：对于在线客服、金融交易和智能文档处理等对延迟与吞吐量要求极高的场景，推荐选择 vLLM、TensorRT-LLM 或 Hugging Face TGI，它们在多 GPU 部署和低延

迟响应方面表现尤为突出。

个人开发与本地原型：Ollama 凭借其跨平台、易上手的特性，非常适合个人原型验证和离线本地部署，而 Llama.cpp 则满足了无 GPU 环境下的基本推理需求。

国产硬件部署：LMDeploy 针对国产 GPU 进行了深度优化，具备多模态处理优势，适合国内企业和政府机构在特定硬件环境下部署。

新兴技术探索：SGLang 与 MLC-LLM 分别在高吞吐量和编译优化上展示了前沿技术潜力，虽然当前还存在一定局限，但未来发展前景值得期待。

未来展望

随着硬件升级、算法革新和产业生态不断完善，大模型推理技术正朝着以下方向发展：

跨平台与异构计算：未来推理引擎将支持 CPU、GPU 及专用 AI 芯片的无缝切换，构建更加灵活的部署体系。

模块化与智能调度：通过模块化设计和智能调度，用户可根据业务需求自定义优化策略，实现更高效的资源利用。

多模态与融合能力：在视觉、语音、文本等多模态数据处理方面，推理平台将不断完善跨模态融合技术，提供全方位智能服务。

开源生态与产业协作：开源社区的活跃和产业界的深度合作，将推动标准化接口、数据安全和高效部署方面的持续优化，为 AI 应用提供坚实技术支撑。

四、结语

当前大模型推理平台/引擎生态各具特色，从企业级高并发服务到本地轻量化部署，从国产硬件优化到前沿编译技术探索，每种方案都有其独到优势。选择合适的推理方案不仅需考虑技术指标，更要结合业务场景、硬件资源与未来扩展规划。未来，随着技术的不断进步和产业协作的加深，大模型推理生态将呈现出更加多元、灵活和高效的局面，为各领域在激烈竞争中抢占先机提供强大支撑。