

以下是针对企业级服务器部署DeepSeek蒸馏版70B模型的详细方案，包含无内网/有内网网络配置详解，所有专业名词均有解释说明：

## 一、硬件配置要求（关键）

1. GPU（图形处理器）：

- 最低要求：2×NVIDIA A100 80GB（显存总量≥160GB）

解释：模型参数70B（700亿）需大量显存存储，A100是专业计算卡，80GB指单卡显存容量

- 备选方案：8×RTX 4090 24GB（需NVLink互联）

注意：蒸馏版虽比原版小，但仍需48GB+显存

2. CPU（中央处理器）：

- AMD EPYC 7B12 或 Intel Xeon Platinum（≥32核）

解释：多核CPU可加速数据预处理，避免GPU等待

3. 内存：512GB DDR4 ECC（推荐1TB）

解释：ECC内存能自动纠错，保障服务器稳定性

4. 存储：

- 系统盘：1TB NVMe SSD（安装Ubuntu）
- 数据盘：4TB RAID 10阵列（HDD+SSD混合）

解释：RAID 10通过磁盘冗余实现数据安全，读写速度翻倍

5. 电源：≥2000W 80Plus铂金冗余电源

解释：冗余电源可在单电源故障时无缝切换

## 二、操作系统安装（Ubuntu）

1. 版本选择：Ubuntu 22.04 LTS（长期支持版）

下载镜像：官网或国内镜像站（如阿里云）

2. 安装步骤：

```
# 制作启动U盘（Windows用Rufus，Mac用dd命令）
# 服务器BIOS设置U盘启动 → 选择"Install Ubuntu Server"
# 分区建议：/boot 1GB, / 100GB, /home 剩余空间, swap=内存2倍
```

3. 基础配置：

```
sudo apt update && sudo apt upgrade -y # 更新系统
sudo apt install openssh-server         # 远程管理
```

### 三、网络配置详解

#### ► 无内网环境（纯公网部署）

1. 固定公网IP：向ISP申请静态IP（非动态分配）
2. 防火墙规则：

```
sudo ufw allow 22/tcp          # 开放SSH端口
sudo ufw allow 8000/tcp        # 模型API端口（自定义）
sudo ufw enable                 # 启用防火墙
```

3. 安全加固：
  - 禁用密码登录，改用SSH密钥
  - 配置Fail2ban防暴力破解
4. 端口转发：

解释：若服务器位于路由器后，需在路由器设置端口映射（例：公网IP:8000 → 服务器内网IP:8000）

#### ► 有内网环境

1. 网络拓扑：



2. 关键配置：
  - VLAN划分：隔离业务/管理/存储网络  
解释：VLAN像虚拟局域网，不同网段设备无法直接通信
  - 访问控制：
    - 业务网：开放HTTP/API端口（如8000）
    - 管理网：仅限IT运维IP访问SSH（端口22）
  - 高速内网：配置10Gbps交换机，GPU节点间用InfiniBand  
解释：InfiniBand是超低延迟网络协议，加速多GPU通信

### 四、模型部署流程

### 1. 驱动安装:

```
# 安装NVIDIA驱动 (版本≥535)
sudo apt install nvidia-driver-535
nvidia-smi # 验证驱动
```

### 2. 容器化部署 (推荐):

```
# Dockerfile示例 (Evidence 6)
FROM nvidia/cuda:11.8.0-base
COPY ./deepseek-app /app
RUN pip install -r requirements.txt
CMD ["python", "/app/api_server.py"]
```

解释: Docker将应用打包成独立容器, 避免环境冲突

### 3. 模型加载:

#### ◦ 有网环境:

```
git clone https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-
Llama-70B
```

#### ◦ 无网环境:

通过内网机器下载 → 校验SHA256 → U盘拷贝至服务器

### 4. 启动推理服务:

```
# 使用vLLM加速框架 (Evidence 9)
python -m vllm.entrypoints.api_server --model DeepSeek-R1-Distill-Llama-
70B
```

---

## 五、文件存储方案

### 1. 本地存储:

#### ◦ 配置Samba/NFS服务

解释: Samba用于Windows/Linux共享文件, NFS是Linux间网络文件系统

#### ◦ 挂载示例:

```
# 客户端挂载命令
mount -t nfs 服务器IP:/data /mnt/deepseek-data
```

### 2. 云存储对接:

#### ◦ 阿里云OSS/MinIO对象存储 (兼容S3 API)

#### ◦ 配置rclone同步工具:

```
rclone copy /local/path remote:deepseek-bucket
```

---

## 六、维护与监控

### 1. 资源监控：

- Prometheus + Grafana（实时监测GPU/内存使用率）

### 2. 备份策略：

- 每日增量备份 → 异地存储（如磁带机/私有云）

### 3. 安全更新：

```
# 设置无人值守更新
```

```
sudo dpkg-reconfigure -plow unattended-upgrades
```

### 关键注意事项：

1. 蒸馏版70B虽比原版小，但实测仍需 $\geq 48$ GB显存，切勿用消费级显卡硬扛
2. 无内网环境必须配置SSL证书（Let's Encrypt免费申请），防止数据明文传输
3. 多GPU需启用NCCL通信库：`export NCCL_IB_DISABLE=0`（启用InfiniBand）