

DeepSeek全方位解读：模型介绍，优势及应用场景

原创

Quest for Knowledge

于 2025-02-12 10:51:37 发布

阅读量1.7w

收藏 45

点赞数 36

分类专栏：

大模型LLM学习

 文章标签：

人工智能

Deepseek

CC 4.0 BY-SA版权

DeepSeek全方位解读：领先科技背后的革新力量

前言

- 1.DeepSeek整体介绍
- 2.DeepSeek-R1
- 3.DeepSeek-V3
- 4.DeepSeek系列模型之间的关系
- 5.Deepseek优势及应用场景
- 6.模型参数与量化精度的关系
- 7.行业部署Deepseek及应用情况

前言

在当今快速发展的科技世界里，人工智能（AI）已经成为推动社会进步和创新的关键力量。从智能家居到自动驾驶汽车，再到复杂的数据分析与预测模型，AI的应用无处不在，并不断拓展着人类认知和技术实现的边界。而在众多引领这场智能革命的企业和研究机构中，DeepSeek以其独特的核心技术和前瞻性的研究方向脱颖而出，成为行业内外关注的焦点。

本文旨在为读者提供一个深入了解DeepSeek的机会。

1.DeepSeek整体介绍

DeepSeek是一家中国人工智能初创公司开发的大型语言模型和AI助手。该公司由杭州深度求索人工智能基础技术研究有限公司和北京深度求索人工智能基础技术研究有限公司及其关联公司共同开发。DeepSeek的核心产品是基于深度神经网络算法的DeepSeek Chat大语言模型，该模型经过大规模自监督学习的预训练和针对性的优化训练。

DeepSeek的主要功能包括文本生成、对话能力、代码编写、数学计算和推理任务等。它可以集成到各种下游系统或应用中，为用户提供智能对话和内容生成服务。DeepSeek还提供API接口，允许开发者将其集成到自己的应用中。

DeepSeek引起关注的一个主要原因是其在各项基准测试中的出色表现。据报道，DeepSeek在数学、编码和推理任务等多个基准测试中取得了与OpenAI的GPT模型相当的结果，在某些领域甚至超越了GPT。特别是在编码任务中，DeepSeek声称达到了97%的成功率，这一成绩相当令人印象深刻。

DeepSeek-V2.5版本在主要的大模型排行榜上表现出色。在AlignBench测试中，它排名前三，超过了GPT-4并接近GPT-4-Turbo的水平。在MT-Bench测试中，DeepSeek与LLaMA3-70B不相上下，并优于Mixtral 8x22B。这些成绩表明DeepSeek在整体性能上已经达到了顶级水平。

此外，DeepSeek的开源模型支持128K的上下文长度，这为处理长文本和复杂任务提供了更大的灵活性。与ChatGPT和Google Gemini相比，DeepSeek在某些方面展现出独特的优势。例如，在回答时间上，DeepSeek与ChatGPT相当，有时甚至比Google Gemini更快。这种快速响应能力对于需要实时交互的应用来说是一个重要优势。

DeepSeek 主要功能

- 自然语言处理：DeepSeek能够理解和生成自然语言，可以进行语言翻译、文本摘要、情感分析和命名实体识别等任务
- 问答系统：DeepSeek可以回答用户提出的各种问题，包括常识问题、专业问题、历史问题和科技问题等
- 智能对话：能与用户进行智能对话，理解用户的意图和情感，并给出相应的回答
- 代码生成：DeepSeek具备强大的代码生成能力，可以帮助开发者快速生成代码片段，提高开发效率
- 多语言编程支持：在多语言编程测评中表现优异，超越多个竞争对手
- 信息推荐：根据用户的历史行为和偏好，推荐相关的内容和信息
- 内容写作：根据用户提供的关键词和主题，自动生成相关的文章和内容
- 智能客服：可以代替人工客服，回答用户的咨询和问题，提高客服效率和质量
- 联网搜索：类似于GPT search的功能，可以根据网络搜索到的内容提供答案
- 深度思考：在回答问题之前，会进行多步骤的推理和思考，类似于OpenAI的功能
- API和Web服务：提供API和Web服务，方便用户在不同场景下集成和使用DeepSeek的功能

DeepSeek 发布历史

2023年11月2日，DeepSeek发布了其首款模型DeepSeek Coder，该模型免费向研究人员和商业用户开放。该模型的代码以MIT许可协议开源，同时附加了关于“开放和负责任的下游使用”的许可协议。

2023年11月29日，DeepSeek推出了DeepSeek LLM，参数规模达到67B，旨在与当时其他大型语言模型竞争，其性能接近GPT-4。然而，该模型在计算效率和可扩展性方面面临挑战。同时还发布了该模型的聊天版本DeepSeek Chat。

2024年5月，DeepSeek-V2发布。据《金融时报》报道，其价格低于同类产品，每百万输出标记仅需2人民币。滑铁卢大学Tiger Lab的排行榜将DeepSeek-V2列为LLM排名的第七位。

2024年11月，DeepSeek R1-Lite-Preview发布，专为逻辑推理、数学运算和实时问题解决任务设计。DeepSeek声称其在美国数学邀请赛（AIME）和MATH等基准测试中的表现超过了OpenAI o1。然而，《华尔街日报》表示，在用2024年AIME的15道题测试时，o1模型比DeepSeek R1-Lite-Preview更快得出解答。

2024年12月，DeepSeek-V3发布。该模型拥有6710亿参数，训练耗时约55天，成本为558万美元，显著低于同类模型。它基于14.8万亿标记的数据集进行训练。基准测试显示，其性能超越了Llama 3.1和Qwen 2.5，并与GPT-4o和Claude 3.5 Sonnet相匹敌。该模型采用专家混合技术和多头潜在注意力Transformer架构，包含256个路由专家和1个共享专家，每个标记激活超过370亿参数。


2025年1月20日，DeepSeek-R1和DeepSeek-R1-Zero发布。这两款模型基于V3-Base，与V3一样，均采用专家混合架构，总参数量为6710亿，每次激活参数量为370亿。同时还发布了一些“DeepSeek-R1-Distill”模型，这些模型并非基于R1，而是类似于LLaMA和Qwen等开源权重模型，基于R1生成的合成数据进行微调。R1-Zero完全通过强化学习（RL）训练，没有任何监督微调（SFT）。它采用群组相对策略优化（GRPO），通过群组分数而非评价模型估算基线。其奖励系统基于规则，主要包括两类奖励：准确性奖励和格式奖励。R1-Zero的输出可读性较差，且会在输出中切换使用中英文，因此对R1进行了训练以解决这些问题并进一步提高推理能力。

2.DeepSeek-R1

DeepSeek-R1 在后训练阶段大规模使用了强化学习技术，在仅有极少标注数据的情况下，极大提升了模型推理能力。在数学、代码、自然语言推理等任务上，性能比肩 OpenAI o1 正式版。该系列模型通过不断优化算法和增加训练数据，逐步提升了模型的性能和适用性。目前，DeepSeek-R1系列已推出多个版本，包括但不限于：**R1-671B**、**R1-35B**、**R1-13B**、**R1-7B**。R1-7B 是最轻量化的版本，适合移动设备或边缘计算场景。R1-13B 在性能和资源消耗之间找到了平衡，适合大多数企业级应用。R1-35B 和 R1-671B 则分别针对高复杂度和超大规模任务设计，适合云计算和高性能计算环境。

DeepSeek-R1允许用户通过蒸馏技术借助 R1 训练其他模型。DeepSeek-R1 上线 API，对用户开放思维链输出，通过设置 model='deepseek-reasoner' 即可调用。通过 DeepSeek-R1 的输出，蒸馏了6个模型开源给社区，其中 32B 和 70B 模型在多项能力上实现了对标 OpenAI o1-mini 的效果。蒸馏模型主要为 DeepSeek - R1 - Distill - Qwen系列和DeepSeek - R1 - Distill - Llama系列。DeepSeek - R1蒸馏的大参数模型（如DeepSeek - R1 - Distill - Qwen - 32B、

DeepSeek - R1 - Distill - Llama - 70B) 在数学和编程相关测试集表现较好，反映出DeepSeek - R1蒸馏技术对模型性能有提升作用。



论文链接：https://github.com/deepseek-ai/DeepSeek-R1/blob/main/DeepSeek_R1.pdf

蒸馏小模型超越 OpenAI o1-mini

DeepSeek-R1-Zero 和 DeepSeek-R1 两个 660B 模型，通过 DeepSeek-R1 的输出，蒸馏了 6 个小模型开源给社区，其中 32B 和 70B 模型在多项能力上实现了

对标 OpenAI o1-mini 的效果。

	AIME 2024 pass@1	AIME 2024 cons@64	MATH- 500 pass@1	GPQA Diamond pass@1	LiveCodeBench pass@1	CodeForces rating
GPT-4o-0513	9.3	13.4	74.6	49.9	32.9	759.0
Claude-3.5-Sonnet-1022	16.0	26.7	78.3	65.0	38.9	717.0
o1-mini	63.6	80.0	90.0	60.0	53.8	1820.0
QwQ-32B	44.0	60.0	90.6	54.5	41.9	1316.0
DeepSeek-R1-Distill-Qwen-1.5B	28.9	52.7	83.9	33.8	16.9	954.0
DeepSeek-R1-Distill-Qwen-7B	55.5	83.3	92.8	49.1	37.6	1189.0
DeepSeek-R1-Distill-Qwen-14B	69.7	80.0	93.9	59.1	53.1	1481.0
DeepSeek-R1-Distill-Qwen-32B	72.6	83.3	94.3	62.1	57.2	1691.0
DeepSeek-R1-Distill-Llama-8B	50.4	80.0	89.1	49.0	39.6	1205.0
DeepSeek-R1-Distill-Llama-70B	70.0	86.7	94.5	65.2	57.5	1633.0


HuggingFace 链接： <https://huggingface.co/deepseek-ai>

3.DeepSeek-V3

当前版本的 DeepSeek-V3 暂不支持多模态输入输出。DeepSeek-V3系列大规模模型发布时间为2024年12月26日。作为深度求索公司自主研发的首款混合专家（MoE）模型，其拥有6710亿参数，激活370亿，在14.8万亿token上完成了预训练。DeepSeek-V3 多项评测成绩超越了 Qwen2.5-72B 和 Llama-3.1-405B 等其他开源模型，并在性能上和世界顶尖的闭源模型 GPT-4o 以及 Claude-3.5-Sonnet 不分伯仲。

论文链接： https://github.com/deepseek-ai/DeepSeek-V3/blob/main/DeepSeek_V3.pdf

DeepSeek-V3 多项评测成绩超越了 Qwen2.5-72B 和 Llama-3.1-405B 等其他开源模型，并在性能上和世界顶尖的闭源模型 GPT-4o 以及 Claude-3.5-Sonnet 不分伯仲。



- 百科知识：DeepSeek-V3 在知识类任务（MMLU, MMLU-Pro, GPQA, SimpleQA）上的水平相比前代 DeepSeek-V2.5 显著提升，接近当前表现最好的模型 Claude-3.5-Sonnet-1022。
- 长文本：在长文本测评中，DROP、FRAMES 和 LongBench v2 上，DeepSeek-V3 平均表现超越其他模型。
- 代码：DeepSeek-V3 在算法类代码场景（Codeforces），远远领先于市面上已有的全部非 o1 类模型；并在工程类代码场景（SWE-Bench Verified）逼近

Claude-3.5-Sonnet-1022。

- 数学： 在美国数学竞赛（AIME 2024, MATH）和全国高中数学联赛（CNMO 2024）上，DeepSeek-V3 大幅超过了所有开源闭源模型。
- 中文能力： DeepSeek-V3 与 Qwen2.5-72B 在教育类测评 C-Eval 和代词消歧等评测集上表现相近，但在事实知识 C-SimpleQA 上更为领先。

测试集		DeepSeek-V3	Qwen2.5 72B-Inst.	Llama3.1 405B-Inst.	Claude-3.5-Sonnet-1022	GPT-4o 0513
模型架构		MoE	Dense	Dense	-	-
# 激活参数		37B	72B	405B	-	-
# 总参数		671B	72B	405B	-	-
英文	MMLU (EM)	88.5	85.3	88.6	88.3	87.2
	MMLU-Redux (EM)	89.1	85.6	86.2	88.9	88
	MMLU-Pro (EM)	75.9	71.6	73.3	78	72.6
	DROP (3-shot F1)	91.6	76.7	88.7	88.3	83.7
	IF-Eval (Prompt Strict)	86.1	84.1	86	86.5	84.3
	GPQA-Diamond (Pass@1)	59.1	49	51.1	65	49.9
	SimpleQA (Correct)	24.9	9.1	17.1	28.4	38.2
	FRAMES (Acc.)	73.3	69.8	70	72.5	80.5
	LongBench v2 (Acc.)	48.7	39.4	36.1	41	48.1
代码	HumanEval-Mul (Pass@1)	82.6	77.3	77.2	81.7	80.5
	LiveCodeBench(Pass@1-COT)	40.5	31.1	28.4	36.3	33.4
	LiveCodeBench (Pass@1)	37.6	28.7	30.1	32.8	34.2
	Codeforces (Percentile)	51.6	24.8	25.3	20.3	23.6
	SWE Verified (Resolved)	42	23.8	24.5	50.8	38.8
	Aider-Edit (Acc.)	79.7	65.4	63.9	84.2	72.9
	Aider-Polyglot (Acc.)	49.6	7.6	5.8	45.3	16
数学	AIME 2024 (Pass@1)	39.2	23.3	23.3	16	9.3
	MATH-500 (EM)	90.2	80	73.8	78.3	74.6
	CNMO 2024 (Pass@1)	43.2	15.9	6.8	13.1	10.8
中文	CLUEWSC (EM)	90.9	91.4	84.7	85.4	87.9
	C-Eval (EM)	86.5	86.1	61.5	76.7	76
	C-SimpleQA (Correct)	64.1	48.4	50.4	51.3	59.3

CSDN @ (_) _ up

生成速度提升至 3 倍

通过算法和工程上的创新，DeepSeek-V3 的生成吐字速度从 20 TPS 大幅提高至 60 TPS，相比 V2.5 模型实现了 3 倍的提升，为用户带来更加迅速流畅的使用

体验。

4.DeepSeek系列模型之间的关系

DeepSeek R1 并非从零开始构建，而是基于 DeepSeek V3 进行开发。DeepSeek R1 的初版被称为 R1 Zero，这个版本是在V3的基础上，通过强化学习（RL）训练而来的。在这个过程中，DeepSeek V3 模型充当了RL代理的角色，负责执行动作和决策。

尽管在R1 Zero的最终测试中，研究人员发现它在推理任务上的表现相当出色，甚至在AIME 2024等复杂任务中的得分接近如OpenAI-01-0912这样的高级模型，但该模型也暴露出了一些显著的问题。其中最突出的是在处理多语言问题时，R1 Zero会偶尔在同一回答中混合使用多种语言，导致输出结果不一致且混乱。例如，当你用西班牙语提问时，它的回应可能会夹杂着英语和西班牙语，不够连贯和准确。这些问题促使团队进一步优化，将R1 Zero升级为更完善的R1版本。

在成功改进并推出性能更加稳定和高效的DeepSeek R1后，团队并未止步于此。他们继续努力，通过知识蒸馏等技术，将更大规模的模型提炼成体积更小、效率更高的版本，以供更广泛的社区使用。这一系列工作不仅提升了模型的通用性和可用性，也为人工智能领域的研究和发展贡献了重要力量。

以下展示了各个系列模型之间的递进关系。



5.Deepseek优势及应用场景

DeepSeek 技术创新

- 1. 混合专家(MoE)架构：DeepSeek-V3拥有6710亿参数，但每次输入仅激活370亿参数，大幅降低计算成本同时保持高性能。
- 2. 多头潜在注意力(MLA)：这种架构实现了高效的训练和推理。
- 3. 无辅助损失的负载平衡策略：最小化负载平衡对模型性能的负面影响。
- 4. 多tokens预测训练目标：提升了模型的整体性能。
- 5. 高效训练框架：采用HAI-LLM框架，支持16-way Pipeline Parallelism、64-way Expert Parallelism和ZeRO-1 Data Parallelism，降低训练成本。
- 6. 多token预测(MTP)技术：允许模型同时预测多个连续位置的token，提高训练效率并更好捕捉token间依赖关系。
- 7. 多阶段训练方式：包括基础模型训练、强化学习(RL)训练和微调，使模型在不同阶段吸收不同知识和能力。

8. “顿悟时刻”：通过RL框架，AI自发形成类人推理能力，超越预设规则限制。
这些技术创新使DeepSeek在性能、效率和成本方面都取得了显著优势，在多项基准测试中超越其他主流模型，甚至在某些领域接近或超过GPT-4和Claude-3.5-Sonnet等顶级闭源模型。

DeepSeek 应用场景

- 9. 自然语言处理：DeepSeek可以进行语言翻译、文本摘要、情感分析和命名实体识别等任务
- 10. 智能对话：能与用户进行智能对话，理解用户的意图和情感，并给出相应的回答
- 11. 代码生成和辅助：DeepSeek-Coder-V2支持338种编程语言，可以生成代码、解释代码含义、修复代码错误等
- 12. 问答系统：回答用户提出的各种问题，包括常识、专业、历史和科技等领域
- 13. 内容创作：根据用户提供的关键词和主题，自动生成相关的文章和内容
- 14. 智能客服：代替人工客服，回答用户的咨询和问题，提高客服效率和质量
- 15. 多模态交互：处理图像、音频等多种数据形式，适用于智能助手和移动应用等场景
- 16. 数学和推理任务：在数学计算和复杂推理任务方面表现出色
- 17. 信息推荐：根据用户的历史行为和偏好，推荐相关的内容和信息
- 18. 量化投资：作为幻方人工智能公司的产品，DeepSeek在量化投资领域也有应用

这些应用场景涵盖了从日常生活到专业领域的多个方面，展示了DeepSeek作为大型语言模型的多功能性和广泛适用性。

DeepSeek优势：

- 创新的模型架构：DeepSeek采用了混合专家模型（MoE）架构，包括路由专家和共享专家，通过稀疏激活机制大幅减少了计算量。
- 低精度训练：DeepSeek V3原生使用FP8混合精度训练，显著降低了计算和存储需求。
- 多头潜在注意力（MLA）机制：这种改进的注意力机制通过低秩键值联合压缩和解耦旋转位置嵌入，提高了计算效率。
- 优化的训练流程：DeepSeek团队在训练稳定性、多词同时预测等方面进行了深入优化，进一步降低了训练成本。
- 算法创新：DeepSeek证明了算法有很大的提升空间，不需要依赖大量GPU和算力来堆砌效果。

这些创新使得DeepSeek能够以约600万美元的成本训练出一个600B参数的大模型，被认为是工程上的奇迹。据报道，DeepSeek用10-15分之一的成本就训练出了比肩OpenAI GPT-4水平的模型，并且完全开源。这种低成本高效能的模式可能会对整个AI行业产生深远影响，包括刺激更多专用推理模型的诞生和改变企业对API的依赖。

6.模型参数与量化精度的关系

模型的参数量决定了其基础大小，而量化精度（如 FP16、INT8、INT4）则影响每个参数所占用的存储空间。通过降低量化精度，可以显著减少模型的显存和内存占用，但可能会对模型性能产生一定影响。

以下是不同量化精度下，每个参数的存储需求：

- FP16（16位浮点）：每个参数占用 2 字节。
- INT8（8位整数）：每个参数占用 1 字节。
- INT4（4位整数）：每个参数占用 0.5 字节。

根据上述量化精度，每个模型在不同精度下的显存和内存占用估算如下：

模型名称	参数量	FP16 显存占用	INT8 显存占用	INT4 显存占用	FP16 内存占用	INT8 内存占用	INT4 内存占用
DeepSeek-R1-Distill-Qwen-1.5B	1.5B	3.0GB	1.5GB	0.75GB	6.0GB	3.0GB	1.5GB
DeepSeek-R1-Distill-Qwen-7B	7B	14.0GB	7.0GB	3.5GB	28.0GB	14.0GB	7.0GB
DeepSeek-R1-Distill-Llama-8B	8B	16.0GB	8.0GB	4.0GB	32.0GB	16.0GB	8.0GB
DeepSeek-R1-Distill-Qwen-14B	14B	28.0GB	14.0GB	7.0GB	56.0GB	28.0GB	14.0GB
DeepSeek-R1-Distill-Qwen-32B	32B	64.0GB	32.0GB	16.0GB	128.0GB	64.0GB	32.0GB
DeepSeek-R1-Distill-Llama-70B	70B	140.0GB	70.0GB	35.0GB	280.0GB	140.0GB	70.0GB
DeepSeek-R1 671B	671B	1342.0GB	671.0GB	335.5GB	2684.0GB	1342.0GB	671.0GB

说明：

- 显存占用：指模型在 GPU 上运行时所需的显存。
- 内存占用：指模型在 CPU 上运行时所需的内存，通常为显存占用的两倍，用于加载模型和计算缓冲。

注意：

- 实际的显存和内存占用可能因模型架构、批处理大小（batch size）、序列长度（sequence length）以及推理框架等因素而有所变化。
- 采用量化技术（如 INT8 或 INT4）可以显著降低显存和内存占用，但可能会对模型的精度产生一定影响。
- 在 CPU 上运行大型模型可能导致推理速度较慢，建议根据硬件配置选择适当的模型版本。

7.行业部署Deepseek及应用情况

江苏银行

江苏银行于2023年率先研究并开发出行业级大语言模型服务平台“智慧小苏”，通过构建基础设施层、工具层、模型层、服务层与应用层五层架构，做到高度自主可控与定制化。“智慧小苏”依托行业领先的大模型底座，具备文本、图像、代码、语音等灵活可扩展的生成能力，集成的多种单一领域模型，在各特定场景下表现优异。

此次通过引入DeepSeek大语言模型，“智慧小苏”在复杂多模态、多任务场景处理能力、算力节约、效能等方面得到进一步提升。DeepSeek-VL2多模态模型，能够同时处理文本、图像、语音等多种数据类型，较单一领域模型部署节约了算力成本，为进一步解决金融领域复杂的多模态场景问题（如票据识别、合同解析等）提供了技术基础；DeepSeek-R1模型，在模型规模和性能上具备显著优势，为处理复杂任务（如风险评估、投资分析）和生成高质量文本（如报告撰写、合规审查）提供更优解决方案。结合DeepSeek的模型特性，江苏银行“智慧小苏”应用在不同场景实现智能化创新：

运用多模态模型实现合同质检智能化，筑牢企业信贷防火墙。“智慧小苏”通过DeepSeek-VL2多模态模型的细粒度文档理解能力解决了传统模型在非制式合同中存在合并单元格、跨页表格等多结构表格内容识别准确率不足、精度局限的问题，将嵌套表格、手写体混合排版等复杂场景的识别成功率提升至领先水平。通过创新的多模态技术与混合专家框架，识别综合准确率跃升至96%，较传统方案提升12个百分点。利用识别结果结合外部数据等方式智能检测校验合同信息，对风险较高的交易提前发出预警，有效防范潜在的信贷风险。利用DeepSeek模型优化后，识别及预警响应速度提升20%，有效防范潜在的信贷风险，助力分支行更高效地完成受托支付合规性审核。

运用推理模型实现托管资产估值对账自动化，优化流程提质增效。“智慧小苏”通过轻量化DeepSeek-R1推理模型引擎的高效计算特性完成资产托管估值信息自动化解析录入、自动化对账。传统资产托管估值对账依赖人工处理每日超2000封差异化邮件，对TA信息、交易信息、估值信息等区分后手工录入比对，存在录入工作量大、对账异常回溯困难等问题。江苏银行应用R1推理模型，结合邮件网关解析处理能力，实现邮件分类、产品匹配、交易录入、估值表解析对账全链路自动化处理，识别成功率达90%以上，目前已初步实现业务集中运营，按照平均手工操作水平测算，每天可节约9.68小时工作量。

江苏银行持续探索大模型技术在金融场景的应用，在智能客服、智慧办公、数据治理、风险防控等领域都有领先的创新实践，已落地近二十个场景，为客服坐席、客户经理、研发运维人员释放大量生产力。未来，江苏银行将紧紧围绕做好“数字金融”这篇大文章，持续推动数智化转型，积极拥抱大模型带来的变革，不断创新金融服务模式，打造更具竞争力的智慧金融生态，更高效、更智能地服务实体经济。

北京银行

2025年2月8日消息，北京银行今日宣布全面启动“all in AI”战略，携手华为率先实现 DeepSeek 全栈国产化金融应用，致力于打造“人工智能驱动的商业银行”的北京银行。近年来，北京银行在大模型建设与应用方面持续深耕，产研联动，打造了全栈国产化的大模型应用平台，搭建“4+N”全栈国产化大模型应用体系：涵盖全栈国产化算力底座，为大模型运行提供稳定的硬件支撑；企业级知识库，整合海量金融数据与知识；“京翼”MaaS平台，实现模型即服务的便捷应用模式，部署了10余个大型模型；“京骑”Agent的应用平台，推动智能化交互应用的发展。

北京银行表示，基于昇腾系列 AI 服务器、华为 MindIE 推理引擎完成了 DeepSeek V3 和 R1 满血模型、R1 蒸馏模型和 Janus Pro 多模态模型推理任务的快速部署和推理加速调优，并针对 DeepSeek 模型 MoE、MLA 等技术特点，持续开展并行调度、MTP、融合算子等优化方向的推进，率先实现 DeepSeek 全栈国产化

金融应用。

券商、基金

截止目前，已有多家券商、基金宣布完成DeepSeek开源模型的本地化部署，不少公募基金也正探索上述系列开源模型的业务应用场景。

2月6日晚，国金证券、国元证券、华福证券等中小型券商宣布已完成DeepSeek本地化部署测试。该消息一出，券商股在2月7日反应热烈，华林证券一度涨停，国金证券涨近6%，券商板块集体拉升。

与券商一样，基金公司也在密集实行DeepSeek开源模型的私有化部署。2月7日，包括汇添富、富国、国泰、景顺长城、博时、诺安等基金公司都宣布已在探索相关应用场景。沪上某腰部基金公司IT负责人透露，“未来，公司将根据搭建效果运用到代码辅助生成、研报解读、信息披露文件检查、制度解答、非结构化数据核对等相关场景”。

兴业证券表示，目前已搭建强大数智中台，支持包括Qwen等不同开源大模型接入及融合应用，日前又追加完成了DeepSeek V3和R1两款大模型产品接入中台大模型矩阵，可实现诸多业务场景的全面赋能升级。

基金行业也正在适应技术变化。据时代财经了解，诺安基金在完成DeepSeek金融大模型本地化部署的基础上，已经推出基于主流AI开源框架自主研发的“诺安AI助手”，在投研分析、客户服务、风险管控等核心业务场景启动试点应用。

金融科技公司乐信于去年5月正式引入 DeepSeek V2，并在 DeepSeek 基础上通过乐信金融数据进行预训练和微调，形成乐信专有的金融垂直领域大模型“奇点AI大模型”，目前DeepSeek最新的V3和R1版本已在引入中。

据乐信CTO陆勇介绍，乐信“奇点AI大模型”目前已加速在公司多个领域落地应用。业务交互方面，已在电销、客服等主要业务流程中全面落地，提升了公司整体的运营效率和客户体验。