

vllm 工作原理是什么

回答

基于我搜索到的资料，vLLM（**虚拟大语言模型推理加速框架**）的工作原理主要围绕高效内存管理和并行计算优化展开，具体可分为以下核心技术要点：

1. PagedAttention：核心内存管理技术

- 功能：通过分页机制管理**注意力机制中的键值缓存（KV Cache）**，解决显存碎片问题。
- 将 KV Cache 分割为固定大小的块（类似操作系统的虚拟内存分页），存储在非连续显存空间中。
- 动态映射请求与内存块，显著提高显存利用率，支持更多并发请求 [3][6][14]。
- 类比：类似操作系统的虚拟内存机制，允许物理内存不足时使用磁盘交换（vLLM 中 GPU 显存不足时临时交换到 CPU 内存）[6]。

2. 连续批处理（Continuous Batching）

- 动态请求调度：采用“**先进先出 + 抢占式调度**”策略：
- 新请求加入队列，按顺序处理（FCFS）。
- 若 GPU 资源不足，将部分计算暂时交换到 CPU 内存，待资源释放后恢复 [6]。
- 优势：最大化 GPU 利用率，避免传统静态批处理的资源闲置问题 [3][18]。

3. 并行计算优化

- 模型并行化：
- **大型模型分割到多个 GPU（如 Tensor Parallelism），实现分布式推理** [14]。

- 注：截至 v0.4.0 版本，暂不支持 Pipeline Parallelism [14]。
- CUDA 内核优化：针对注意力计算等关键操作优化 GPU 指令，提升计算速度 [3][18]。

4. 推理流程

1. 请求预处理：输入文本分词、向量化（词嵌入/句嵌入） [10][12]。
2. 编码与缓存：
 - 编码器将输入转换为语义向量。
 - KV Cache 存储注意力中间结果（PagedAttention 管理） [10][14]。
3. 解码生成：解码器基于语义向量逐步生成输出文本 [10][12]。
4. 动态调度：调度器协调请求优先级与资源分配 [6]。

5. 插件系统（扩展性支持）

- 机制：通过 Python 的 entry_points 标准接口加载自定义插件。
- 分布式兼容：所有进程（含分布式推理）自动加载插件，无需修改核心代码 [4][20]。

与其他概念的区别

- vLLM ≠ 视觉语言模型（VLM）：
 - [7][8][9]提到的"视觉语言模型"（缩写同为 VLM）是多模态模型（图文融合），与 vLLM 的推理加速框架无关。
- vLLM ≠ 大语言模型本身：
 - [1][2][10]混淆了"框架"与"模型"，vLLM 是服务引擎（如优化 GPT-3 的推理），而非模型结构。

总结

vLLM 的核心是通过 **PagedAttention** 内存分页、连续批处理调度和并行计算优化，解决大语言模型推理中的显存瓶颈与高并发需求。其设计思想借鉴操作系统虚拟内存机制，显著提升吞吐量（如[18]显示推理速度提升数倍），适用于需要高性能 LLM 服务的场景（如聊天机器人、实时翻译）[3][6][14]。

[AI 生成]

相关组织

组织名称	概述	类型
vLLM 社区	维护 vLLM 开源代码库的社区。	技术/开源社区
DeepSeek	提供集成 vLLM 推理引擎的平台。	科技/人工智能

参考资料

1. 什么是 VLLM 原理？ [2025-02-16]
2. 一文看懂什么是 vLLM？虚拟大语言模型详解 [2025-01-16]
3. vllm 算法原理 [2024-08-06]
4. vLLM 的插件系统
5. Tom B. Brown, Benjamin Mann et al. “Language Models are Few-Shot Learners.” ArXiv
6. vLLM 核心技术 PagedAttention 及调度原理 [2024-07-16]
7. 一文详解视觉语言模型 [2025-02-12]
8. 视觉大模型基本原理与发展历程 [2025-01-22]
9. 并非一切都是大模型（LLMs），2025 年你需要了解的 8 种 AI 模型！ [2025-07-02]
10. vLLM Meetup 工作坊：亲手实践 vLLM，掌握实用技能 [2025-03-11]
11. Calibrated Self-Rewarding Vision Language Models

- 12. vLLM 在实际应用中的挑战与机遇 [2025-03-11]
- 13. DeepSeek 本地部署深度解析：从入门到精通 [2025-02-28]
- 14. vLLM 原理 [2025-04-27]
- 15. vllm 背后的秘密，你真的知道吗？ [2024-06-04]
- 16. VLLM 操作指南，学了就能用！ [2024-06-20]
- 17. 以 DeepSeek-VL 为例，详解视觉语言模型原理及代码 [2024-08-17]
- 18. vLLM：高效推理与服务引擎的深度探索 [2024-01-01]
- 19. Tutorial on vLLM Framework
- 20. vLLM 的插件系统专题（三十三） [2022-05-20]