

小飞侠

爱科学-刘磊

[首页](#)[关于](#)[关于我](#)

vllm算法原理

作者: [admin](#)

时间: 2024-08-06

分类: [推理加速](#)

访问: 4,795 次

一 基本介绍

vLLM (Vectorized Large Language Model Serving System) 是一个用于大型语言模型推理加速的工具。它的核心技术主要包括:

PagedAttention技术: 这是一种**内存管理技术**, 可以在不连续的内存空间中存储注意力机制中的键和值, 从而减少显存碎片并提高显存利用率。

连续批处理: vLLM能够连续批处理接入的请求, 充分利用GPU资源, 提高吞吐量。

CUDA核心优化: vLLM对CUDA核心进行了优化, 确保了速度与效率。

分布式推理支持: vLLM支持**分布式推理**, 能够在多台GPU上并行运行模型, 进一步提高推理速度。

一、PagedAttention算法概述

(PagedAttention) 受操作系统虚拟内存和分页思想启发, 将原本连续的 KV cache 存储在不连续的空间, 以避免 KV cache 带来的显存浪费。

PagedAttention算法是一种针对大型语言模型推理过程的优化方案。其核心思想是将**每个序列的KV cache (键值缓存) 分块 (blocks)**, 每块包含固定数量的token的key和value张量。通过这种方式, 算法可以在显存中更灵活地管理键和值, 实现了内存的高效利用和共享。

二、内存管理与块映射

在PagedAttention算法中, KV cache被划分为多个块, 这些块在内存空间中不必连续。这种设计使得算法可以像操作系统的虚拟内存分页一样, 以更灵活的方式管理键和值。**具体而言**, 算法将block视为page, 将token视为bytes, 将序列视为进程。序列的连续逻辑块通过block table映射到非连续物理块。这种映射方式使得物理块可以在生成新token时按需分配, 从而减少了显存的浪费。

三、内存共享与性能提升

PagedAttention算法还通过内存共享的方式进一步减少了显存占用。不同序列可以通过将其逻辑块映射到同一物理块来共享块。这种**共享机制使得显存占用减少了55%, 同时吞吐量提升了2.2倍**。这种性能提升对于在实际应用中部署大型语言模型具有重要意义。

标签: none